Propuestas de implementación de Machine Learning Causal

Seminario de Tesis — Estimación de efectos causales sobre el precio de alquiler de departamentos en Lima

*Base de datos: **data_wramling_final.csv** · ~3.3k avisos geolocalizados · 13 distritos · variables hedónicas (área, dormitorios, baños, antigüedad, distrito, latitud/longitud, precio, precioxm2).*

1. Diagnóstico y oportunidad

Los datos son **observacionales y hedónicos**: describen propiedades reales sin asignación aleatoria de sus atributos. En *notebook1* varias hipótesis ya son, de hecho, **preguntas causales** resueltas con herramientas asociativas — por ejemplo, la hipótesis 2.8 señala que "para aislar el efecto real del número de dormitorios sobre el precio es fundamental controlar por área", y el análisis de antigüedad detecta un resultado contraintuitivo (propiedades más antiguas a veces más caras) que es un síntoma clásico de **confusión** por ubicación y tamaño. El Machine Learning Causal formaliza ese salto de *correlación* a *efecto*: estima cuánto cambiaría el precio si se interviniera sobre un atributo, manteniendo lo demás constante.

2. Marco metodológico común

Grafo causal (DAG) hedónico: el *tratamiento* y el *resultado* (log-precio o log-precioxm2) comparten **confusores** observables: área, ubicación (distrito y coordenadas), tipo y antigüedad. **Identificación:** ignorabilidad condicional (criterio *back-door*) ajustando por esos confusores. **Herramientas: DoWhy** (formalizar/identificar/refutar), **EconML** (DML, Causal Forest, meta-learners) y **causal-learn** (descubrimiento de estructura). Todo ejecutable sobre el CSV actual reutilizando el pipeline *notebook0* → CSV → *notebook1*.

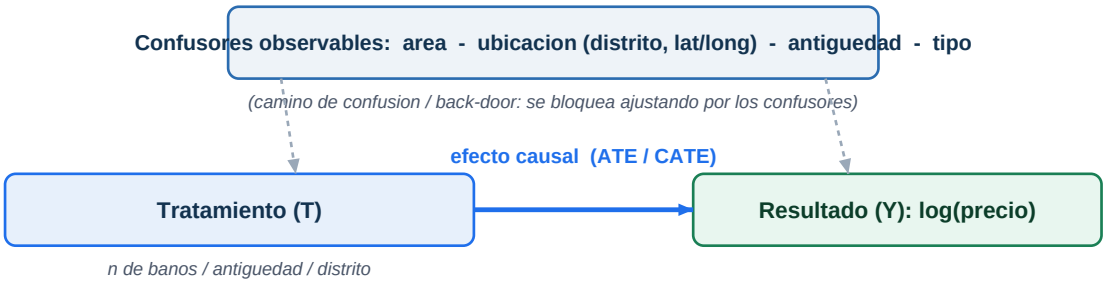

Figura 1. DAG genérico de los estudios propuestos: para estimar T → Y de forma insesgada se ajusta por los confusores que abren el camino back-door.

3. Propuestas concretas de implementación

#	Propuesta y pregunta causal	Tratamiento → Resultado	Método / librería	Vínculo con notebook1
1	**Valor causal de un baño/dormitorio adicional.** ¿Cuánto sube el precio por un baño extra, a igualdad de área y ubicación?	nº baños (o dormitorios) → log(precio)	Double ML: **LinearDML / CausalForestDML** (EconML)	Formaliza la hipótesis 2.8 ("controlar por área"); da ATE + CATE por clase de distrito.
2	**Premio causal de ubicación "Lima Top".** ¿Qué parte del mayor precioxm2 en Miraflores/San Isidro/Barranco/Lince es causal y no composición?	lima_top (0/1) → log(precioxm2)	**Propensity Score** (IPW/matching) o DML + placebo	Reemplaza el t-test / Tukey de la Sección 4 por un contraste ajustado.
3	**Discontinuidad Geográfica (GeoRDD).** Comparar propiedades a ambos lados de la frontera entre un distrito top y uno no-top.	cruzar frontera → log(precioxm2)	RDD espacial sobre **latitud/longitud**; kernel local	Explota las coordenadas (68% precisión ROOFTOP). Identificación fuerte y original.
4	**Depreciación causal por antigüedad.** ¿Efecto de un año más de antigüedad sobre el precioxm2, aislando ubicación y tamaño?	antigüedad (continua) → log(precioxm2)	**CausalForestDML / DRLearner**; curva dosis-respuesta	Resuelve el "puzzle" de la hipótesis 2.7 (antiguo = más caro).
5	**Descubrimiento de estructura + robustez.** Aprender el DAG entre variables hedónicas y auditar la validez de los efectos.	todas las variables (grafo completo)	**PC / LiNGAM / NOTEARS** (causal-learn) + refutadores DoWhy	Respalda la matriz de correlación y el VIF ya calculados.

4. Ejemplo de *pipeline* — Propuesta 1 (Double Machine Learning)

El estimador DML modela por separado **E[Y|X]** y **E[T|X]** con ML flexible (p.ej. gradient boosting), ortogonaliza (residualiza) ambos y regresa los residuos: así obtiene un efecto **insesgado** aunque los *nuisance* se estimen con error. Esquema reproducible sobre el CSV actual:

```
import pandas as pd, numpy as np
from econml.dml import LinearDML
from sklearn.ensemble import GradientBoostingRegressor as GBR

df = pd.read_csv("csv/data_wramling_final.csv")
Y = np.log(df["precio"])                       # resultado
T = df["banos"]                                # tratamiento
X = pd.get_dummies(df[["area","antiguedad","distrito","type",
                       "latitud","longitud"]], drop_first=True)   # confusores

est = LinearDML(model_y=GBR(), model_t=GBR(), random_state=42)
est.fit(Y, T, X=X, W=X)
print("ATE:", est.ate(X), est.ate_interval(X))  # efecto medio + IC 95%
# est.effect(X)  -> CATE por propiedad;  agregar por 'distrito' para heterogeneidad
```

Validación: comparar con OLS/hedónico como línea base; contrastar heterogeneidad (CATE) entre clase1/2/3; ejecutar refutadores de DoWhy (confusor aleatorio, subconjunto, placebo) para acotar la robustez.

5. Plan de trabajo por fases (viable para el seminario)

Fase	Actividad	Entregable
F1	Formalizar el DAG y el objetivo causal; preparar T, Y, X desde el CSV; línea base hedónica (OLS).	DAG + notebook de identificación (DoWhy)
F2	Estimar el efecto núcleo (Propuesta 1, DML): ATE, IC y CATE por distrito.	Estimaciones + gráficos de heterogeneidad
F3	Estudio diferenciador (Propuesta 3, GeoRDD) usando coordenadas y fronteras distritales.	Efecto local + validación de continuidad
F4	Robustez (Propuesta 5): refutadores, análisis de sensibilidad y, opcional, NLP sobre *descripcion*.	Capítulo de validez + conclusiones

6. Ruta recomendada y limitaciones

Núcleo: Propuesta 1 (Double ML) — alta viabilidad, conecta con lo ya hecho y da un efecto interpretable (soles por atributo). **Diferenciador:** Propuesta 3 (GeoRDD), identificación creíble poco explorada en el mercado limeño. **Transversal:** Propuesta 5 como capítulo de validez. El riesgo central son los **confusores no observados** (calidad de acabados, piso, vista, amenities, seguridad), ausentes en el CSV; por eso toda estimación debe acompañarse de **análisis de sensibilidad** (E-value, refutadores de DoWhy) y, de ser posible, del enriquecimiento por **NLP sobre *descripcion*** (piso, vista al mar, remodelado, amoblado, cochera) para mitigar el sesgo por variable omitida.

7. Referencias clave

- Chernozhukov et al. (2018). *Double/Debiased Machine Learning for Treatment and Structural Parameters.* The Econometrics Journal.
- Wager & Athey (2018). *Estimation and Inference of Heterogeneous Treatment Effects using Random Forests.* JASA.
- Künzel et al. (2019). *Metalearners for estimating heterogeneous treatment effects.* PNAS.
- Pearl (2009). *Causality: Models, Reasoning, and Inference.* Cambridge University Press.
- Sharma & Kiciman (2020). *DoWhy: An End-to-End Library for Causal Inference.* · Microsoft **EconML** & **causal-learn** (docs).

---

*Stack sugerido: Python + **DoWhy**, **EconML**, **causal-learn** (opcional **CausalPy** para RDD). Compatible con el entorno actual (pandas / numpy / scikit-learn / statsmodels).*