Guía explicativa de la tesis

Del análisis exploratorio al machine learning causal
qué se hizo, cómo y por qué

Luis Azaña

Octubre 2026

Cómo leer esta guía

Está escrita para alguien que ya domina EDA, análisis de datos y machine learning, pero no tanto la estadística ni la inferencia causal. Cada concepto estadístico se explica la primera vez que aparece, y al final hay un glosario (sección 5). Las cifras son las de las ejecuciones finales de los notebooks 2, 2b, 3, 3b y 4 (muestra con direcciones exactas, cochera como tratamiento principal).

Índice

1. Qué se quiere lograr **3**

1.1. La pregunta . . . 3
1.2. Por qué es difícil: el problema de la confusión . . . 3
1.3. Dos problemas extra de esta versión . . . 3
1.4. Por qué no basta con un buen modelo de machine learning . . . 3
1.5. Objetivos e hipótesis . . . 4

2. Qué dice el notebook de análisis y pruebas estadísticas **4**

2.1. Preparación y EDA . . . 4
2.2. Las pruebas estadísticas, explicadas . . . 5
2.3. Qué aporta y qué no aporta este análisis . . . 5

3. Qué se hace luego: el análisis causal paso a paso **6**

3.1. Paso 1 — Auditoría de los datos (notebook 2) . . . 6
3.2. Paso 2 — Medir la cochera con IA (notebook 2b) . . . 6
3.3. Paso 3 — El grafo causal (DAG) . . . 8
3.4. Paso 4 — Qué se estima (el "estimando") . . . 8
3.5. Paso 5 — Double ML interactivo (dónde está el ML) . . . 9
3.6. Paso 6 — Grilla, sensibilidad, grupos y espacio . . . 9

3.7. Paso 7 — Baños (notebook 3) y simulación (notebook 4) 9

4. Resultados y cómo responden a lo que pide tu asesor **10**

4.1. Resultado principal (OE3, H1) 10

4.2. Qué decisiones importan (OE4, H2) 10

4.3. ¿Varía por zona? (OE4, H3) 11

4.4. Qué tan frágil es (OE4, H4) 11

4.5. Baños (análisis secundario) 11

4.6. ¿El método funciona? (OE6) 11

4.7. Cómo se contrasta con otros estudios 12

4.8. Correspondencia con lo que pide tu asesor 12

4.9. Cómo resumirlo en la defensa 12

4.10. Preguntas probables del jurado 13

5. Glosario mínimo **13**

1. Qué se quiere lograr

1.1. La pregunta

La tesis responde una pregunta de **causa y efecto**:

¿Cuánto cambiaría el precio de alquiler de un departamento si incluyera cochera, sin cambiar nada más?

Como **análisis secundario** se repite la pregunta para *un baño adicional*, que era la pregunta del entregable anterior.

1.2. Por qué es difícil: el problema de la confusión

Los departamentos con cochera incluida también son más grandes (96 frente a 65 m^2), tienen más baños y están en los distritos más caros. Si se comparan directamente, se mezcla el efecto de la cochera con el de todo lo demás.

Ejemplo intuitivo

Las personas que usan encendedor tienen más cáncer de pulmón. ¿El encendedor causa cáncer? No: fumar causa ambas cosas. Fumar es un **confusor**. En la tesis, la **ubicación** y el **área** cumplen ese papel: causan a la vez "tener cochera" y "costar más".

Con los datos de la tesis:

- Comparación directa: los departamentos con cochera incluida cuestan **63 %** más.
- Efecto aislado (resultado final): **7.5 %**.

1.3. Dos problemas extra de esta versión

1. **La cochera no está en la base.** Hay que leerla en el texto del aviso. Para eso se usa IA (OpenAI), con cuidado de no gastar de más y de medir sus errores.
2. **No todas las ubicaciones son exactas.** Google devuelve la precisión de cada dirección. Solo `ROOFTOP` es el edificio exacto; las demás pueden errar por cientos de metros. Como la ubicación es el confusor más importante, **solo se usan direcciones `ROOFTOP`**.

1.4. Por qué no basta con un buen modelo de machine learning

Un modelo predictivo responde *"¿cuánto costará este departamento?"*. La importancia de una variable (o su valor SHAP) dice *cuánto la usa el modelo para adivinar*, no *qué pasaría si la cambiaras*.

La idea central de tu asesor

"No se declara identificada una relación causal por usar XGBoost, redes o DML." La causalidad viene de **supuestos explícitos** (qué causa qué), que luego se ponen a prueba.

1.5. Objetivos e hipótesis

Objetivo general: estimar el efecto causal de que un departamento incluya cochera sobre su precio de oferta y evaluar qué tan sólido es.

Tabla 1: Objetivos específicos (los define tu asesor en `nuevo_informe`)

Objetivo	Qué pregunta responde	Estado
OE1 Auditar los datos	¿Sobre qué población valen los resultados?	Hecho
OE2 Identificación	¿Qué variables controlar y por qué? (DAG)	Hecho
OE3 Estimación	¿Cuánto vale la cochera? ¿Cómo se compara con la regresión?	Hecho
OE4 Variación y sensibilidad	¿Cambia con otras decisiones? ¿Varía por zona? ¿Qué tan frágil es?	Hecho
OE5 IA sobre el texto	¿Se puede medir la cochera desde la descripción?	Hecho (falta validación humana)
OE6 Simulación	¿El método funciona cuando conozco la respuesta?	Hecho
OE7 Trazabilidad	¿Se puede reproducir cada número?	Parcial

H1 Ajustar por los confusores cambia de forma clara la asociación inicial.

H2 Elegir bien los controles importa más que elegir el algoritmo.

H3 El efecto varía por zona o por tamaño (solo si la precisión lo permite).

H4 La conclusión depende de cuán fuertes sean los factores no observados.

2. Qué dice el notebook de análisis y pruebas estadísticas

Esta sección resume `notebook0` y `notebook1` (el trabajo previo) y explica qué hace cada prueba estadística.

2.1. Preparación y EDA

- `notebook0` toma 3 739 avisos del scraping, quita los que no tienen dormitorios, baños, área, precio o distrito (quedan 3 516) y crea variables: precio por m², fecha de publicación binaria y grupos de antigüedad.
- `notebook1` elimina atípicos (precio por m² extremo, combinaciones raras de dormitorios y baños, precios menores de S/ 600) y queda con **3 276 avisos**.
- **Clustering** (K-means sobre PCA de dormitorios, baños, área y precio; 89 % de la varianza en 2 componentes): tres tipos de departamento, pequeños (unos 56 m², S/ 2 100), "normales" (unos 94 m², S/ 2 860) y amplios (unos 238 m², S/ 8 140).
- **Correlaciones**: precio y área tienen una correlación de 0.83. Barranco, Miraflores, San Isidro y Lince tienen el precio por m² más alto.

2.2. Las pruebas estadísticas, explicadas

Qué es un p-valor (en una frase)

Es la probabilidad de ver una diferencia tan grande como la observada *si en realidad no hubiera ninguna diferencia*. Si es menor que 0.05, se dice que la diferencia es "estadísticamente significativa": es poco probable que sea solo azar. No dice nada sobre causas.

Tabla 2: Las 8 aseveraciones del `notebook1` (valores de sus salidas actuales)

Aseveración	Prueba (qué hace)	Resultado
1. Precio/m² entre distritos top	**Tukey**: compara las medias de varios grupos de dos en dos, corrigiendo por hacer muchas comparaciones	Barranco es el más caro; Miraflores está por encima de San Isidro y Lince; San Isidro y Lince no difieren ($p = 0.43$)
2. Medianas Miraflores, San Isidro y Lince	**Kruskal-Wallis**: compara grupos usando rangos (no supone distribución normal)	$p = 0.006$: las medianas no son iguales (Miraflores es mayor)
3. Lima Top al menos 30 % más caro por m²	**Prueba t**: compara las medias de dos grupos	Diferencia estimada del 36 %, $p = 0.0007$
4. Antigüedad y precio	**Spearman**: correlación por rangos (mide si una variable sube cuando la otra sube, aunque no sea en línea recta)	$\rho = 0.07$: relación positiva muy débil
5. Antigüedad y área	Spearman	$\rho = 0.31$: los departamentos antiguos son más grandes
6. Antigüedad y precio/m²	Spearman	$\rho = -0.34$: los antiguos son más baratos por m²
7. Antigüedad y dormitorios + baños	Spearman	$\rho = 0.19$: los antiguos tienen más ambientes
8. Distribución interna y precio, controlando el área	**Regresión lineal múltiple** por clase de distrito	A igual área: un baño más se asocia con S/ 195–298 más y un dormitorio más con S/ 168–323 menos ($R^2 = 0.62$–0.74)

2.3. Qué aporta y qué no aporta este análisis

Aporta una descripción sólida del mercado: dónde es caro, cómo se relacionan tamaño, antigüedad y precio, y qué tipos de departamento existen. Todo eso se reutiliza para *construir el modelo causal*: por ejemplo, la aseveración 5 (los antiguos son más grandes) justifica la flecha "antigüedad → área" del grafo.

No aporta efectos causales:

- Las pruebas 1–7 comparan grupos o correlacionan dos variables *sin controlar nada más*. Que Lima Top sea un 36 % más caro por m² puede deberse, en parte, a que allí los departamentos son distintos.

- La aseveración 8 sí intenta "controlar el área" y, por eso, **es la semilla de la tesis actual**. Pero usa una regresión lineal con variables elegidas a mano: no justifica por qué esas variables y no otras, supone relaciones en línea recta y trata cada aviso como independiente.

Conexión clave

La aseveración 8 ya era una pregunta causal ("el efecto de los baños, a igual área") resuelta con herramientas asociativas. La tesis actual responde *la misma pregunta* con las herramientas correctas: grafo causal, Double ML, inferencia agrupada, análisis de sensibilidad y simulación.

3. Qué se hace luego: el análisis causal paso a paso

El flujo nuevo tiene cinco notebooks, en este orden:

`notebook2_auditoria` → `notebook2b_extraccion_ia` → `notebook3b_efecto_cochera` → `notebook3_estimacion_causal` (baños) → `notebook4_semisintetico`

Las funciones comunes están en `causal_utils.py`, `extraccion_ia.py` y `semisintetico.py`.

3.1. Paso 1 — Auditoría de los datos (notebook 2)

Tabla 3: De dónde salen los 2 220 avisos finales

Paso	Excluidos	Quedan
Archivo crudo del scraping	–	3 739
Sin baños, dormitorios, área, precio o distrito	223	3 516
Duplicados (83 eran el mismo aviso en dos distritos)	243	3 273
Coordenada a más de 8 km de su distrito	26	3 247
Dirección no exacta (distinta de `ROOFTOP`)	967	2 280
Reglas del `notebook1` (rangos, combinaciones raras, atípicos)	60	**2 220**

Qué es ROOFTOP

Cuando Google geocodifica una dirección, devuelve su precisión. `ROOFTOP` es el edificio exacto. `RANGE_INTERPOLATED` está interpolada en la cuadra, `GEOMETRIC_CENTER` es el centro de una calle y `APPROXIMATE` el centro del barrio, donde caen decenas de avisos en el mismo punto. Solo el 70 % de los avisos era `ROOFTOP`.

3.2. Paso 2 — Medir la cochera con IA (notebook 2b)

Para ahorrar tokens, la extracción se hace en capas:

1. **Regex**: se buscan *cochera, estacionamiento, parqueo, parking, garaje* y sus variantes. Si no aparece ninguna, el aviso queda como *sin cochera* **sin llamar a la API** (659 avisos).

2. **Fragmento**: para cada mención en la posición x se toma `texto[x-200 : x+200]` (sin pasarse de los bordes). Los fragmentos que se tocan se unen.

3. **Privacidad**: se borran teléfonos, correos y enlaces.

4. **OpenAI**: `gpt-4.1-mini-2025-04-14`, temperatura 0, respuesta obligada a un JSON fijo:

```
{"cochera":"si", "tipo":"incluida", "precio_extra":0, ..., "motivo":"Incluye 1
                                    estacionamiento"}
```

5. **Caché**: cada respuesta se guarda; volver a ejecutar no cuesta nada.

Un **piloto de 25 avisos** reveló tres errores del primer prompt: marcar como "ambigua" una cochera sin precio, leer "ALQUILER CON COCHERA $700" como 700 de costo extra y no reconocer "sin cochera, pero se puede alquilar". Se corrigieron antes de la corrida completa. **Costo total: 0.76 USD.**

Tabla 4: Resultado de la extracción

Clasificación	N	Uso
Cochera incluida (sin pago extra mencionado)	1 095	$D = 1$
No menciona cochera	659	$D = 0$
Menciona, pero la IA lee "no tiene" (visitas, calle, "sin cochera")	297	$D = 0$
Cochera con costo extra (mediana S/ 250)	150	Excluido
Ambigua	19	Excluido

Supuestos de esta medición

(1) Si el aviso no menciona cochera, se asume que no la tiene. (2) Si tiene cochera y no menciona un pago extra, se asume incluida. Solo 155 avisos dicen "incluida" literalmente. (3) Tu asesor exige una **validación humana**: hay 249 avisos listos para que los etiquetes en `csv/validacion_cochera_para_etiquetar.csv`.

3.3. Paso 3 — El grafo causal (DAG)

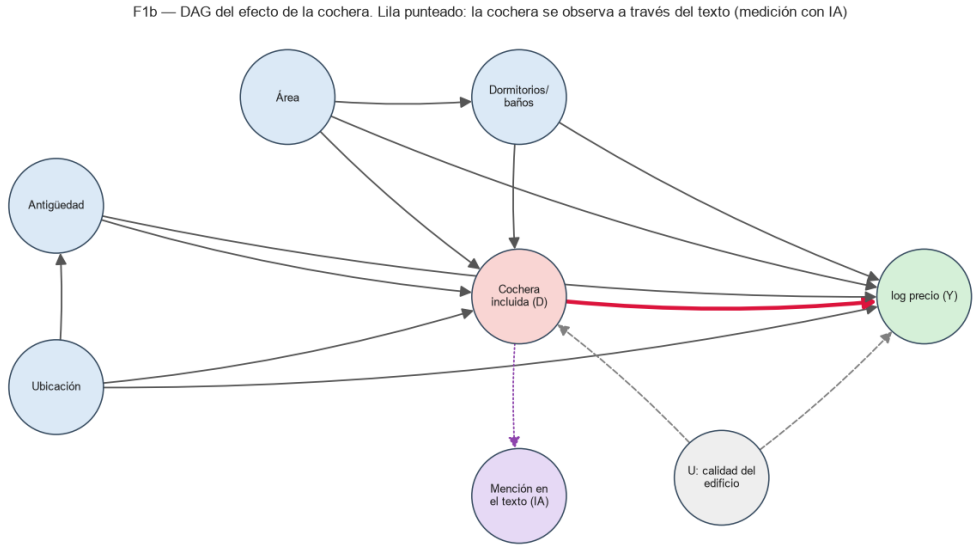


Figura 1: DAG de la cochera. La flecha roja es el efecto que se quiere medir.

Tabla 5: Tipos de variables y qué hacer con cada una

Tipo	Forma en el grafo	¿Controlar?	En la tesis
Confusor	Causa a D y a Y	**Sí**	Área, ubicación, antigüedad, baños, dormitorios
Descendiente de Y	Consecuencia del resultado	**No**	Precio por m²
Confusor no observado	Causa a D y a Y, no está en los datos	Imposible	Calidad del edificio

El grafo no lo deciden los datos: lo construyes tú con conocimiento del mercado y con el **orden temporal**. Primero existen el terreno y el edificio, luego se diseña el departamento (con o sin cochera) y al final se fija el precio. Las flechas no tienen peso; solo dicen qué controlar.

3.4. Paso 4 — Qué se estima (el "estimando")

El **efecto promedio** (ATE) de tener cochera incluida, en log del precio, entre los avisos con **soporte común**. En porcentaje es $100\,(e^{\theta} - 1)$.

Propensión y soporte común

La **propensión** $m(X)$ es la probabilidad de que un aviso tenga cochera dado su perfil (área, zona…). Si un perfil tiene propensión 0.99, casi todos los departamentos parecidos tienen cochera: no hay con quién compararlo. El **soporte común** es quedarse con los avisos con propensión entre 0.05 y 0.95, donde sí hay comparaciones reales.

3.5. Paso 5 — Double ML interactivo (dónde está el ML)

Como el tratamiento es sí/no, se usa la versión **IRM** (o AIPW) de Double ML, con **3 modelos** de *gradient boosting*:

1. **Modelo A** (clasificador): predice si tiene cochera a partir de X. Es la propensión $\hat{m}(X)$.
2. **Modelo B**: predice el precio *de los que tienen cochera* a partir de X, $\hat{g}_1(X)$.
3. **Modelo C**: predice el precio *de los que no tienen*, $\hat{g}_0(X)$.

Para cada aviso se calcula el **score doblemente robusto**:

$$\phi = \underbrace{\hat{g}_1 - \hat{g}_0}_{\text{diferencia predicha}} + \underbrace{\frac{D\,(Y-\hat{g}_1)}{\hat{m}} - \frac{(1-D)\,(Y-\hat{g}_0)}{1-\hat{m}}}_{\text{corrección por el error de predicción}}$$

El efecto es el **promedio de** ϕ en el soporte común. "Doblemente robusto" significa que basta con que el modelo de la propensión *o* el del precio esté bien para que el resultado sea correcto.

Igual que antes: *cross-fitting* con 5 folds agrupados por edificio (un edificio nunca está a la vez en entrenamiento y en prueba), 10 repeticiones y errores agrupados por edificio.

Balance: ¿quedaron comparables?

Se mide la **diferencia estandarizada** (SMD) de cada variable entre los grupos con y sin cochera. Antes del ajuste, el área difiere 0.92 desviaciones estándar; después de ponderar por la propensión, todas quedan por debajo de 0.05. Bajo 0.1 se considera buen balance.

3.6. Paso 6 — Grilla, sensibilidad, grupos y espacio

- **Grilla**: se repite cambiando *una* decisión (quitar la ubicación, agregar el precio/m², usar la definición estricta de "incluida", etc.).
- **Sensibilidad**: ¿qué tan fuerte tendría que ser un factor oculto (la calidad del edificio) para anular el efecto? Se compara con la fuerza de los factores observados.
- **GATE**: el efecto por clase de distrito y por tamaño, con una prueba de Wald de igualdad.
- **I de Moran**: ¿los errores de avisos cercanos se parecen?

3.7. Paso 7 — Baños (notebook 3) y simulación (notebook 4)

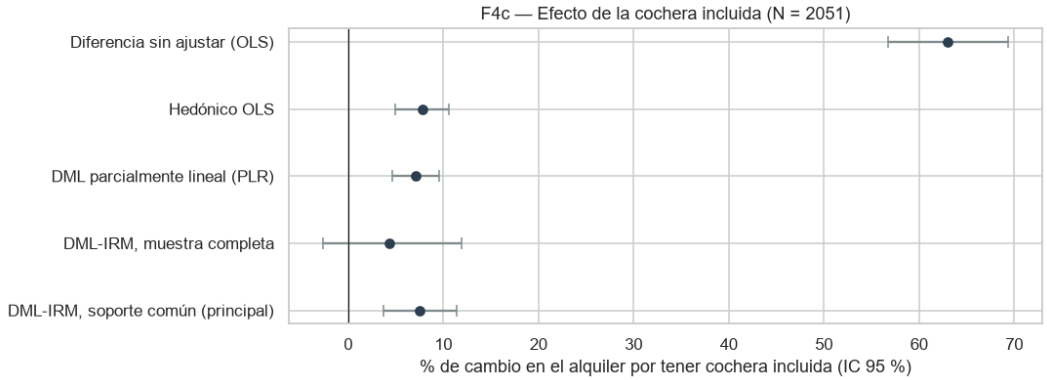
- **Baños**: el mismo análisis del entregable anterior (Double ML parcialmente lineal: 2 modelos y residuos), ahora solo con ROOFTOP y con la cochera como control adicional.
- **Simulación**: se toman los avisos reales y se *inventa* el tratamiento y el precio con un efecto conocido (0.10 para la cochera, 0.05 para los baños), con y sin factores ocultos. Se mide si los métodos aciertan. Son 800 réplicas en total.

4. Resultados y cómo responden a lo que pide tu asesor

4.1. Resultado principal (OE3, H1)

Tabla 6: Efecto de tener cochera incluida

Método	Efecto	IC 95 %	En soles (alquiler S/ 2 650)
Diferencia directa	63.0 %	56.8 – 69.4 %	S/ 1 668
Regresión lineal con controles	7.8 %	5.0 – 10.6 %	S/ 206
Double ML parcialmente lineal	7.1 %	4.6 – 9.6 %	S/ 187
Double ML IRM, soporte común (principal)	**7.5 %**	**3.7 – 11.4 %**	**S/ 199**



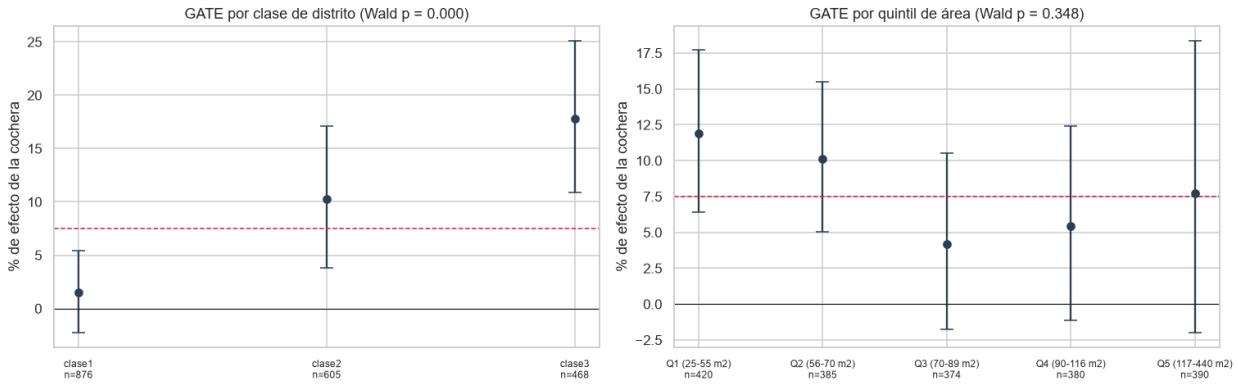
Lectura: casi todo el 63 % bruto era tamaño y zona. **H1 se confirma.** Aquí, a diferencia de los baños, la regresión lineal y Double ML coinciden. Sin el recorte al soporte común, el IRM se vuelve inestable (4.3 %, con un IC de −2.7 a 11.9 %), lo que muestra por qué el recorte es necesario.

4.2. Qué decisiones importan (OE4, H2)

- **Sin la ubicación**: 21.7 %, el efecto se triplica porque las cocheras abundan en los distritos caros.
- Sin el área: 11.4 %. Sin baños ni dormitorios: 9.1 %.
- **Con el precio por m²** (prohibido): −0.5 %.
- Solo "incluida" explícita: 7.9 %. Contando también las cocheras de costo extra: 5.3 %, lo esperable porque su precio no las incluye.

H2 se confirma.

4.3. ¿Varía por zona? (OE4, H3)



Sí: en Miraflores, San Isidro, Barranco y Lince la cochera casi no se paga (1.5 %, no significativo). En la clase2 vale 10 % y en la clase3 18 % (Wald $p = 0.0001$). Una explicación posible, no probada: donde casi todos los avisos tienen cochera, no diferencia a uno de otro; donde escasea, se paga. Por tamaño no hay diferencias. **H3 se confirma para la cochera.**

4.4. Qué tan frágil es (OE4, H4)

- **RV = 0.105**: un factor oculto que explique el 10.5 % de la variación sobrante de la cochera y del precio anularía el efecto.
- Uno tan fuerte como la **antigüedad** lo dejaría en 0.4 %. Uno como la **ubicación** lo invertiría.
- La simulación mostró que esta cota es **optimista** para el tratamiento binario: la fragilidad real podría ser mayor.

H4 se confirma: es un resultado **frágil**; vale bajo los supuestos del DAG.

4.5. Baños (análisis secundario)

Un baño adicional sube el precio **3.8 %** (1.7–6.0 %), unos S/ 100 al mes. Antes, con todas las direcciones, daba 5.3 %: **la ubicación imprecisa inflaba el efecto**. Controlar por la cochera lo deja en 3.5 %. No varía por zona y es igual de frágil.

4.6. ¿El método funciona? (OE6)

Tabla 7: Qué muestra la simulación

Escenario	Resultado
Cochera, nada oculto	Los tres métodos aciertan (cobertura 94–96 %).
Cochera, factor oculto	Todos se sesgan (+0.04) y la cota de sensibilidad lo **subestima**.
Baños, nada oculto	Double ML acierta (93 %); la regresión lineal se sesga.
Baños, factor oculto	Double ML se sesga, pero la cota **sí** lo detecta (95–98 %).

4.7. Cómo se contrasta con otros estudios

Tabla 8: Contraste con los antecedentes

Referencia	Qué se puede decir
Tu propio avance (notebook1)	La regresión lineal daba S/ 195–298 por baño; el análisis causal con direcciones exactas da ≈ S/ 100.
UPeU (2024), ESAN (2026)	Dicen que la cochera es de los mejores *predictores* del precio en Lima. Tú mides cuánto vale realmente: mucho menos que la diferencia bruta (7.5 % frente a 63 %).
BCRP (2018)	**No es comparable en magnitud**: estudia la venta y cada cochera adicional. Sí coincide en la dirección y en que la cochera es lo más valorado.
El propio mercado	Quien cobra la cochera aparte pide una mediana de **S/ 250**, del mismo orden que tus S/ 199. **Es la mejor validación de magnitud.**
Ordenanzas (Miraflores, San Isidro)	Exigen estacionamientos mínimos por vivienda; ahí la cochera es habitual (78 % en Miraflores) y casi no se paga extra.
Gabbe y Pierce (2017), EE. UU.	Cochera incluida +17 %; en Lima es menor, coherente con que solo ≈ 17 % de hogares tiene auto.

4.8. Correspondencia con lo que pide tu asesor

Tabla 9: Requisitos de `nuevo_informe` y dónde se cumplen

Requisito	Dónde	Estado
Tratamiento binario bien definido	Cochera incluida (notebook 2b)	Hecho
R1 Auditoría y geografía	notebook 2	Hecho
R2 Balance y soporte común	notebook 3b	Hecho
R3 Estimación primaria	notebook 3b	Hecho
R4 Especificaciones	notebook 3b (y 3 para baños)	Hecho
R5 Robustez a factores ocultos	notebook 3b	Hecho (cota optimista)
R6 Validación semisintética	notebook 4	Hecho
R7 Heterogeneidad	notebook 3b	Hecho
R8 IA de medición	notebook 2b	Hecho; falta la validación humana
Figuras F1–F7	`resultados/figuras`	Todas
Manuscrito y presentación	`informe/`	Hecho (65 págs.; 15 diapositivas)
Un comando que reproduzca todo	–	Pendiente

4.9. Cómo resumirlo en la defensa

1. **Observacional**: con cochera, los avisos cuestan un 63 % más, pero casi todo es tamaño y zona.

2. **Causal (condicionado al DAG)**: tener cochera incluida sube el precio de oferta un 7.5 % (3.7–11.4 %), unos S/ 199 al mes.

3. **Hallazgo nuevo**: la cochera casi no se paga en los distritos más caros y se paga mucho

donde escasea.

4. **Metodológico**: la IA mide la cochera por menos de 1 USD, y usar solo direcciones exactas cambia los resultados.

5. **Límite honesto**: un factor oculto como la antigüedad lo anularía, y falta validar la IA con etiquetas humanas.

4.10. Preguntas probables del jurado

¿Cómo sabes que la IA leyó bien la cochera?
Todavía no lo sé con certeza: el piloto corrigió errores evidentes y hay 249 avisos listos para la validación humana. Por eso el resultado se presenta como exploratorio.

¿Y si un aviso tiene cochera pero no lo menciona?
Quedaría como "sin cochera". Si ese error es parejo entre zonas, achica el efecto: el real sería mayor.

¿Por qué solo ROOFTOP?
Porque la ubicación es el confusor más importante. Con direcciones aproximadas, el control de la ubicación queda incompleto; de hecho, el efecto de los baños se inflaba.

¿Por qué recortar a propensión 0.05–0.95?
Porque fuera de ese rango no hay departamentos comparables: el efecto solo podría extrapolarse. Sin recorte, el estimador se vuelve inestable.

¿Por qué la cochera vale tan poco en Miraflores?
Hipótesis: allí la mayoría de la oferta ya la tiene y no diferencia un aviso de otro. No está demostrado.

5. Glosario mínimo

Tratamiento (T)
La variable cuyo efecto se mide: el número de baños.

Resultado (Y)
Lo que se ve afectado: el logaritmo del precio.

Confusor
Variable que causa a la vez el tratamiento y el resultado (el área). Hay que controlarla.

DAG
Grafo de flechas "A causa B" que resume los supuestos causales.

Criterio back-door
Regla para decidir qué controlar: bloquear todos los caminos no causales entre T e Y.

Estimando
La cantidad exacta que se quiere estimar (θ).

Residuo
Lo que un modelo no logra explicar: valor real menos valor predicho.

Double ML
Método que usa ML para quitar el efecto de los confusores al precio y al tratamiento, y luego relaciona los residuos.

Cross-fitting
Predecir cada dato con modelos que no lo vieron al entrenar (como un cross-validation).

p-valor
Probabilidad de ver un resultado así de extremo si no hubiera ningún efecto. Si es menor que 0.05, se llama "significativo".

Intervalo de confianza (IC 95 %)
Rango de valores compatibles con los datos; un procedimiento que acierta el 95 % de las veces.

Error estándar (EE)
Cuánto variaría la estimación con otra muestra.

Errores agrupados
Errores estándar que reconocen que las observaciones de un mismo grupo (edificio o zona) no son independientes.

R^2
Fracción de la variación de una variable que un modelo explica (0 a 1).

Valor de robustez (RV)
Fuerza mínima de un factor oculto para anular el efecto.

GATE
Efecto promedio calculado dentro de un grupo predefinido.

Prueba de Wald
Prueba de si varios efectos son iguales entre sí.

Potencia
Probabilidad de detectar un efecto que realmente existe.

I de Moran
Medida de cuánto se parecen los valores de puntos cercanos en el mapa.

Propensión
Probabilidad de recibir el tratamiento (tener cochera) dado el perfil del departamento.

Soporte común
Zona de perfiles donde hay departamentos con y sin tratamiento para comparar (propensión entre 0.05 y 0.95).

Balance / SMD
Qué tan parecidos son los grupos con y sin tratamiento; diferencia estandarizada menor que 0.1 = parecidos.

IRM / AIPW
Double ML para tratamientos sí/no: combina la propensión y dos modelos del precio en un score doblemente robusto.

ROOFTOP
Precisión de geocodificación de Google que indica el edificio exacto.

Modelo de lenguaje (LLM)
Modelo de IA de texto (aquí `gpt-4.1-mini`) usado para leer las descripciones.

Sesgo
Error sistemático: cuánto se equivoca un método en promedio.

RMSE
Error típico de un método (combina el sesgo y la variabilidad).

Cobertura
Porcentaje de veces que el IC contiene el valor verdadero (ideal: 95 %).

Simulación semisintética
Usar datos reales pero inventar el resultado con un efecto conocido, para comprobar si el método lo recupera.