Efecto causal de un baño adicional en el precio de oferta de alquiler en Lima Metropolitana

Inferencia causal espacial asistida por aprendizaje automático

Luis Azaña

Seminario de Tesis 2

2026

Problema: la correlación no responde la pregunta

- Pregunta contrafactual: **¿cuánto cambiaría el alquiler si el mismo departamento tuviera un baño más?**
- Los departamentos con más baños son también más grandes, más nuevos y mejor ubicados.
- Los estudios locales **predicen** precios (hedónico, XGBoost); no identifican efectos.
- ML flexible $\neq$ causalidad: hace falta un modelo causal explícito.

+45 %
asociación sin ajustar

?
efecto causal

Alcance, objetivos e hipótesis

Alcance

- Precio *de oferta* mensual, no contrato.
- Avisos de un portal, 13 distritos, marzo 2025.
- Tratamiento: nº de baños (1–5). Resultado: log(precio).

Objetivos

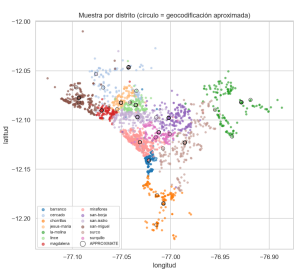
- OE1 auditoría · OE2 identificación · OE3 estimación
- OE4 heterogeneidad y sensibilidad · OE6 simulación · OE7 trazabilidad
- OE5 (IA sobre el texto): diferido

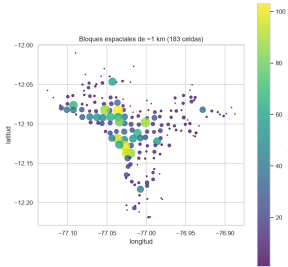
Hipótesis (sin dirección obligatoria)

- H1: el ajuste cambia la asociación.
- H2: la composición causal de los controles importa más que el algoritmo.
- H3: hay heterogeneidad, solo si la precisión la respalda.
- H4: la solidez depende de la fuerza de los confusores no observados.

Datos: auditoría de la muestra (R1)

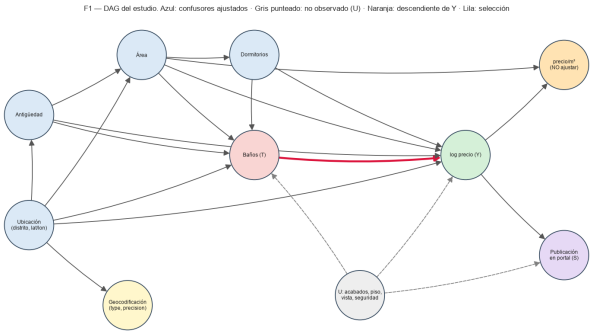
Paso	N
Archivo crudo	3 739
Variables núcleo completas	3 516
– **duplicados** (83 en 2 distritos)	−243
– **geocodificación incoherente**	−26
– reglas de depuración F1–F6	−219
Muestra analítica	**3 028**





- 2 178 edificios (37 % de avisos comparte edificio).
- Antigüedad faltante: 25 % (0 % en Miraflores, 47 % en Cercado).

Intervención, estimando y DAG



$$Y = \theta\, T + g(X) + \varepsilon$$

- θ: efecto de **un baño más** con área, dormitorios, antigüedad y ubicación fijos.
- **Ajustar**: confusores previos (azul).
- **No ajustar**: precio/m^2 (descendiente de Y), baños/dormitorio (contiene T).
- **Amenaza**: calidad no observada U.

Método: Double ML con dependencia espacial

1. Predecir el precio y los baños a partir de los confusores con *gradient boosting* (relaciones no lineales).
2. *Cross-fitting*: cada aviso se predice con modelos entrenados **sin su edificio** (5 folds agrupados $\times$ 10 repeticiones).
3. Residuos: $\tilde{Y} = Y - \hat{E}[Y|X]$, $\tilde{T} = T - \hat{E}[T|X]$.
4. Efecto: pendiente de $\tilde{Y}$ sobre $\tilde{T}$.
5. Inferencia **agrupada por edificio** (alternativa: bloques de 1 km).

Además: grilla preespecificada de controles, sensibilidad a confusores omitidos, efectos por grupos (GATE), I de Moran y validación semisintética.

Resultado principal (R3)

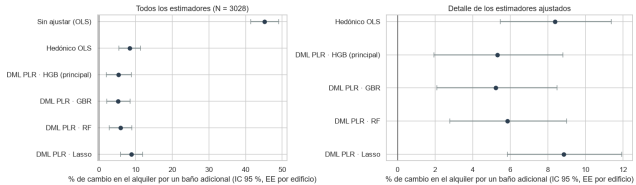
+5.3 %

por baño adicional

IC 95 %: 1.9 – 8.8 %

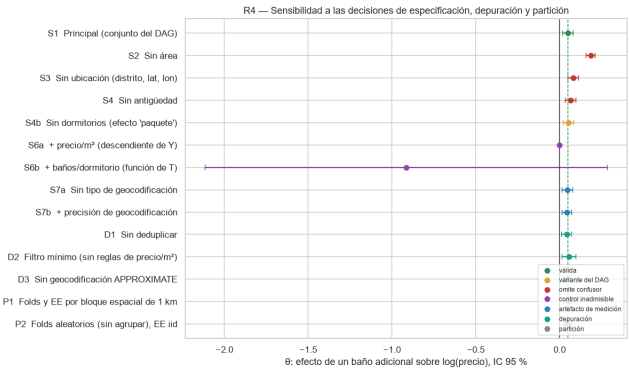
≈ S/ 133

al mes (alquiler de S/ 2 500)



Sin ajustar: 45.1 % → hedónico lineal: 8.4 % → DML: 5.3 %. Los tres *learners* de árboles coinciden (5.2–5.8 %). **H1 se confirma.**

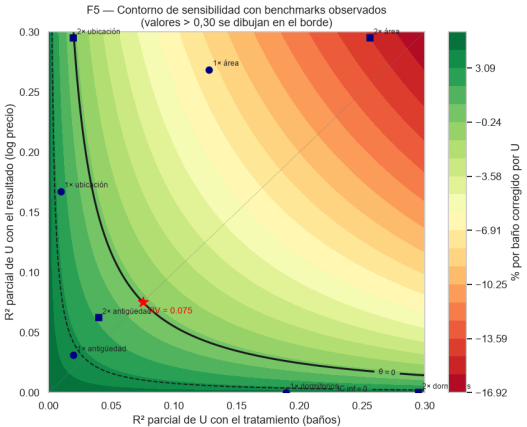
¿Qué controles? La grilla de especificaciones (R4)



- Sin área: **20.4 %** (se cuadruplica).
- $+$ precio/m^2: $\approx$ **0** (control inadmisible).
- $+$ baños/dormitorio: errático.
- Sin deduplicar, filtro mínimo, sin geocodificación aproximada, otras particiones: **4.2–5.8 %**.

H2 se confirma: la composición causal importa más que el algoritmo.

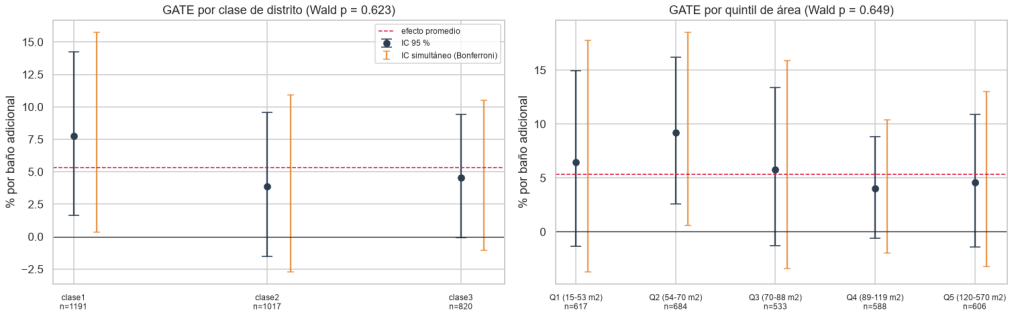
Robustez a confusores no observados (R5)



- **RV = 0.075**: un U que explique el 7.5 % de la varianza residual de los baños y del precio anula el efecto.
- U tan fuerte como la **antigüedad** $\rightarrow$ 3.6 % (sigue siendo > 0).
- U tan fuerte como la **ubicación** $\rightarrow$ 2.5 % (el IC incluye 0).
- U tan fuerte como el **área** $\rightarrow$ cambia de signo.

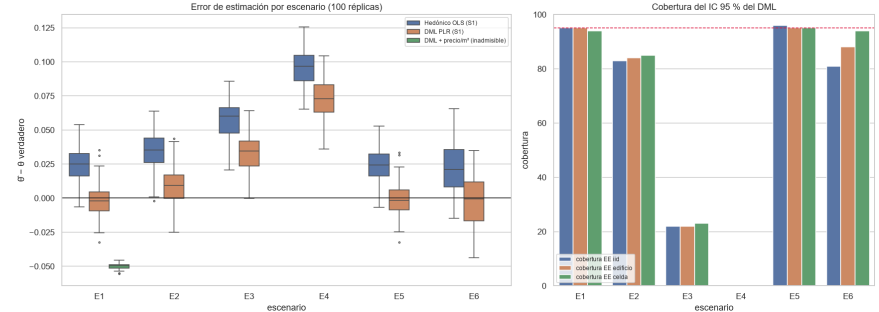
H4 se confirma: fragilidad **moderada**.

Heterogeneidad y dependencia espacial (R7)



- Sin diferencias significativas por clase de distrito ni por tamaño (Wald $p > 0.6$) $\rightarrow$ **H3 sin respaldo** (no concluyente: baja potencia).
- Residuos del precio con autocorrelación espacial (I de Moran $= 0.06$, $p = 0.001$): EE agrupados 31–39 % mayores que los iid; el IC sigue excluyendo el 0.

Validación semisintética: ¿funciona con verdad conocida? (R6)



- Covariables reales, $\theta_0 = 0.05$, 600 réplicas. **Sin** U: DML insesgado y cobertura 95 %; el hedónico lineal se sesga ($+0.025$; cobertura 50 %).
- **Con** U: el DML se sesga y el IC no lo detecta; la **cota de sensibilidad sí** recupera la cobertura (92–96 %).
- Heterogeneidad real (0.03 vs 0.08) detectada solo el 24 % de las veces. Dependencia espacial: hay que agrupar al nivel correcto.

Medición con IA (OE5) y límites

OE5: diferido, con diseño listo

- El texto de los avisos menciona vista, ascensor, acabados…: *proxies* de la calidad U.
- Requiere: taxonomía, 200–300 avisos etiquetados a mano, precisión/*recall*, posición causal en el DAG.
- Especificación S5 reservada.

Límites

- Ignorabilidad: se acota, no se prueba.
- Un portal, un mes, precio de oferta.
- Antigüedad faltante en el 25 %.
- Efecto lineal por baño; sin diagnóstico formal de soporte común.

Conclusiones

- **Respuesta**: bajo los supuestos del DAG, un baño adicional eleva el precio de oferta en **5.3 %** (1.9–8.8 %), unos S/ 133 al mes.
- **Hallazgo observacional**: el 86 % de la asociación bruta se explica por tamaño, antigüedad y ubicación.
- **Metodológico**: el hedónico lineal sobreestima incluso sin confusión omitida; los malos controles destruyen la estimación.
- **Fragilidad**: moderada; resiste un confusor como la antigüedad, no como la ubicación.
- **No se afirma**: que construir un baño sea rentable, ni que el efecto valga para contratos o para toda Lima.

Contribución y continuidad

Contribución verificable

- Auditoría reproducible (duplicados entre distritos, geocodificación).
- Efecto con identificación explícita e inferencia agrupada.
- Demostración empírica de buenos y malos controles.
- Sensibilidad calibrada y validada con simulación.

Siguiente entregable

- OE5: *proxies* de calidad desde el texto (S5).
- Tratamiento binario (cochera) con DML-IRM y soporte común.
- Repositorio con una orden reproducible y pruebas.
- Más meses y portales para estudiar la heterogeneidad.

¡Gracias!