# Cómo se estima el efecto de la cochera (Double ML interactivo)

Resumen de la sesión de preguntas sobre `notebook_resumen.ipynb`

**La pregunta**

¿Cuánto aumenta el precio de oferta de un alquiler en Lima por incluir cochera, comparando departamentos **equivalentes en todo lo demás**? El notebook resumen parte de datos ya limpios (`notebook2`) y de la cochera ya medida con IA (`notebook2b`): 2 220 avisos ROOFTOP, de los que 2 051 tienen el tratamiento definido.

**1. Qué entra al modelo.** *Tratamiento* $D$: cochera incluida (1) o sin cochera (0). Es binario porque la pregunta es "¿incluye o no?" y así lo pide el asesor; el 74 % de los tratados tiene una sola cochera, y los que tienen 2 o más se tratan igual. *Resultado* $Y = \ln(\text{precio})$: el logaritmo natural convierte diferencias en porcentajes, porque $\ln a - \ln b = \ln(a/b)$, y reduce el peso de los alquileres extremos. *Controles* $X$ (23 columnas): los confusores del DAG (log del área, dormitorios, baños, antigüedad e indicador de faltante, latitud, longitud y distrito), más días publicado y tipo de geocodificación. No entra el precio por m², porque se calcula con el precio.

**2. Modelo 1: la propensión $m(X) = P(D = 1 \mid X)$.** Es un clasificador de *gradient boosting* (cientos de árboles). Los árboles parten el espacio de $X$ buscando hojas puras, así que departamentos parecidos quedan juntos, y cada departamento recibe **su probabilidad de tener cochera**. Por ejemplo: "un depa como este tiene cochera con probabilidad 0.60". El modelo no busca 0.50; solo predice lo mejor posible. Se limita (profundidad 4, al menos 20 avisos por hoja, predicción fuera de fold) para que no memorice. Desempeño: AUC = 0.82.

**3. Soporte común.** Después de entrenar, *tú* revisas cada aviso. Si $m < 0.05$ o $m > 0.95$, casi todos los parecidos tienen (o no tienen) cochera: no hay gemelo del otro grupo y el aviso se descarta. Se descartó el 5 % y quedaron 1 949 (1 046 con y 903 sin cochera).

**4. Modelos 2 y 3: los dos precios de cada departamento.** Se entrenan por separado: el modelo 2 solo con departamentos *con* cochera, $g_1(X) = E[Y \mid D = 1, X]$, y el modelo 3 solo con departamentos *sin* cochera, $g_0(X) = E[Y \mid D = 0, X]$. Luego **cada departamento pasa por los dos**: se predice su precio con cochera y su precio sin cochera. Con *cross-fitting* (5 folds agrupados por edificio), cada predicción sale de un modelo que no vio ese departamento ni su edificio.

**Por qué predecir "sin cochera" a un departamento que sí la tiene**

Cada departamento tiene **dos precios posibles**, pero solo vemos uno. El otro es el *contrafactual*. El efecto es la diferencia entre ambos, así que hay que estimar el que falta.

| | Precio con cochera | Precio sin cochera |
|---|---|---|
| Depto A (sí tiene) | observado | estimado por el modelo 3 |
| Depto B (no tiene) | estimado por el modelo 2 | observado |

**5. La fórmula (score AIPW).** Para cada departamento $i$ en soporte común:

$$\phi_i = \underbrace{g_1(X_i) - g_0(X_i)}_{\text{diferencia predicha}} + \underbrace{\frac{D_i\,(Y_i - g_1(X_i))}{m(X_i)}}_{\text{corrección si tiene cochera}} - \underbrace{\frac{(1 - D_i)\,(Y_i - g_0(X_i))}{1 - m(X_i)}}_{\text{corrección si no tiene}}, \qquad \hat{\theta} = \frac{1}{n}\sum_i \phi_i.$$

- **Primer término:** lo que los modelos de precio creen que suma la cochera a ese departamento.
- **Corrección:** para la versión que sí observamos, se mira cuánto se equivocó el modelo de precio ($Y_i - g$). Si A tiene cochera, cuesta 3 000 y $g_1$ predijo 3 050, el error ($-50$) corrige su diferencia. Solo se corrige el término observado: $D_i$ o $(1 - D_i)$ apagan el otro.
- **División por $m$ o $1 - m$ (pesos).** Da a cada departamento un peso $1/m$. Si entre los departamentos de 60 m² en San Miguel solo el 20 % tiene cochera, cada uno con cochera "representa" a $1/0.20 = 5$ departamentos y cada uno sin cochera a $1/0.80 = 1.25$. Así, cada tipo de departamento pesa lo mismo en los dos grupos, *como si la cochera se hubiera asignado al azar dentro de cada tipo*. Tras ponderar, todas las diferencias estandarizadas entre grupos son menores que 0.05 (grupos comparables).
- **Promedio:** $\hat{\theta}$ es el promedio de los $\phi_i$. En porcentaje es $100\,(e^{\hat{\theta}} - 1)$.

**Por qué así: doble robustez**

Si los modelos de precio $(g_1, g_0)$ son buenos, la corrección es casi cero y manda la diferencia predicha. Si fallan, la corrección ponderada por la propensión compensa el error. Basta con que **uno de los dos** (propensión o precio) esté bien para que el promedio sea correcto. Además, la forma del score hace que los errores pequeños de los modelos de ML no contaminen el efecto (ortogonalidad).

**6. Resultado.** $\hat{\theta} = 0.0724$, es decir, **+7.5 % (IC 95 %: 3.7–11.4 %), unos S/ 199 al mes** sobre un alquiler de S/ 2 650. La diferencia bruta era del 63 %: casi todo era tamaño y zona.

**7. ¿El peso es la causalidad?** No. El peso es solo una herramienta para comparar en igualdad de condiciones. La causalidad es el promedio $\hat{\theta}$, y es causal **solo si** se cumplen los supuestos: (i) ningún factor oculto, como la calidad del edificio, influye a la vez en la cochera y el precio; (ii) hay comparables (soporte común); y (iii) la cochera está bien medida (falta la validación humana de la IA).

**En una línea**

**Modelo 1** decide a quién comparar y cuánto pesa cada uno $\rightarrow$ **modelos 2 y 3** dan el precio con y sin cochera de cada departamento $\rightarrow$ la **fórmula AIPW** corrige y promedia $\rightarrow$ +7.5 %.