[UNIVERSIDAD]
[FACULTAD]
[ESCUELA PROFESIONAL]

INFERENCIA CAUSAL ESPACIAL ASISTIDA POR INTELIGENCIA ARTIFICIAL PARA LA VALORACIÓN CONTRAFACTUAL DE ATRIBUTOS RESIDENCIALES: EL EFECTO DE UN BAÑO ADICIONAL EN EL PRECIO DE OFERTA DE ALQUILER EN LIMA METROPOLITANA

TESIS

Para optar el título profesional de [título]

Elaborada por

Luis Azaña

Asesor

[Nombre del asesor]

Lima, Perú

2026

Resumen

Esta tesis estima el efecto causal de un baño adicional sobre el precio de oferta del alquiler de departamentos en Lima Metropolitana. A diferencia de los trabajos locales previos, que predicen precios, el objetivo es separar la asociación hedónica del efecto atribuible al atributo bajo supuestos explícitos. Se auditaron 3 739 avisos obtenidos por *web scraping* en 13 distritos (marzo de 2025). Tras eliminar 243 duplicados (83 de ellos eran el mismo aviso registrado en dos distritos), 26 geocodificaciones incoherentes y valores atípicos, la muestra analítica tiene 3 028 avisos. Un grafo acíclico dirigido justifica el conjunto de ajuste: área, dormitorios, antigüedad, ubicación, días publicado y tipo de geocodificación. El estimador principal es Double Machine Learning parcialmente lineal, con *gradient boosting*, *cross-fitting* agrupado por edificio y errores estándar agrupados. La asociación sin ajustar sugiere un 45.1 % más de precio por baño. El modelo hedónico lineal la reduce a 8.4 % y Double ML a **5.3 % (IC 95 %: 1.9–8.8 %)**, unos S/ 133 mensuales sobre un alquiler de referencia de S/ 2 500. El resultado es estable ante cambios de *learner*, de depuración y de partición. Incluir controles inadmisibles (precio por m², baños por dormitorio) lo destruye, y omitir el área lo cuadruplica. No hay evidencia de heterogeneidad por clase de distrito ni por tamaño (Wald, $p > 0.6$). El análisis de sensibilidad muestra fragilidad moderada: un confusor omitido que explique el 7.5 % de la varianza residual de los baños y del precio anularía el efecto. Uno tan fuerte como la antigüedad no lo anula; uno tan fuerte como la ubicación, sí. Una validación semisintética con 600 réplicas sobre las covariables reales indica que el estimador recupera el efecto cuando no hay confusión omitida y cuantifica cuánto se sesga cuando la hay. Los resultados son causales solo de forma condicional a los supuestos y válidos para la población de avisos publicados.

Palabras clave: inferencia causal; Double Machine Learning; precios hedónicos; alquiler; análisis de sensibilidad; dependencia espacial; Lima.

Abstract

This thesis estimates the causal effect of an additional bathroom on the asking rent of apartments in Metropolitan Lima. Unlike previous local studies, which predict prices, the goal is to separate hedonic association from the effect attributable to the attribute under explicit assumptions. We audited 3,739 web-scraped listings from 13 districts (March 2025). After removing 243 duplicates (83 of them the same listing recorded under two districts), 26 inconsistent geocodes and outliers, the analytic sample contains 3,028 listings. A directed acyclic graph justifies the adjustment set: floor area, bedrooms, building age, location, days on market and geocoding type. The main estimator is a partially linear Double Machine Learning model with gradient boosting, building-grouped cross-fitting and cluster-robust standard errors. The raw association suggests 45.1 % higher rent per bathroom. A linear hedonic model reduces it to 8.4 % and Double ML to **5.3 % (95 % CI: 1.9–8.8 %)**, about PEN 133 per month for a reference rent of PEN 2,500. The estimate is stable across learners, data-cleaning choices and sample-splitting schemes. Adding inadmissible controls (price per m², bathrooms per bedroom) destroys it, and omitting floor area quadruples it. There is no evidence of heterogeneity by district class or by apartment size (Wald $p > 0.6$). Sensitivity analysis indicates moderate fragility: an omitted confounder explaining 7.5 % of the residual variance of both bathrooms and rent would nullify the effect. One as strong as building age would not; one as strong as location would. A semi-synthetic validation with 600 replications on the real covariates shows that the estimator recovers the effect when there is no omitted confounding and quantifies its bias when there is. The findings are causal only conditionally on the stated assumptions and apply to the population of published listings.

Keywords: causal inference; double machine learning; hedonic pricing; rental housing; sensitivity analysis; spatial dependence; Lima.

Índice general

Resumen I

Abstract II

1. Introducción **1**

1.1. Contexto 1

1.2. Problema 1

1.3. Pregunta de investigación 2

1.4. Objetivos 2

1.4.1. Objetivo general 2

1.4.2. Objetivos específicos 2

1.5. Hipótesis 3

1.6. Alcance y aportes 3

1.7. Organización del documento 4

2. Antecedentes y estado del arte **5**

2.1. Precios hedónicos: el baño como atributo valorado 5

2.2. Evidencia para Lima 6

2.3. Aprendizaje automático para predecir precios 6

2.4. Identificación causal en mercados de vivienda 6

2.5. Métodos de aprendizaje causal y robustez 7

2.6. Síntesis y brecha 8

3. Fundamentos y modelo causal **10**

3.1. Resultados potenciales y estimando 10

3.2. Supuestos de identificación 11

3.3. Grafo causal (DAG) . . . 11
3.4. Papel de cada variable: buenos y malos controles . . . 12
3.5. Selección, causalidad espacial y amenazas a la validez . . . 13

4. Datos y metodología **15**
4.1. Fuente de datos . . . 15
4.2. Auditoría y construcción de la muestra . . . 15
4.3. Variables . . . 16
4.4. Estimadores . . . 17
4.4.1. Línea base: asociación y modelo hedónico . . . 17
4.4.2. Double Machine Learning parcialmente lineal . . . 17
4.4.3. Inferencia agrupada . . . 18
4.4.4. Efectos por grupos (GATE) . . . 18
4.4.5. Sensibilidad a confusores omitidos . . . 18
4.4.6. Autocorrelación espacial . . . 19
4.5. Medición de atributos con IA (OE5): justificación de no ejecución . . . 19

5. Diseño experimental y validación **20**
5.1. Comparadores y métricas . . . 20
5.2. Particiones . . . 20
5.3. Grilla congelada de especificaciones . . . 21
5.4. Estrategia de sensibilidad . . . 22
5.5. Validación semisintética . . . 22

6. Resultados **24**
6.1. Población y muestra (R1) . . . 24
6.1.1. Exclusiones . . . 24
6.1.2. Perfil territorial . . . 25
6.1.3. Tratamiento . . . 26
6.2. Estimación primaria (R3) . . . 26
6.3. Grilla de especificaciones (R4) . . . 28
6.4. Robustez a confusores no observados (R5) . . . 30
6.5. Heterogeneidad preespecificada (R7) . . . 31

6.6. Dependencia espacial 32
6.7. Validación semisintética (R6) 33
6.8. Resultados desfavorables 35

7. Discusión **37**
7.1. Interpretación económica 37
7.2. Comparación con los antecedentes 37
7.3. Por qué el efecto podría estar sesgado 38
7.4. Amenazas a la validez y alcance 39
7.5. Alcance de las aplicaciones 39

8. Conclusiones y recomendaciones **40**
8.1. Respuesta a la pregunta de investigación 40
8.2. Conclusiones por objetivo específico 40
8.3. Tres tipos de afirmaciones 41
8.4. Límites del trabajo 42
8.5. Recomendaciones y continuidad 42

Referencias **43**

A. Diccionario de variables **46**

B. Registro de la búsqueda bibliográfica **47**

C. Inventario de artefactos y trazabilidad **49**

D. Versiones de software **51**

E. Tablas suplementarias **52**

Índice de tablas

2.1. Cuadro comparativo de antecedentes 9

3.1. Papel de cada variable respecto del efecto de los baños sobre el precio . 13

5.1. Grilla de especificaciones (preespecificada) 21

6.1. Flujo de exclusiones de la muestra (R1) 25

6.2. Cobertura y perfil por distrito, muestra principal (N = 3 028) 25

6.3. Efecto de un baño adicional sobre el precio de oferta (R3). EE agrupados por edificio; N = 3 028 27

6.4. Diagnóstico de los modelos auxiliares y efecto por *learner* (métricas fuera de fold) 27

6.5. Efecto estimado bajo cada especificación (R4). DML-HGB, 3 repeticiones, EE agrupados 28

6.6. Efecto corregido si existiera un confusor omitido tan fuerte como un bloque de confusores observados (R5) 30

6.7. Efectos por grupo preespecificado (GATE, R7) 32

6.8. I de Moran de los residuos (10 vecinos más cercanos, 999 permutaciones) 33

6.9. Inferencia del estimador principal según el tratamiento de la dependencia 33

6.10. Validación semisintética: sesgo, RMSE y cobertura del IC 95 % (%) por escenario y estimador (R6) 33

6.11. Calibración de la cota de sensibilidad con el confusor plantado 34

6.12. Recuperación de efectos heterogéneos (escenario E5) 35

A.1. Variables del archivo crudo y faltantes (N = 3 739) 46

B.1. Matriz de extracción resumida de los antecedentes 48

E.1. Variantes de la muestra analítica 52

E.2. Agrupamientos usados para la partición y la inferencia (muestra principal) 52
E.3. Indicadores de robustez frente a confusores no observados 52

Índice de figuras

3.1. DAG del estudio (F1). Azul: confusores ajustados; gris punteado: confusor no observado U; naranja: descendiente del resultado (no ajustar); lila: selección de publicación. 12

6.1. Distribución territorial de la muestra (F2). Izquierda: avisos por distrito; los círculos negros marcan la geocodificación aproximada. Derecha: bloques espaciales de 1 km usados como agrupamiento alternativo. . . . 26

6.2. Estimadores del efecto de un baño adicional con IC 95 % (F4). Izquierda: todos; derecha: detalle de los estimadores ajustados. 28

6.3. Sensibilidad del efecto a las decisiones de especificación, depuración y partición. 29

6.4. Contorno de sensibilidad con benchmarks (F5). Línea continua: efecto igual a cero; línea discontinua: límite inferior del IC igual a cero; estrella: valor de robustez; puntos: confusores 1× y 2× tan fuertes como los observados. 31

6.5. GATE por clase de distrito y por quintil de área (F7). Negro: IC 95 %; naranja: IC simultáneo; rojo: efecto promedio. 32

6.6. Validación semisintética (F6). Izquierda: error de estimación por escenario. Derecha: cobertura del IC 95 % del DML según el tipo de error estándar (línea roja: 95 % nominal). 34

Capítulo 1

Introducción

1.1. Contexto

El alquiler es una vía de acceso a la vivienda cada vez más importante en Lima Metropolitana. En los distritos consolidados del centro y del sur de la ciudad, la oferta de departamentos se publica sobre todo en portales inmobiliarios, donde cada aviso informa el precio pedido y un conjunto de atributos: área, número de dormitorios y de baños, antigüedad del edificio, ubicación y una descripción libre. Esa información permite estudiar con un nivel de detalle inédito cómo se forma el precio de oferta.

La literatura peruana sobre el tema ha seguido dos caminos. El primero es el enfoque hedónico clásico, que interpreta los coeficientes de una regresión del precio sobre los atributos como "precios implícitos" de cada característica (Rosen, 1974). El índice hedónico de precios de departamentos del Banco Central de Reserva del Perú encuentra, por ejemplo, que el número de cocheras y el número de baños están entre las características más valoradas en Lima (Mundaca y Sánchez, 2018). El segundo camino, más reciente, aplica aprendizaje automático para *predecir* precios de venta o de alquiler (Cacñahuaray y Jiménez, 2024; Barrientos et al., 2026). Ambos son útiles, pero ninguno responde una pregunta contrafactual: *¿cuánto cambiaría el precio de un departamento si tuviera un baño más, sin cambiar nada de lo demás?*

1.2. Problema

La respuesta a esa pregunta no se puede leer en una correlación ni en un coeficiente predictivo. Los departamentos con más baños son, en promedio, más grandes, más nuevos y están mejor ubicados; cada una de esas características también eleva el precio. En los datos de esta tesis, un baño adicional se asocia con un precio 45 % mayor cuando no se ajusta por nada, cifra que confunde el efecto del baño con el del tamaño y la zona.

Al ajustar, aparece un segundo problema: ¿por qué variables ajustar? Agregar todas las disponibles no es inocuo. Algunas, como el precio por metro cuadrado, son consecuencia del precio y destruyen la estimación; otras, como los dormitorios, se deciden junto con los baños al diseñar el plano. Y queda un tercer problema que ningún ajuste resuelve: atributos no observados, como la calidad de los acabados, el piso o la vista, pueden influir tanto en el número de baños como en el precio.

El aprendizaje automático causal, en particular *Double/Debiased Machine Learning* (Chernozhukov et al., 2018), permite ajustar por muchas variables de forma flexible sin imponer una forma funcional y conservar una inferencia válida. Pero la flexibilidad del estimador no sustituye la estrategia de identificación (Hünermund et al., 2023). La contribución de esta tesis es aplicar ese marco a un atributo residencial concreto en Lima, haciendo explícitos los supuestos, auditando los datos y midiendo cuán frágil es la conclusión.

1.3. Pregunta de investigación

> ¿En qué medida un diseño de aprendizaje causal con ajuste espacial permite estimar, dentro de la población de avisos comparables, la prima contrafactual sobre el precio de oferta de alquiler asociada a un baño adicional, y cuán estable es esa estimación frente a confusión no observada y a las decisiones de modelado?

1.4. Objetivos

1.4.1. Objetivo general

Estimar y evaluar la robustez del efecto causal de un baño adicional sobre el precio de oferta del alquiler de departamentos en Lima Metropolitana. Para ello se usan métodos de aprendizaje causal ortogonal, controles espacialmente informados e inferencia que respeta la dependencia entre avisos.

1.4.2. Objetivos específicos

OE1. Auditar, depurar y caracterizar los avisos y la selección de la muestra (procedencia, duplicados, exclusiones y perfil territorial).

OE2. Definir la intervención y justificar su identificación (estimando, DAG, conjunto de ajuste, población y amenazas no identificables).

OE3. Estimar y comparar la asociación hedónica con el ML causal (efecto principal con IC 95 %, diagnósticos de los modelos auxiliares y comparación de estimadores).

OE4. Evaluar la variación socioespacial y la sensibilidad de los resultados (efectos por grupos, grilla de especificaciones, confusión no observada y dependencia espacial).

OE5. Cuantificar el aporte de atributos medidos mediante IA a partir del texto de los avisos. *En este entregable no se ejecuta*: la sección 4.5 justifica la decisión y deja el diseño preparado.

OE6. Verificar el comportamiento del procedimiento con una verdad conocida (validación semisintética: sesgo, RMSE y cobertura).

OE7. Garantizar la trazabilidad de los resultados: cada tabla y figura indica el notebook y el archivo que la generan.

1.5. Hipótesis

Las hipótesis no exigen por anticipado un efecto significativo ni positivo:

H1. La magnitud de la asociación inicial cambia de forma mensurable tras el ajuste preespecificado.

H2. La omisión de confusores o la inclusión de controles causalmente inadecuados altera la estimación más que la elección del algoritmo de predicción.

H3. Existe heterogeneidad del efecto según el contexto territorial o el tamaño del departamento, y solo se afirmará si la precisión estadística la respalda.

H4. La solidez de la conclusión depende de la fuerza que se postule para los confusores no observados.

1.6. Alcance y aportes

Alcance. El objeto son los precios *de oferta* mensuales de departamentos publicados en un portal, no contratos firmados ni el bienestar de los hogares. La cobertura son 13 distritos de Lima Metropolitana con avisos activos en marzo de 2025. La unidad de análisis es el aviso, con un manejo explícito de los avisos repetidos y de la agrupación por edificio y por zona. Los resultados no se extrapolan al parque residencial completo ni a otros distritos.

Aportes verificables. (i) Una auditoría reproducible de la base, que documenta duplicados entre distritos y errores de geocodificación que no se habían detectado. (ii) Una estimación del efecto de un baño adicional con identificación explícita, inferencia agrupada y comparación con el enfoque hedónico. (iii) Una demostración empírica de cómo la elección de controles cambia el resultado. (iv) Un análisis de sensibilidad calibrado con confusores observados. (v) Una validación semisintética anclada en las covariables reales del mercado limeño.

Limitaciones principales. El tratamiento no se asignó al azar, por lo que la interpretación causal depende de la ausencia de confusores omitidos importantes, supuesto que solo puede acotarse. La muestra corresponde a un único corte de un portal, y la antigüedad falta en el 25 % de la muestra final. Los atributos de calidad del texto aún no se extraen (OE5).

1.7. Organización del documento

El capítulo 2 revisa la literatura. El capítulo 3 presenta el modelo causal, el estimando y el DAG. El capítulo 4 describe los datos, la auditoría y los métodos de estimación, y el capítulo 5 el diseño de las pruebas de robustez y de la validación semisintética. El capítulo 6 reporta los resultados, el 7 los discute y el 8 presenta las conclusiones por objetivo. Los anexos contienen el diccionario de variables, el registro de la búsqueda bibliográfica, el inventario de artefactos y las versiones de software.

Capítulo 2

Antecedentes y estado del arte

Este capítulo resume una revisión focalizada, no una revisión sistemática PRISMA. Las cadenas de búsqueda, las fuentes y los criterios de inclusión están en el anexo B. La revisión cubre cinco frentes: (i) la teoría hedónica y su evidencia sobre baños, (ii) los estudios del mercado limeño, (iii) el aprendizaje automático aplicado a precios de vivienda, (iv) la identificación causal en mercados inmobiliarios y (v) los métodos de ML causal, robustez y dependencia espacial que usa la tesis.

2.1. Precios hedónicos: el baño como atributo valorado

Rosen (1974) formalizó la idea de que el precio de un bien diferenciado es una función de sus atributos y de que, en equilibrio, la derivada de esa función respecto de un atributo es su precio implícito marginal. El modelo hedónico se convirtió en la herramienta estándar para índices de precios y para valorar atributos de la vivienda (Malpezzi, 2003). La revisión de Sirmans et al. (2005) sobre más de cien estudios hedónicos muestra que el número de baños es una de las características incluidas con más frecuencia y que su coeficiente suele ser positivo y significativo. También muestra que su magnitud varía mucho entre estudios según qué otras variables se controlen, en particular el área.

Ese último punto es central para esta tesis. El coeficiente hedónico es un precio implícito *condicional a la especificación*. Si el modelo omite atributos que determinan a la vez el número de baños y el precio, el coeficiente mezcla el valor del baño con el de esos atributos. Si incluye variables que son consecuencia del precio, se sesga en otra dirección. La teoría hedónica no dice qué variables incluir; esa decisión requiere un modelo causal.

2.2. Evidencia para Lima

Mundaca y Sánchez (2018) construyen un índice hedónico de precios de departamentos en venta para Lima Metropolitana con datos del BCRP y tres variantes metodológicas (variables binarias de tiempo, características e imputación). Según su resumen, el número de cocheras y el número de baños están entre las características con mayor valoración por los compradores. Es la referencia local más cercana a la pregunta de esta tesis. Sin embargo, su objetivo es construir un índice, no identificar el efecto causal de un atributo, y trabaja con precios de venta y no de alquiler.

Rivera (2018) estudia los determinantes del precio por metro cuadrado de departamentos en Lima Metropolitana entre 2005 y 2017. Al usar el precio por metro cuadrado como variable dependiente, la pregunta es distinta: en el marco causal de esta tesis, el precio por metro cuadrado es una transformación del resultado (capítulo 3).

2.3. Aprendizaje automático para predecir precios

La línea más activa en el ámbito local es la predicción. Cacñahuaray y Jiménez (2024) desarrollan un modelo predictivo de precios de alquiler de departamentos en la provincia de Lima con técnicas de aprendizaje automático. Barrientos et al. (2026) comparan un árbol de decisión y XGBoost con la regresión hedónica sobre más de 40 000 registros del BCRP (2014–2024). XGBoost obtiene el mejor desempeño, y los autores identifican el tamaño, la cochera y la ubicación como determinantes principales. En Santiago de Chile, Tapia et al. (2025) comparan modelos automáticos de valuación con ML y modelos hedónicos con ajuste espacial. Gyger et al. (2026) proponen un modelo híbrido de proceso gaussiano espacial con *tree boosting* para el modelamiento hedónico de alquileres en Alemania. Con técnicas de explicabilidad estudian los efectos no lineales de la ubicación y muestran la importancia de modelar la correlación espacial.

Estos trabajos responden a "¿cuánto costará este departamento?" y no a "¿cuánto cambiaría su precio si tuviera un baño más?". Las importancias de variables o los valores SHAP de un modelo predictivo describen cómo usa el modelo cada variable, no el efecto de intervenirla. Una variable muy importante para predecir puede no tener ningún efecto causal, y viceversa.

2.4. Identificación causal en mercados de vivienda

La economía urbana tiene una larga tradición de estimar el valor de amenidades con diseños cuasiexperimentales. Black (1999) compara viviendas a ambos lados de

las fronteras de zonas escolares para aislar el valor de la calidad educativa. Chay y Greenstone (2005) usan cambios en la calidad del aire inducidos por regulación. Keele y Titiunik (2015) formalizan las fronteras geográficas como discontinuidades de regresión. Estos diseños requieren una fuente de variación casi aleatoria del tratamiento, algo que no existe para el número de baños de un departamento.

Cuando no hay cuasiexperimento, la alternativa es el ajuste por confusores observados bajo el supuesto de ignorabilidad condicional, con un análisis de sensibilidad que acote el sesgo por confusores omitidos. Recientemente, Chen et al. (2026) compararon regresiones hedónicas y estimadores de ML causal (incluido un *causal forest* con diferencias en diferencias) mediante una simulación Monte Carlo empírica sobre más de un millón de transacciones. Encuentran que el desempeño relativo depende del escenario y del tamaño de muestra, lo que respalda validar los estimadores con datos semisintéticos antes de interpretarlos.

2.5. Métodos de aprendizaje causal y robustez

Double/Debiased ML. Chernozhukov et al. (2018) muestran que, si se estiman las funciones auxiliares $E[Y \mid X]$ y $E[T \mid X]$ con aprendizaje automático, se ortogonaliza el problema (se trabaja con residuos, como en el teorema de Frisch–Waugh–Lovell) y se usa *cross-fitting*, el parámetro de interés es consistente y asintóticamente normal aunque las funciones auxiliares converjan lentamente. El modelo parcialmente lineal que se usa aquí se remonta a Robinson (1988). Bach et al. (2022) implementan el marco en la biblioteca DoubleML.

Buenos y malos controles. Cinelli et al. (2024) sistematizan qué variables deben incluirse para identificar un efecto y cuáles lo sesgan: mediadores, colisionadores y descendientes del resultado. Hünermund et al. (2023) muestran que DML es muy sensible a la inclusión de unos pocos malos controles y que la selección automática de covariables no resuelve el problema. Ambos trabajos motivan la grilla de especificaciones de esta tesis.

Heterogeneidad. Wager y Athey (2018) y Athey et al. (2019) desarrollan los bosques causales para estimar efectos condicionales con inferencia válida. Knaus et al. (2021) evalúan estimadores de efectos heterogéneos mediante Monte Carlo empírico y muestran que su desempeño depende mucho del contexto. Por ello esta tesis prioriza efectos por grupos preespecificados (GATE) y reporta el CATE individual solo como exploración.

Sensibilidad a confusores omitidos. Cinelli y Hazlett (2020) reformulan el sesgo por variable omitida en términos de R^2 parciales e introducen el valor de robustez. Chernozhukov et al. (2022) extienden esa idea a los estimadores de ML causal y derivan cotas de sesgo para DML que se calibran con confusores observados. Esa es la herramienta principal del capítulo de robustez. Como referencia complementaria se reporta el *E-value* de VanderWeele y Ding (2017).

Dependencia espacial e inferencia. Los avisos de un mismo edificio o barrio comparten choques no observados. El índice de Moran (1950) permite detectar autocorrelación espacial en los residuos. La inferencia robusta a clusters (Cameron y Miller, 2015) corrige los errores estándar cuando las observaciones de un mismo grupo están correlacionadas.

Validación semisintética. Advani et al. (2019) advierten que las simulaciones genéricas pueden ser engañosas para elegir estimadores y recomiendan simulaciones ancladas en los datos reales (Monte Carlo empírico), como hacen Knaus et al. (2021) y Chen et al. (2026). La validación de esta tesis sigue ese principio: conserva las covariables reales y simula solo el tratamiento y el resultado.

2.6. Síntesis y brecha

La tabla 2.1 compara los antecedentes por tratamiento, estrategia de identificación y método.

Tabla 2.1: Cuadro comparativo de antecedentes

Trabajo	Objeto / datos	Identificación del efecto de un atributo	Método
Mundaca y Sánchez (2018)	Venta, Lima (BCRP)	No: precio implícito condicional a la especificación	Regresión hedónica
Rivera (2018)	Venta, Lima, 2005–2017	No: determinantes del precio/m²	Regresión
Cacñahuaray y Jiménez (2024)	Alquiler, Lima	No: predicción	ML predictivo
Barrientos et al. (2026)	Venta, Lima (BCRP)	No: predicción e importancias	Árbol, XGBoost, hedónico
Tapia et al. (2025)	Venta, Santiago	No: valuación automática	ML y hedónico espacial
Gyger et al. (2026)	Alquiler, Alemania	No: predicción explicable	GP espacial + boosting
Black (1999); Keele y Titiunik (2015)	Venta, EE. UU.	Sí: discontinuidad geográfica	RDD
Chen et al. (2026)	Venta, Nueva York	Sí: diferencias en diferencias	Hedónico vs. ML causal (Monte Carlo empírico)
Esta tesis	**Alquiler, Lima, 13 distritos**	**Sí: ajuste por DAG + sensibilidad calibrada**	**DML con inferencia agrupada y validación semisintética**

En la búsqueda realizada no se encontraron estudios sobre Lima que estimen el efecto de un atributo de la vivienda con una estrategia de identificación explícita (DAG, conjunto de ajuste justificado, análisis de sensibilidad y validación con verdad conocida). La búsqueda no fue exhaustiva, de modo que esta afirmación se limita a las fuentes consultadas (anexo B). La novedad de la tesis no es el algoritmo, sino aplicar con rigor un protocolo causal a un mercado local poco estudiado con estas herramientas y medir con honestidad su fragilidad.

Capítulo 3

Fundamentos y modelo causal

3.1. Resultados potenciales y estimando

Sea i un aviso de alquiler. Su tratamiento $T_i \in \{1, \dots, 5\}$ es el número de baños y su resultado $Y_i = \ln P_i$ el logaritmo del precio mensual de oferta. Con el lenguaje de resultados potenciales (Imbens y Rubin, 2015; Hernán y Robins, 2020), $Y_i(t)$ es el log-precio que se pediría por el departamento i si tuviera t baños y todos sus demás atributos previos (área, ubicación, antigüedad, dormitorios) se mantuvieran fijos. La intervención de interés es *agregar un baño*. Se entiende como una modificación del departamento en el plano, no como un cambio de departamento.

Dado que T es un conteo, el estimando se define dentro del modelo parcialmente lineal (Robinson, 1988):

$$Y = \theta\, T + g(X) + \varepsilon, \qquad E[\varepsilon \mid T, X] = 0, \tag{3.1}$$

$$T = m(X) + V, \qquad E[V \mid X] = 0, \tag{3.2}$$

donde X es el vector de confusores observados y g y m son funciones desconocidas y posiblemente no lineales. El parámetro θ es el cambio esperado en el log-precio por un baño adicional. En porcentaje, el efecto es $100\,(e^{\theta} - 1)$; en soles, se reporta solo para un alquiler de referencia fijado de antemano, la mediana de la muestra (S/ 2 500).

Si el efecto de un baño varía entre departamentos, θ no es el promedio simple de los efectos individuales. Es un promedio ponderado por la varianza condicional del tratamiento, $\theta = E[\mathrm{Var}(T \mid X)\,\theta(X)]/E[\mathrm{Var}(T \mid X)]$. Pesan más los tipos de departamento en los que el número de baños varía más entre unidades comparables. Esta interpretación se mantiene en todo el documento y se verifica en la validación semisintética (escenario E5).

3.2. Supuestos de identificación

θ se identifica con los datos observados bajo los supuestos siguientes. Ninguno es verificable por completo; los capítulos 5 y 6 los ponen a prueba hasta donde es posible.

1. **Ignorabilidad condicional.** $Y(t) \perp T \mid X$ para todo t: dos departamentos iguales en X difieren en número de baños por razones no relacionadas con su precio potencial. Es el supuesto más fuerte. Se viola si existe una variable omitida U (por ejemplo, la calidad de los acabados) que afecte a la vez a los baños y al precio.

2. **Consistencia y versiones del tratamiento.** "Un baño más" tiene el mismo significado entre avisos. En la práctica puede tratarse de un medio baño o de un baño completo; el portal no lo distingue, y esta heterogeneidad se absorbe en θ.

3. **Variación suficiente (positividad).** Para cada perfil X debe haber variación en el número de baños. En el modelo (3.1) esto se refleja en la varianza del residuo V: si T se predijera perfectamente desde X, no habría variación para identificar θ. El diagnóstico formal del soporte común queda fuera del alcance de este entregable (sección 8.4).

4. **Ausencia de interferencia.** El número de baños de un departamento no afecta el precio de otro. Es plausible para un atributo interno. Los choques comunes de edificio o de zona no violan este supuesto, pero inducen dependencia entre observaciones y se tratan con inferencia agrupada.

5. **Linealidad en T.** El modelo (3.1) supone que cada baño adicional tiene el mismo efecto medio en log-precio. El conteo de baños se concentra en 1–3 (97 % de la muestra), de modo que θ resume sobre todo los pasos de 1 a 2 y de 2 a 3 baños.

3.3. Grafo causal (DAG)

La figura 3.1 presenta el modelo causal supuesto. Se construyó con conocimiento del dominio y con el orden temporal de las decisiones. La ubicación del terreno y la época de construcción preceden al diseño del departamento. El área y el número de dormitorios se deciden con el plano, junto con los baños. El precio se fija al publicar el aviso.

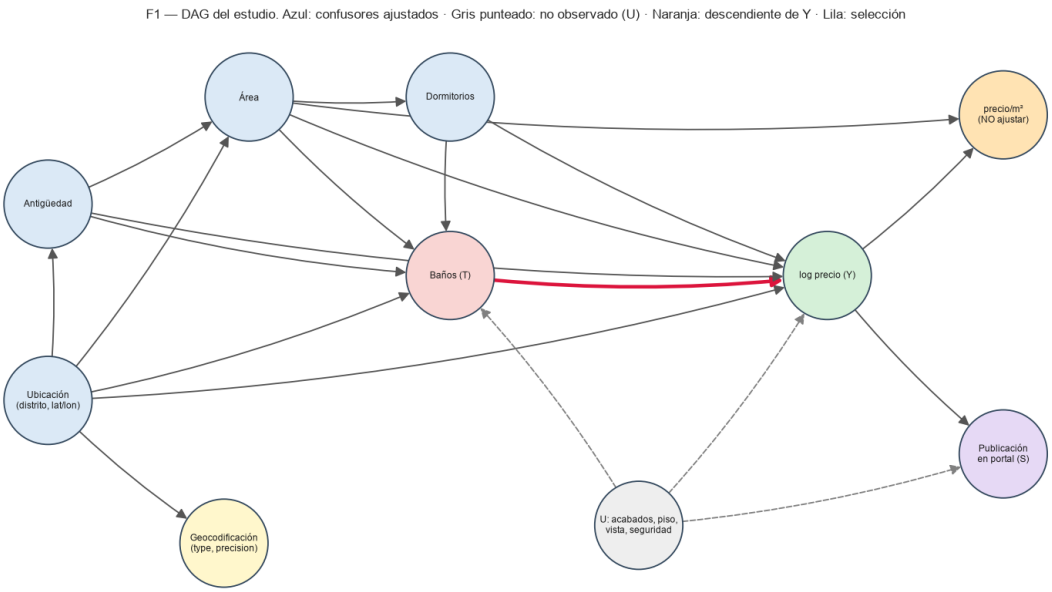


Figura 3.1: DAG del estudio (F1). Azul: confusores ajustados; gris punteado: confusor no observado U; naranja: descendiente del resultado (no ajustar); lila: selección de publicación. *Fuente:* `notebook3_estimacion_causal.ipynb`, sección 1 → `resultados/figuras/F1_dag.png`.

Según el criterio *back-door* (Pearl, 2009), para identificar el efecto $T \to Y$ basta con bloquear todos los caminos no causales entre T e Y que entran en T por la espalda. En el DAG esos caminos pasan por la ubicación, la antigüedad, el área y los dormitorios, que forman el **conjunto de ajuste principal (S1)**. Se agregan los días que lleva publicado el aviso y el tipo de lugar devuelto por el geocodificador, para absorber diferencias de antigüedad del aviso y de error de medición de la ubicación. El camino $T \leftarrow U \to Y$ no puede bloquearse con los datos disponibles; es la amenaza principal.

3.4. Papel de cada variable: buenos y malos controles

Siguiendo a Cinelli et al. (2024), la tabla 3.1 clasifica las variables disponibles. La clasificación no proviene de los datos (las tres estructuras $A \to B$, $A \leftarrow B$ y $A \leftarrow C \to B$ generan la misma correlación); es un supuesto argumentado.

Tabla 3.1: Papel de cada variable respecto del efecto de los baños sobre el precio

Variable	Papel	¿Ajustar?	Justificación
Ubicación (distrito, latitud, longitud)	Confusor	Sí	Precede al diseño; define el tipo de edificio y el precio
Área	Confusor	Sí	El tamaño condiciona cuántos baños caben y eleva el precio
Antigüedad	Confusor	Sí	La época de construcción fija estándares de diseño y afecta el precio
Dormitorios	Confusor dudoso	Sí (S1); no (S4b)	Se decide junto con los baños; si fuera parte del mismo "paquete", ajustarla bloquearía parte del efecto. Se reportan ambas especificaciones
Días publicado	Previa al precio observado	Sí	Absorbe diferencias entre avisos nuevos y antiguos
Tipo y precisión de geocodificación	Artefacto de medición	Tipo sí; precisión en S7b	No causa el precio; corrige error en la ubicación
Precio por m^2	Descendiente de Y	**No**	Es el resultado dividido por el área: ajustar por él elimina el efecto por construcción
Baños por dormitorio	Función de T	**No**	Contiene el tratamiento
Acabados, piso, vista, seguridad	Confusor no observado U	Imposible	Amenaza principal; se acota con análisis de sensibilidad
Publicación en el portal	Selección	Condicionado por diseño	Solo se observan avisos publicados; los resultados valen para esa población

3.5. Selección, causalidad espacial y amenazas a la validez

Selección de publicación. La muestra contiene solo departamentos publicados en un portal y vigentes en la fecha de captura. Si la decisión de publicar depende del precio y de la calidad no observada, el condicionamiento implícito en la selección (S en el DAG) puede inducir asociaciones entre T y U dentro de la muestra. Por eso los resultados se interpretan como válidos para la *población de avisos publicados*. No se

transportan al parque residencial ni a los precios de contrato.

Dependencia espacial. Departamentos cercanos comparten accesibilidad, entorno y la reputación del barrio, y los avisos de un mismo edificio comparten la calidad del inmueble. Estas dependencias no sesgan θ si se ajusta por la ubicación, pero hacen que los avisos no sean independientes. Ignorarlas produce intervalos demasiado estrechos. La tesis las trata en tres niveles: el *cross-fitting* se agrupa por edificio para que un mismo edificio no esté a la vez en entrenamiento y evaluación; los errores estándar se agrupan por edificio y, como alternativa, por bloques de 1 km; y la autocorrelación residual se mide con el I de Moran.

Amenazas. (i) Confusores no observados de calidad (sección 4.4.5). (ii) Error de medición en el número de baños (medios baños) y en la ubicación (geocodificación aproximada). (iii) Duplicados que inflan artificialmente la precisión. (iv) Reglas de depuración basadas en el precio, que constituyen selección por el resultado. (v) Forma funcional lineal en T. Cada una se aborda con una especificación alternativa en la grilla del capítulo 5.

Capítulo 4

Datos y metodología

4.1. Fuente de datos

Los datos provienen del *web scraping* de un portal inmobiliario peruano, realizado en marzo de 2025 sobre avisos de alquiler de departamentos en 13 distritos de Lima Metropolitana. Un *pipeline* previo geocodificó cada dirección con una API de geocodificación, que devuelve latitud, longitud, un indicador de precisión (`ROOFTOP`, `GEOMETRIC_CENTER`, `RANGE_INTERPOLATED` o `APPROXIMATE`) y el tipo de lugar encontrado. El archivo crudo tiene 3 739 avisos y 13 variables (anexo A). El precio es el precio de oferta mensual en soles; la descripción libre se usa solo para detectar duplicados. Ni la descripción ni la dirección se exportan a los archivos de análisis.

4.2. Auditoría y construcción de la muestra

La auditoría (`notebook2_auditoria.ipynb`) aplica, en orden, las reglas siguientes. Cada paso se registra con su número de exclusiones (tabla 6.1).

1. **Variables núcleo.** Se excluyen los avisos sin dormitorios, baños, área, precio o distrito. No se imputa el tratamiento, el resultado ni el área.

2. **Deduplicación.** Se identificaron dos patrones. *D1 (re-publicación)*: avisos con el mismo texto normalizado (minúsculas, sin tildes ni signos), los mismos área, dormitorios y baños, y precio a ± 10 %. La mitad de estos casos eran el mismo aviso capturado bajo dos distritos, porque el scraping buscó por distrito y el portal lo mostraba en ambos. Cuando el texto coincide pero los atributos no, se trata de una plantilla de la inmobiliaria para otra unidad y no se marca. *D2 (publicación cruzada)*: mismas coordenadas (cuatro decimales, unos 11 m), área, dormitorios, baños y precio con texto distinto, es decir, el mismo inmueble ofrecido por otro corredor. En

cada grupo se conserva el aviso más reciente. Los casos D2 son ambiguos (podrían ser dos unidades idénticas del mismo edificio), por lo que se reporta también la estimación sin deduplicar.

3. **Geocodificación incoherente (G1).** Se excluyen los avisos situados a más de 8 km de la mediana de las coordenadas de su distrito, radio que ningún distrito de la muestra supera. Un caso de San Miguel aparecía a 141 km. La regla no usa el precio.

4. **Reglas de depuración F1–F6.** Son las del análisis exploratorio previo: rangos plausibles de dormitorios, área y precio por m^2 (F1); combinaciones incoherentes de área y distribución (F2–F3); precio menor de S/ 600 (F4); combinaciones de dormitorios y baños con tres casos o menos (F5); y precio por m^2 atípico dentro de su distrito (F6, por encima de $Q_3 + 2.5\,\mathrm{RIC}$). Varias usan el precio, lo que constituye selección por el resultado. Por eso se define además un **filtro mínimo** predefinido, que solo elimina errores groseros (área 15–1 000 m^2, precio S/ 300–30 000, 1–6 dormitorios y baños), y se usa como especificación alternativa.

Unidades de dependencia. Se definen dos agrupamientos. El `edificio_id` reúne los avisos con las mismas coordenadas redondeadas a cuatro decimales; es la unidad que no se reparte entre folds y el cluster principal de los errores estándar. La `celda_1km` es un bloque espacial de unos 1×1 km, usado como agrupamiento alternativo más grueso. Las coordenadas `APPROXIMATE` son centroides de calle o de zona, de modo que reúnen muchos avisos en un solo punto. Tratarlos como un único cluster es conservador; además se reporta la estimación sin ellos.

4.3. Variables

- **Resultado** Y: logaritmo natural del precio mensual de oferta.
- **Tratamiento** T: número de baños (1–5).
- **Confusores** X **(S1)**: logaritmo del área; dormitorios; antigüedad en años, con los faltantes codificados como 0 y un indicador de faltante (así no se usa información de otras filas y no hay fuga entre folds); latitud y longitud; días publicado; distrito (12 indicadores); y tipo de lugar de geocodificación (indicadores, con las categorías de menos de 30 casos agrupadas en "otro"). Son 25 columnas en total.
- **Segmentos para heterogeneidad**: clase de distrito (clase1: Miraflores, San Isidro, Barranco y Lince; clase2: Magdalena, Surquillo, Jesús María, San Borja y Surco; cla-

se3: Cercado, San Miguel, Chorrillos y La Molina, la misma clasificación del análisis exploratorio) y quintiles de área.

4.4. Estimadores

4.4.1. Línea base: asociación y modelo hedónico

La asociación sin ajustar es la pendiente de una regresión de Y sobre T. El modelo hedónico lineal regresa Y sobre T y las 25 columnas de X por mínimos cuadrados. En ambos casos los errores estándar se agrupan por edificio.

4.4.2. Double Machine Learning parcialmente lineal

Siguiendo a Chernozhukov et al. (2018), θ en (3.1) se estima con el procedimiento siguiente.

1. Se divide la muestra en $K = 5$ folds **agrupados por edificio**: todos los avisos de un edificio caen en el mismo fold.

2. Para cada fold k, se ajustan con los otros cuatro folds dos modelos de aprendizaje automático, $\hat{\ell}(X) \approx E[Y \mid X]$ y $\hat{m}(X) \approx E[T \mid X]$, y se predicen en el fold k (*cross-fitting*).

3. Se forman los residuos fuera de fold $\tilde{Y}_i = Y_i - \hat{\ell}(X_i)$ y $\tilde{T}_i = T_i - \hat{m}(X_i)$: la parte del precio y de los baños que no explican los confusores.

4. Se estima $\hat{\theta} = \sum_i \tilde{T}_i \tilde{Y}_i / \sum_i \tilde{T}_i^2$, que resuelve el momento ortogonal $E[(\tilde{Y} - \theta\tilde{T})\tilde{T}] = 0$.

5. Se repite con 10 particiones aleatorias distintas y se reporta la mediana. El error estándar incorpora la dispersión entre particiones: $\hat{\sigma} = \sqrt{\text{mediana}_r\,(\hat{\sigma}_r^2 + (\hat{\theta}_r - \hat{\theta})^2)}$.

La ortogonalización hace que los errores de primer orden de $\hat{\ell}$ y $\hat{m}$ no contaminen $\hat{\theta}$, y el *cross-fitting* evita el sesgo por sobreajuste. El *learner* principal, fijado antes de estimar, es *histogram gradient boosting* (scikit-learn; 300 iteraciones, tasa de aprendizaje 0.05, profundidad máxima 4, mínimo de 20 observaciones por hoja y regularización L_2 igual a 1). Como comparadores se usan *gradient boosting* clásico, *random forest* y Lasso con validación cruzada. Los diagnósticos de los modelos auxiliares (R^2 y error absoluto medio) se calculan fuera de fold.

4.4.3. Inferencia agrupada

Con $\psi_i = (\tilde{Y}_i - \hat{\theta}\tilde{T}_i)\tilde{T}_i$ y $J = n^{-1}\sum_i \tilde{T}_i^2$, el error estándar agrupado (CR1) es

$$\widehat{\mathrm{EE}}(\hat{\theta}) = \frac{1}{nJ}\sqrt{\frac{G}{G-1}\sum_{g=1}^{G}\Big(\sum_{i\in g}\psi_i\Big)^2},$$

donde g indexa los clusters. El principal es el edificio ($G = 2\,178$); como alternativas se usan la celda de 1 km ($G = 183$) y la versión iid.

4.4.4. Efectos por grupos (GATE)

Para cada grupo preespecificado s (clase de distrito o quintil de área) se estima $\hat{\theta}_s = \sum_{i\in s}\tilde{T}_i\tilde{Y}_i / \sum_{i\in s}\tilde{T}_i^2$, reutilizando los residuos fuera de fold de la muestra completa. La covarianza conjunta entre grupos se calcula de forma agrupada por edificio a partir de las funciones de influencia. Así se construyen intervalos simultáneos (Bonferroni) y una prueba de Wald de igualdad de todos los θ_s.

4.4.5. Sensibilidad a confusores omitidos

Sea U un confusor omitido. Siguiendo a Chernozhukov et al. (2022), en el modelo parcialmente lineal el sesgo de $\hat{\theta}$ queda acotado por

$$|\hat{\theta} - \theta| \le \sqrt{\frac{R^2_{Y\sim U|T,X}\, R^2_{T\sim U|X}}{1 - R^2_{T\sim U|X}}}\;\frac{\sigma_\varepsilon}{\sigma_{\tilde{T}}}, \tag{4.1}$$

donde $R^2_{T\sim U|X}$ es la fracción de la varianza residual del tratamiento explicada por U y $R^2_{Y\sim U|T,X}$ la del resultado. La cota corresponde al caso más desfavorable ($\rho = 1$). A partir de ella se calculan tres cosas:

- el **valor de robustez** RV: la fuerza común $R^2_T = R^2_Y$ que llevaría $\hat{\theta}$ a cero (Cinelli y Hazlett, 2020), y RV_α, la que llevaría a cero el límite inferior del IC 95 %;
- los **benchmarks**: se re-estima el modelo omitiendo un bloque de confusores observados (área, ubicación, dormitorios o antigüedad) y se mide cuánto explicaba de la varianza residual de T y de Y. Esto permite preguntar si un U tan fuerte como el área (o el doble de fuerte) anularía el efecto;
- el **contorno de sensibilidad**: el efecto corregido en función de (R^2_T, R^2_Y).

Como referencia complementaria se reporta el *E-value* (VanderWeele y Ding, 2017), con el efecto estandarizado por la desviación estándar de Y.

4.4.6. Autocorrelación espacial

Se calcula el I de Moran (Moran, 1950) de los residuos con una matriz de pesos de 10 vecinos más cercanos, estandarizada por filas. Su significancia se evalúa con 999 permutaciones. Un I positivo y significativo en los residuos indica que avisos cercanos comparten choques no explicados y justifica la inferencia agrupada.

4.5. Medición de atributos con IA (OE5): justificación de no ejecución

El texto de los avisos contiene menciones de atributos que podrían actuar como *proxies* de la calidad no observada: vista, ascensor, piscina, amoblado o remodelado. Una inspección preliminar con expresiones regulares indica que estas menciones son frecuentes. Usar estas variables como controles exige (i) una taxonomía documentada, (ii) un etiquetado manual de 200 a 300 avisos para medir precisión y *recall*, (iii) enmascarar las menciones del propio tratamiento y del precio y (iv) justificar la posición causal de cada *proxy* en el DAG. Por decisión de alcance, este componente se difiere al siguiente entregable. La especificación S5 de la grilla queda reservada para él y el análisis de sensibilidad cubre, mientras tanto, la amenaza que estos *proxies* buscarían reducir.

Capítulo 5

Diseño experimental y validación

Este capítulo fija, antes de ver los resultados, cómo se comparan los estimadores, qué decisiones se varían para medir la robustez y cómo se valida el procedimiento con una verdad conocida. Las decisiones del protocolo están en la primera celda de `notebook3_estimacion_causal.ipynb` y no se cambiaron en función de los coeficientes obtenidos.

5.1. Comparadores y métricas

- **Comparadores del efecto**: asociación sin ajustar, modelo hedónico lineal con el conjunto S1 y DML parcialmente lineal con cuatro *learners* (HGB como principal; GBR, RF y Lasso como comparadores).
- **Métricas de los modelos auxiliares**: R^2 y error absoluto medio fuera de fold para $E[Y \mid X]$ y $E[T \mid X]$. No se usan para elegir el estimador por su coeficiente, sino para verificar que los modelos auxiliares capturan la confusión observada.
- **Métricas del efecto**: $\hat{\theta}$, error estándar agrupado por edificio, IC 95 %, efecto porcentual y escenario monetario para el alquiler de referencia.

5.2. Particiones

La partición principal es de 5 folds agrupados por edificio, repetida 10 veces. Como alternativas se usan folds agrupados por bloque espacial de 1 km, con errores estándar agrupados al mismo nivel (P1), y folds aleatorios sin agrupar, con errores estándar iid (P2). P2 corresponde a lo que haría un análisis ingenuo y permite ver si la dependencia entre avisos cambia la conclusión.

5.3. Grilla congelada de especificaciones

La tabla 5.1 lista las especificaciones. Cada una cambia *una sola* decisión respecto de S1. Las especificaciones de los grupos S2–S4 deberían mover el efecto si los confusores importan (H2); las del grupo S6 son controles inadmisibles que se incluyen solo para demostrar el sesgo que producen.

Tabla 5.1: Grilla de especificaciones (preespecificada)

Código	Especificación	Propósito
S0	Asociación sin ajustar y hedónico OLS	Cuantificar la asociación, no atribuir causalidad
S1	Conjunto de ajuste del DAG	Estimador principal
S2	S1 sin área	Confusión por tamaño
S3	S1 sin ubicación (distrito, latitud, longitud)	Confusión por localización
S4	S1 sin antigüedad	Dependencia de un confusor con faltantes
S4b	S1 sin dormitorios	Efecto "paquete" (si los dormitorios se deciden con los baños)
S5	S1 + *proxy* textual validado	Reservada para OE5 (no ejecutada)
S6a	S1 + precio por m^2	Control derivado de Y (demostración de sesgo)
S6b	S1 + baños por dormitorio	Control que contiene T (demostración de sesgo)
S7a	S1 sin tipo de geocodificación	Sensibilidad al artefacto de medición
S7b	S1 + precisión de geocodificación	Sensibilidad al artefacto de medición
D1	Sin deduplicar	Efecto de los duplicados
D2	Filtro mínimo (sin reglas de precio/m^2)	Selección por el resultado en la depuración
D3	Sin geocodificación `APPROXIMATE`	Error de medición de la ubicación
P1	Folds y EE por bloque de 1 km	Dependencia espacial más gruesa
P2	Folds aleatorios, EE iid	Inferencia que ignora la dependencia

Para ahorrar cómputo, las especificaciones de la grilla usan 3 repeticiones del *cross-*

fitting en lugar de 10. Por eso el valor de S1 en la grilla difiere levemente del estimador principal.

5.4. Estrategia de sensibilidad

La robustez a confusores no observados se evalúa con la cota (4.1). Se reportan el valor de robustez (RV y RV_α), los benchmarks con cuatro bloques de confusores observados (1× y 2× su fuerza) y el contorno de sensibilidad. Un resultado se considerará *robusto* si un confusor omitido tan fuerte como el más fuerte de los observados comparables no lo anula, y *frágil* en caso contrario. Los placebos y refutadores (tratamiento permutado, causa común aleatoria, submuestras) se aplicaron en el entregable previo y no se interpretan como prueba de ignorabilidad.

5.5. Validación semisintética

La validación (`notebook4_semisintetico.ipynb`) responde: *¿el procedimiento recupera el efecto cuando se conoce la respuesta?*

Proceso generador (DGP). Se conservan las 3 028 filas reales de X, con sus ubicaciones, edificios y bloques. Las funciones $m_0(X)$ y $g_0(X)$ se ajustan una sola vez sobre los datos reales con el mismo *learner* principal, de modo que la confusión observada tiene la forma no lineal del mercado limeño. En cada réplica se generan

$$\begin{aligned} T^* &= m_0(X) + a\,\sigma_V U + \sqrt{1-a^2}\,\sigma_V Z_T + c_T(\text{celda}),\\ T &= \text{mín}(\text{máx}(\text{round}(T^*), 1), 5),\\ Y &= g_0(X) + \theta(X)\,T + b\,\sigma_\varepsilon U + \sqrt{1-b^2}\,\sigma_\varepsilon Z_Y + c_Y(\text{celda}), \end{aligned}$$

con $U, Z_T, Z_Y \sim N(0,1)$ independientes. U es el confusor omitido y no se entrega a los estimadores. c_T y c_Y son choques comunes por bloque de 1 km, y σ_V y σ_ε las desviaciones estándar de los residuos fuera de fold de los datos reales.

Escenarios. E1: sin U y efecto homogéneo $\theta_0 = 0.05$. E2–E4: U con $a^2 = b^2 \in \{0.02, 0.07, 0.15\}$ (débil, moderado y fuerte). E5: efecto heterogéneo $\theta = 0.03$, 0.05 y 0.08 en las clases 1, 2 y 3. E6: choques espaciales con desviación igual a 0.6 veces la del ruido. En E5 el estimando verdadero del modelo parcialmente lineal es el promedio ponderado por la varianza condicional de T, calculado por Monte Carlo.

Estimadores y métricas. En cada réplica se aplican la asociación sin ajustar, el hedónico OLS y el DML principal (con una partición); en E1 se agrega el DML con el control inadmisible precio/m². Con 100 réplicas por escenario se calculan el sesgo medio, el RMSE, la cobertura del IC 95 % (iid, por edificio y por celda) y la longitud media del IC. En E2–E4 se evalúa además si la cota (4.1), calculada con la fuerza real de U en cada réplica, contiene el efecto verdadero. En E5 se evalúan la cobertura de los GATE y la potencia de la prueba de Wald.

La simulación *no* demuestra que el efecto estimado con los datos reales sea causal. Muestra en qué condiciones el procedimiento funciona y en cuáles falla.

Capítulo 6

Resultados

Todas las cifras de este capítulo provienen de las ejecuciones finales de los notebooks 2–4. Cada tabla y figura indica su archivo de origen.

6.1. Población y muestra (R1)

6.1.1. Exclusiones

De los 3 739 avisos del archivo crudo, la muestra analítica conserva 3 028 (81.0 %). La tabla 6.1 detalla las pérdidas. Las dos novedades respecto del análisis previo son la deduplicación y la geocodificación. Se marcaron 243 duplicados: 166 re-publicaciones (D1), de las cuales 83 eran el mismo aviso capturado bajo dos distritos, y 77 publicaciones cruzadas (D2). Además, 26 avisos estaban geocodificados a más de 8 km de su distrito. Sin estas correcciones, el análisis previo trabajaba con 3 276 avisos, de los cuales unos 220 eran repeticiones del mismo departamento.

Tabla 6.1: Flujo de exclusiones de la muestra (R1)

Paso	N restante	Excluidos	% del crudo
Archivo crudo del scraping	3,739	0	100
Sin dormitorios/baños/área/precio/distrito	3,516	223	94.0
Duplicados D1 (re-publicación)	3,350	166	89.6
Duplicados D2 (publicación cruzada)	3,273	77	87.5
G1 geocodificación incoherente (>8 km del distrito)	3,247	26	86.8
F1 rangos (dorm>6, área>600, precio/m2 fuera de [8,120])	3,117	130	83.4
F2 área incoherente (<=2 dorm, 1 baño, >=160 m2)	3,116	1	83.3
F4 precio < 600	3,065	51	82.0
F5 combinación dorm-baños rara (<=3 casos)	3,049	16	81.5
F6 precio/m2 atípico en su distrito	3,028	21	81.0

Fuente: `notebook2_auditoria.ipynb` → `R1_exclusiones.csv`. La regla F3 no excluyó avisos tras la deduplicación.

6.1.2. Perfil territorial

La tabla 6.2 describe la muestra por distrito. Miraflores aporta el 15.2 % de los avisos y Magdalena el 4.3 %. El precio mediano va de S/ 1 800 (Chorrillos) a S/ 3 699 (Miraflores). La calidad de la información varía mucho entre distritos. En Barranco y Miraflores la antigüedad está siempre informada y más del 90 % de las direcciones se geocodificaron con precisión `ROOFTOP`. En Cercado falta la antigüedad del 47 % de los avisos y solo el 58 % tiene precisión `ROOFTOP`. En total, la antigüedad falta en el 25.0 % de la muestra final.

Tabla 6.2: Cobertura y perfil por distrito, muestra principal (N = 3 028)

Distrito	Clase	N	% muestra	Precio med. (S/)	Área med. (m^2)	Baños prom.	% ROOFTOP	% antig. faltante
barranco	clase1	246	8.1	2,762	64	1.59	97.2	0.0
lince	clase1	218	7.2	2,300	60	1.60	63.8	40.8
miraflores	clase1	460	15.2	3,699	99	2.00	92.8	0.0
san-isidro	clase1	267	8.8	3,515	100	1.91	67.4	29.6
jesus-maria	clase2	175	5.8	2,400	72	1.81	67.4	36.0
magdalena	clase2	130	4.3	2,570	80	2.01	80.8	19.2
san-borja	clase2	265	8.8	2,800	98	1.98	62.6	39.6
surco	clase2	242	8.0	2,700	90	2.11	68.6	23.6
surquillo	clase2	205	6.8	2,250	70	1.77	61.5	36.6
cercado	clase3	206	6.8	2,000	67	1.64	57.8	46.6
chorrillos	clase3	168	5.5	1,800	70	1.69	69.6	26.8
la-molina	clase3	167	5.5	2,300	95	1.89	71.3	26.3
san-miguel	clase3	279	9.2	2,000	70	1.69	73.5	28.7

Fuente: `notebook2_auditoria.ipynb` → `R1_cobertura_distrito.csv`.

La figura 6.1 muestra la distribución espacial. Los avisos con geocodificación `APPROXIMATE` (círculos) se concentran en pocos puntos: son centroides de calle o de zona, y en conjunto forman casi todos los "edificios" de más de 20 avisos. La muestra

principal tiene 2 178 edificios (el 37 % de los avisos comparte edificio con otro) y 183 bloques de 1 km (tabla E.2 del anexo).

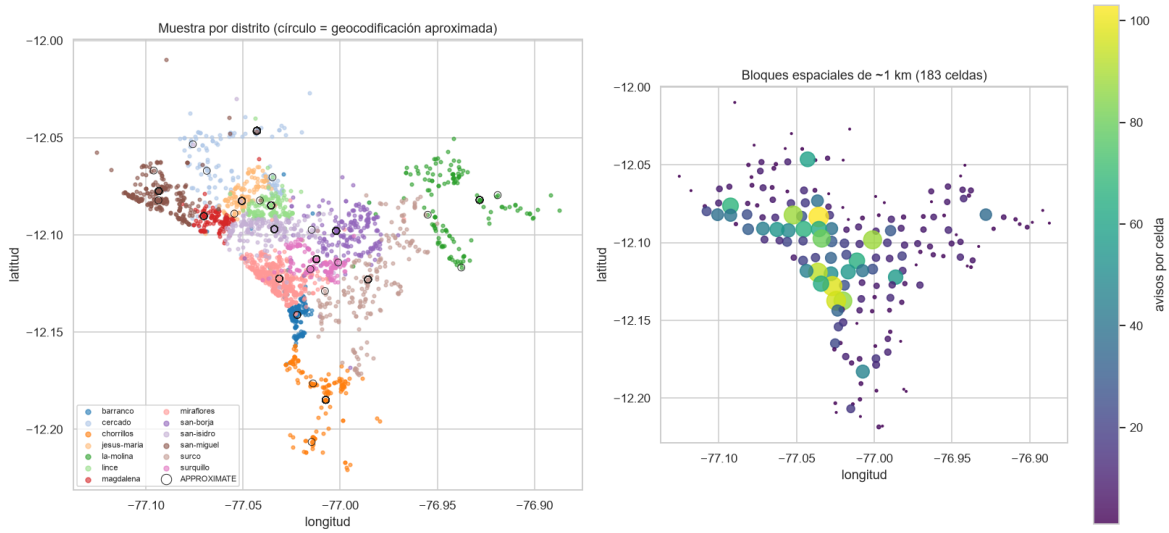


Figura 6.1: Distribución territorial de la muestra (F2). Izquierda: avisos por distrito; los círculos negros marcan la geocodificación aproximada. Derecha: bloques espaciales de 1 km usados como agrupamiento alternativo.

Fuente: `notebook2_auditoria.ipynb`, sección 6 → `F2_territorio.png`.

6.1.3. Tratamiento

El 35.2 % de los departamentos tiene un baño, el 48.9 % dos, el 13.4 % tres y el 2.5 % cuatro o cinco. Los modelos auxiliares explican el 62 % de la varianza del número de baños a partir de los confusores (tabla 6.4). Queda, por tanto, un 38 % de variación residual entre departamentos comparables, que es la fuente de identificación de θ.

6.2. Estimación primaria (R3)

La tabla 6.3 presenta el resultado central. Sin ajustar, un baño adicional se asocia con un precio 45.1 % mayor. Al ajustar linealmente por los confusores del DAG, la asociación cae a 8.4 %. Con Double ML, que permite que área, ubicación y antigüedad afecten de forma no lineal al precio y a los baños, el efecto estimado es de **5.3 %** por baño adicional (IC 95 %: 1.9–8.8 %). Para un alquiler de referencia de S/ 2 500, equivale a **unos S/ 133 mensuales** (IC: S/ 49–220).

Tabla 6.3: Efecto de un baño adicional sobre el precio de oferta (R3). EE agrupados por edificio; N = 3 028

Estimador	θ	EE	IC 95 % (θ)	% por baño	IC 95 % (%)	S/ al mes
Asociación sin ajustar (OLS)	0.3724	0.0134	[0.346, 0.399]	45.1	[41.4, 49.0]	1,128
Hedónico OLS (S1 lineal)	0.0804	0.0139	[0.053, 0.108]	8.4	[5.5, 11.4]	209
Double ML PLR (HGB, S1)	0.0518	0.0166	[0.019, 0.084]	5.3	[1.9, 8.8]	133

Fuente: `notebook3_estimacion_causal.ipynb`, sección 2 → `R3_principal.csv`. Escenario monetario: alquiler de referencia de S/ 2 500 (mediana de la muestra).

La diferencia entre el hedónico lineal (8.4 %) y el DML (5.3 %) indica que la forma funcional importa: una regresión lineal en el log del área y en las coordenadas no captura toda la confusión por tamaño y ubicación, y atribuye parte de ella a los baños. Las 10 repeticiones del *cross-fitting* dieron valores entre 0.048 y 0.058, de modo que la elección de la partición no altera la conclusión.

Modelos auxiliares. La tabla 6.4 muestra que los tres *learners* basados en árboles tienen un desempeño fuera de fold casi idéntico ($R^2 \approx 0.66$–0.68 para el precio y ≈ 0.62 para los baños) y producen efectos muy similares (5.2–5.8 %). Lasso, que solo captura relaciones lineales, ajusta peor el precio ($R^2 = 0.59$) y da un efecto mayor (8.8 %), cercano al del hedónico lineal. Esto es coherente con la lectura anterior: la confusión no lineal que Lasso no captura se filtra al coeficiente del tratamiento.

Tabla 6.4: Diagnóstico de los modelos auxiliares y efecto por *learner* (métricas fuera de fold)

Learner	R^2 E[Y|X]	MAE E[Y|X]	R^2 E[T|X]	MAE E[T|X]	θ	EE	% por baño
HGB	0.683	0.212	0.622	0.334	0.0518	0.0166	5.3
GBR	0.678	0.216	0.622	0.337	0.0510	0.0155	5.2
RF	0.663	0.219	0.626	0.319	0.0568	0.0150	5.8
Lasso	0.593	0.250	0.602	0.361	0.0847	0.0142	8.8

Fuente: `notebook3_estimacion_causal.ipynb`, sección 2 → `R3_learners.csv`. HGB: 10 repeticiones; demás: 3.

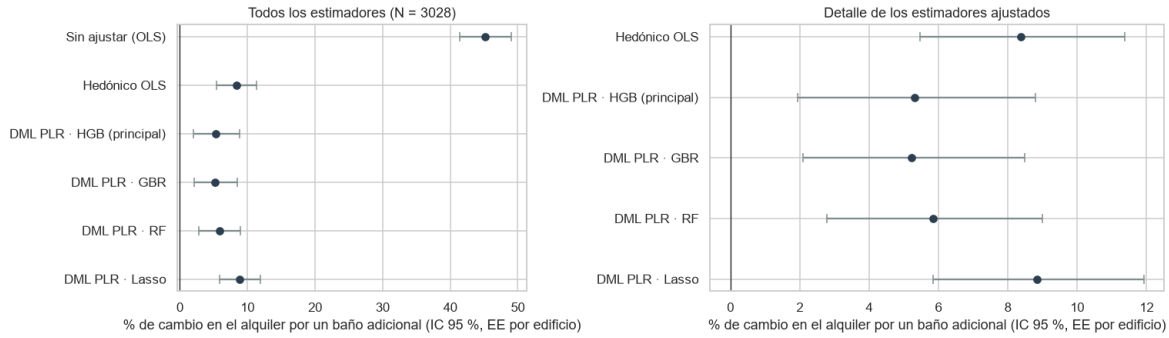


Figura 6.2: Estimadores del efecto de un baño adicional con IC 95 % (F4). Izquierda: todos; derecha: detalle de los estimadores ajustados.

Fuente: `notebook3_estimacion_causal.ipynb` → `F4_estimadores.png`.

6.3. Grilla de especificaciones (R4)

La tabla 6.5 y la figura 6.3 muestran cómo cambia el efecto al variar una decisión a la vez.

Tabla 6.5: Efecto estimado bajo cada especificación (R4). DML-HGB, 3 repeticiones, EE agrupados

Cód.	Especificación	Tipo	N	θ	EE	IC 95 %	% por baño
S1	Principal (conjunto del DAG)	válida	3,028	0.0497	0.0163	[0.018, 0.082]	5.1
S2	Sin área	omite confusor	3,028	0.1856	0.0139	[0.158, 0.213]	20.4
S3	Sin ubicación (distrito, lat, lon)	omite confusor	3,028	0.0808	0.0161	[0.049, 0.112]	8.4
S4	Sin antigüedad	omite confusor	3,028	0.0658	0.0157	[0.035, 0.097]	6.8
S4b	Sin dormitorios (efecto 'paquete')	variante del DAG	3,028	0.0526	0.0160	[0.021, 0.084]	5.4
S5	S1 + proxy textual validado	no ejecutada (OE5 diferido)	–	–	–	–	–
S6a	+ precio/m^2 (descendiente de Y)	control inadmisible	3,028	-0.0013	0.0017	[-0.005, 0.002]	-0.1
S6b	+ baños/dormitorio (función de T)	control inadmisible	3,028	-0.9151	0.6120	[-2.115, 0.284]	-60.0
S7a	Sin tipo de geocodificación	artefacto de medición	3,028	0.0473	0.0159	[0.016, 0.078]	4.8
S7b	+ precisión de geocodificación	artefacto de medición	3,028	0.0441	0.0148	[0.015, 0.073]	4.5
D1	Sin deduplicar	depuración	3,248	0.0424	0.0156	[0.012, 0.073]	4.3
D2	Filtro mínimo (sin reglas de precio/m^2)	depuración	3,243	0.0563	0.0205	[0.016, 0.096]	5.8
D3	Sin geocodificación APPROXIMATE	depuración	2,508	0.0407	0.0107	[0.020, 0.062]	4.2
P1	Folds y EE por bloque espacial de 1 km	partición	3,028	0.0553	0.0163	[0.023, 0.087]	5.7
P2	Folds aleatorios (sin agrupar), EE iid	partición	3,028	0.0467	0.0121	[0.023, 0.070]	4.8

Fuente: `notebook3_estimacion_causal.ipynb`, sección 3 → `R4_especificaciones.csv`.

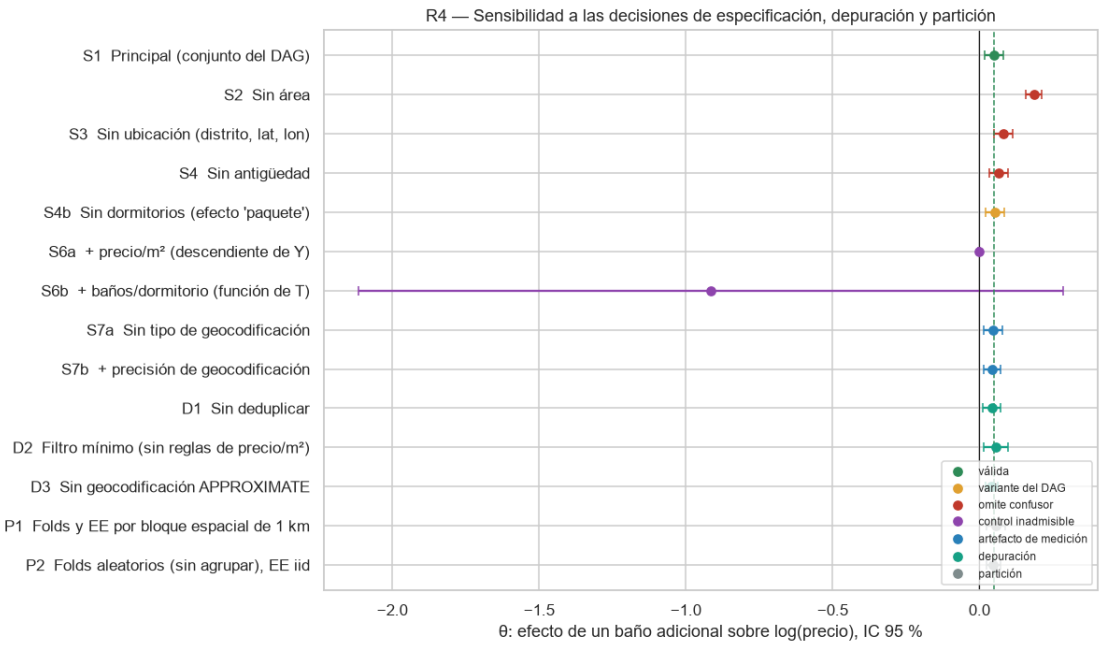


Figura 6.3: Sensibilidad del efecto a las decisiones de especificación, depuración y partición. *Fuente:* `notebook3_estimacion_causal.ipynb` → `F4b_especificaciones.png`.

Se distinguen tres patrones:

1. **Omitir confusores sesga hacia arriba.** Sin el área (S2), el efecto se cuadruplica hasta 20.4 %: los baños pasan a capturar el valor del tamaño. Sin la ubicación (S3), sube a 8.4 %, y sin la antigüedad (S4), a 6.8 %. El orden coincide con la fuerza de cada confusor medida en la sección de sensibilidad.

2. **Los controles inadmisibles destruyen la estimación.** Al incluir el precio por m² (S6a), el efecto colapsa a −0.1 %: como el precio por m² es el precio dividido por el área, condicionar en él y en el área equivale a condicionar en el propio resultado. Con baños por dormitorio (S6b), que contiene el tratamiento, la estimación se vuelve inestable ($\hat{\theta} = -0.92$ con un IC de más de dos unidades).

3. **Las decisiones defendibles no cambian la conclusión.** Excluir los dormitorios (S4b: 5.4 %), cambiar el tratamiento de la geocodificación (S7a, S7b: 4.5–4.8 %), no deduplicar (D1: 4.3 %), usar el filtro mínimo sin reglas de precio (D2: 5.8 %), excluir las coordenadas aproximadas (D3: 4.2 %) o cambiar la partición (P1, P2: 4.8–5.7 %) producen efectos entre 4.2 y 5.8 %, todos con IC que excluyen el cero.

Que S4b sea casi igual a S1 indica que, condicionando en el área, los dormitorios apenas explican el precio. Su papel como posible parte del "paquete" no cambia la conclusión. La especificación sin deduplicar da un efecto algo menor y un IC más estrecho: los duplicados aportan precisión ficticia, porque cuentan dos veces la misma información.

6.4. Robustez a confusores no observados (R5)

El valor de robustez es RV = 0.075: un confusor omitido que explicara el 7.5 % de la varianza residual del número de baños y el 7.5 % de la varianza residual del log-precio bastaría para llevar el efecto a cero. Para que el IC deje de excluir el cero basta un confusor con $\mathrm{RV}_\alpha = 0.029$. El *E-value* es 1.40.

Tabla 6.6: Efecto corregido si existiera un confusor omitido tan fuerte como un bloque de confusores observados (R5)

Escenario de confusor omitido	R^2 con T	R^2 con Y	θ ajustado	IC inf. ajustado	% ajustado
Estimación DML principal	–	–	0.0518	0.0193	5.3
U 1× tan fuerte como área	0.128	0.269	-0.0796	-0.1122	-7.7
U 2× tan fuerte como área	0.256	0.537	-0.2328	-0.2653	-20.8
U 1× tan fuerte como ubicación	0.010	0.168	0.0247	-0.0078	2.5
U 2× tan fuerte como ubicación	0.020	0.335	-0.0026	-0.0351	-0.3
U 1× tan fuerte como dormitorios	0.190	0.000	0.0518	0.0193	5.3
U 2× tan fuerte como dormitorios	0.379	0.000	0.0518	0.0193	5.3
U 1× tan fuerte como antigüedad	0.020	0.031	0.0351	0.0026	3.6
U 2× tan fuerte como antigüedad	0.040	0.062	0.0181	-0.0144	1.8

Fuente: `notebook3_estimacion_causal.ipynb`, sección 4 → `R5_sensibilidad.csv`. Cota con $\rho = 1$ (caso más desfavorable).

¿Es plausible un confusor de esa fuerza? La tabla 6.6 y la figura 6.4 lo comparan con los confusores observados:

- Un U **tan fuerte como la antigüedad** reduciría el efecto a 3.6 % y el IC seguiría excluyendo el cero. Con el doble de fuerza, el efecto puntual se mantendría positivo (1.8 %), pero el IC incluiría el cero.
- Un U **tan fuerte como la ubicación**, que explica poco de los baños (1 %) pero mucho del precio (17 %), reduciría el efecto a 2.5 % y el IC incluiría el cero.
- Un U **tan fuerte como el área**, el confusor más fuerte (13 % de los baños y 27 % del precio), invertiría el signo.
- Los dormitorios explican mucho de los baños pero nada del precio residual, de modo que un confusor como ellos no sesgaría el resultado.

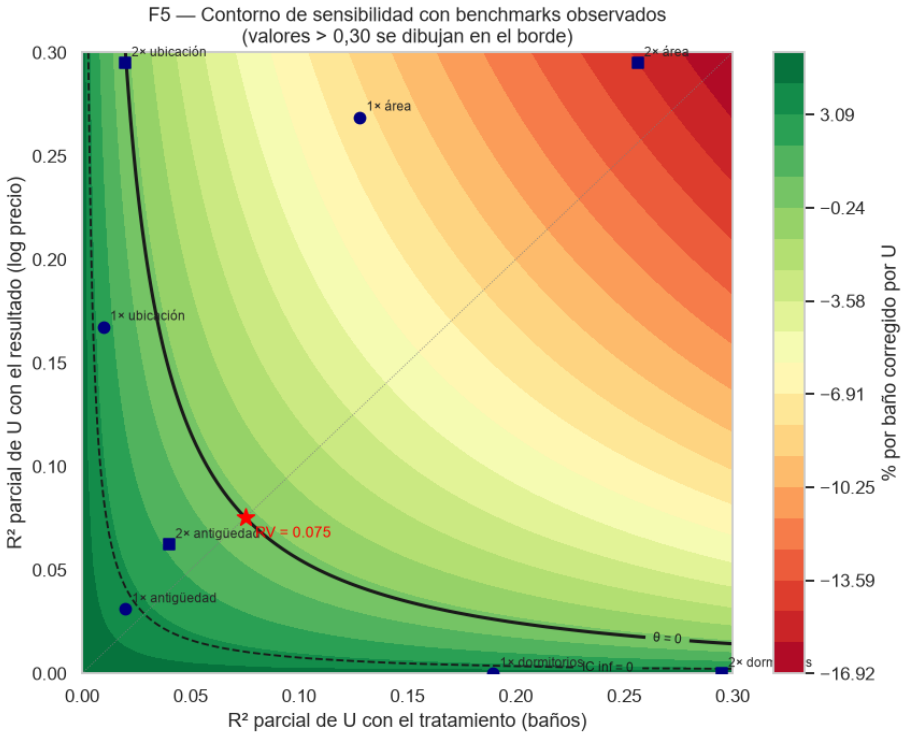


Figura 6.4: Contorno de sensibilidad con benchmarks (F5). Línea continua: efecto igual a cero; línea discontinua: límite inferior del IC igual a cero; estrella: valor de robustez; puntos: confusores 1× y 2× tan fuertes como los observados.

Fuente: `notebook3_estimacion_causal.ipynb`, sección 4 → `F5_sensibilidad.png`.

La pregunta sustantiva es si la calidad de los acabados, el piso o la vista pesan, una vez descontados área, ubicación, antigüedad y dormitorios, tanto como la antigüedad o tanto como la ubicación. Es plausible que la calidad de los acabados explique una fracción del precio residual comparable a la de la ubicación. En cambio, es menos claro que explique mucho del número de baños una vez fijado el área. El resultado es, por tanto, **moderadamente frágil**: sobrevive a confusores de la fuerza de la antigüedad, pero no a uno de la fuerza de la ubicación.

6.5. Heterogeneidad preespecificada (R7)

La tabla 6.7 y la figura 6.5 presentan los GATE. Por clase de distrito, el efecto puntual es mayor en la clase1 (7.8 %) que en la clase2 (3.9 %) y la clase3 (4.6 %). Las diferencias no son estadísticamente significativas (Wald $\chi^2_2 = 0.95$, $p = 0.62$) y los IC simultáneos se superponen ampliamente. Por quintil de área, los efectos van de 4.0 % a 9.2 %, sin un patrón monótono y también sin diferencias significativas (Wald $\chi^2_4 = 2.47$, $p = 0.65$).

Tabla 6.7: Efectos por grupo preespecificado (GATE, R7)

Segmentación	Grupo	n	θ_g	EE	IC 95 %	IC simultáneo	% por baño	p Wald
clase de distrito	clase1	1,191	0.0749	0.0298	[0.017, 0.133]	[0.004, 0.146]	7.8	0.623
clase de distrito	clase2	1,017	0.0380	0.0273	[-0.016, 0.092]	[-0.027, 0.103]	3.9	0.623
clase de distrito	clase3	820	0.0446	0.0232	[-0.001, 0.090]	[-0.011, 0.100]	4.6	0.623
quintil de área	Q1 (15-53 m2)	617	0.0628	0.0391	[-0.014, 0.139]	[-0.038, 0.163]	6.5	0.649
quintil de área	Q2 (54-70 m2)	684	0.0879	0.0318	[0.026, 0.150]	[0.006, 0.170]	9.2	0.649
quintil de área	Q3 (70-88 m2)	533	0.0563	0.0353	[-0.013, 0.126]	[-0.035, 0.147]	5.8	0.649
quintil de área	Q4 (89-119 m2)	588	0.0393	0.0231	[-0.006, 0.085]	[-0.020, 0.099]	4.0	0.649
quintil de área	Q5 (120-570 m2)	606	0.0445	0.0301	[-0.014, 0.104]	[-0.033, 0.122]	4.6	0.649

Fuente: `notebook3_estimacion_causal.ipynb`, sección 5 → `R7_gate.csv`. IC simultáneo de Bonferroni; EE agrupados por edificio.

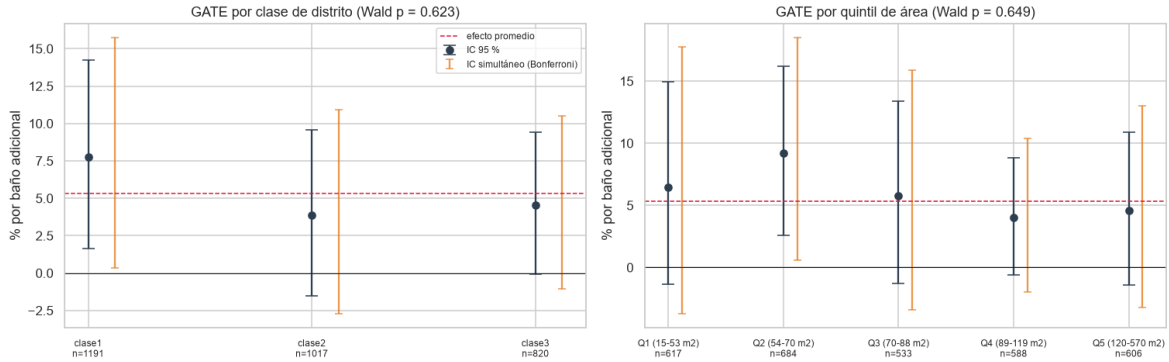


Figura 6.5: GATE por clase de distrito y por quintil de área (F7). Negro: IC 95 %; naranja: IC simultáneo; rojo: efecto promedio.

Fuente: `notebook3_estimacion_causal.ipynb`, sección 5 → `F7_heterogeneidad.png`.

Con esta precisión, los datos no permiten afirmar que el valor de un baño adicional difiera entre zonas o tamaños. La hipótesis H3 queda sin respaldo. No es evidencia de homogeneidad: los IC por grupo son amplios (de unos ±6 puntos porcentuales) y no descartarían diferencias moderadas.

6.6. Dependencia espacial

Los residuos del precio presentan autocorrelación espacial positiva y significativa (I de Moran = 0.061, $p = 0.001$), mientras que los del número de baños no ($I = 0.004$, $p = 0.30$) (tabla 6.8). Avisos cercanos comparten choques de precio no explicados por los confusores, como el entorno inmediato o la calidad del edificio. Como esa dependencia afecta al residuo final, la inferencia iid subestima la incertidumbre. El error estándar agrupado por edificio es un 31 % mayor que el iid, y el agrupado por bloque de 1 km un 39 % mayor (tabla 6.9). Con cualquiera de ellos, el IC del efecto sigue excluyendo el cero.

Tabla 6.8: I de Moran de los residuos (10 vecinos más cercanos, 999 permutaciones)

Serie	I de Moran	E[I] (permutación)	p-valor
Residuo de log precio | X	0.0608	-0.0006	0.001
Residuo de baños | X	0.0037	-0.0002	0.296
Residuo final	0.0587	-0.0006	0.001

Fuente: `notebook3_estimacion_causal.ipynb`, sección 6 → `E7_moran.csv`.

Tabla 6.9: Inferencia del estimador principal según el tratamiento de la dependencia

Inferencia	EE	IC inf.	IC sup.	Razón vs iid
iid (ignora dependencia)	0.0126	0.0270	0.0765	1.00
cluster por edificio (principal)	0.0166	0.0193	0.0843	1.31
cluster por bloque de 1 km	0.0176	0.0173	0.0862	1.39

Fuente: `notebook3_estimacion_causal.ipynb`, sección 6 → `E7_inferencia.csv`.

6.7. Validación semisintética (R6)

La tabla 6.10 y la figura 6.6 resumen las 600 réplicas (100 por escenario) del diseño de la sección 5.5.

Tabla 6.10: Validación semisintética: sesgo, RMSE y cobertura del IC 95 % (%) por escenario y estimador (R6)

Escenario	Estimador	θ verdadero	Sesgo	RMSE	Cob. iid	Cob. edificio	Cob. celda	Long. IC
E1	OLS sin ajustar	0.0500	0.2867	0.2869	–	0	–	0.054
E1	Hedónico OLS (S1)	0.0500	0.0251	0.0279	–	50	–	0.049
E1	DML PLR (S1)	0.0500	-0.0013	0.0125	95	95	94	0.047
E1	DML + precio/m^2 (inadmisible)	0.0500	-0.0500	0.0500	0	0	–	0.006
E2	OLS sin ajustar	0.0500	0.2917	0.2919	–	0	–	0.054
E2	Hedónico OLS (S1)	0.0500	0.0351	0.0375	–	24	–	0.049
E2	DML PLR (S1)	0.0500	0.0094	0.0162	83	84	85	0.047
E3	OLS sin ajustar	0.0500	0.3036	0.3038	–	0	–	0.053
E3	Hedónico OLS (S1)	0.0500	0.0580	0.0595	–	1	–	0.049
E3	DML PLR (S1)	0.0500	0.0333	0.0359	22	22	23	0.047
E4	OLS sin ajustar	0.0500	0.3230	0.3232	–	0	–	0.052
E4	Hedónico OLS (S1)	0.0500	0.0956	0.0965	–	0	–	0.049
E4	DML PLR (S1)	0.0500	0.0730	0.0743	0	0	0	0.047
E5	OLS sin ajustar	0.0503	0.2822	0.2824	–	0	–	0.052
E5	Hedónico OLS (S1)	0.0503	0.0247	0.0276	–	51	–	0.050
E5	DML PLR (S1)	0.0503	-0.0007	0.0125	96	95	95	0.047
E6	OLS sin ajustar	0.0500	0.2611	0.2618	–	0	–	0.064
E6	Hedónico OLS (S1)	0.0500	0.0214	0.0276	–	64	–	0.053
E6	DML PLR (S1)	0.0500	-0.0026	0.0181	81	88	94	0.056

Fuente: `notebook4_semisintetico.ipynb` → `R6_simulacion.csv`. 100 réplicas por escenario; N = 3 028 por réplica. En E5 el estimando verdadero es 0.0503.

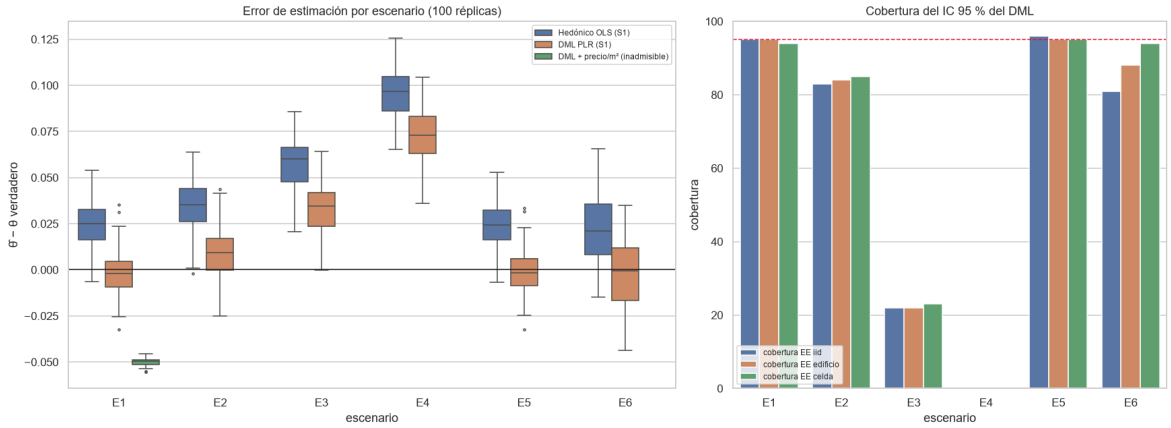


Figura 6.6: Validación semisintética (F6). Izquierda: error de estimación por escenario. Derecha: cobertura del IC 95 % del DML según el tipo de error estándar (línea roja: 95 % nominal).

Fuente: `notebook4_semisintetico.ipynb` → `F6_semisintetico.png`.

Sin confusión omitida, DML recupera el efecto (E1). El DML tiene un sesgo prácticamente nulo (−0.001), un RMSE de 0.013 y una cobertura del 95 %, igual a la nominal. El hedónico OLS, en cambio, sobreestima el efecto en 0.025 (la mitad del efecto verdadero) y su IC cubre la verdad solo en el 50 % de las réplicas, *aunque no hay ningún confusor omitido*. La razón es que la confusión observada es no lineal y la regresión lineal no la absorbe. Este resultado replica en un entorno controlado el patrón de los datos reales (8.4 % del hedónico frente a 5.3 % del DML) y respalda que esa diferencia se deba a la forma funcional. Agregar el control inadmisible precio/m² lleva el efecto a cero en todas las réplicas, con una cobertura del 0 %.

Con confusión omitida, DML se sesga y el IC no lo advierte (E2–E4). Cuando existe un U que afecta a los baños y al precio, el DML hereda un sesgo creciente con su fuerza: 0.009 (débil), 0.033 (moderado) y 0.073 (fuerte). La cobertura cae a 84 %, 22 % y 0 %. Es la demostración empírica de que ningún estimador, por flexible que sea, corrige la confusión no observada.

Tabla 6.11: Calibración de la cota de sensibilidad con el confusor plantado

Escenario	R^2 real U-T	R^2 real U-Y	Sesgo medio DML	Cota media	% cubre IC	% cubre IC + cota
E2	0.012	0.018	0.0094	0.0096	84	96
E3	0.042	0.060	0.0333	0.0331	22	96
E4	0.089	0.121	0.0730	0.0707	0	92

Fuente: `notebook4_semisintetico.ipynb` → `R6_sensibilidad_calibracion.csv`.

La cota de sensibilidad funciona (E2–E4). La tabla 6.11 evalúa, en cada réplica, la cota (4.1) con la fuerza *real* de U. La cota media (0.010, 0.033 y 0.071) coincide casi

exactamente con el sesgo medio del DML (0.009, 0.033 y 0.073). El intervalo ampliado con la cota contiene el efecto verdadero en el 96 %, 96 % y 92 % de las réplicas, frente al 84 %, 22 % y 0 % del IC estándar. La herramienta usada en la sección R5 es, por tanto, informativa en este mercado: si se conociera la fuerza del confusor omitido, la cota corregiría el sesgo. Cabe notar que, por el redondeo del número de baños, la fuerza realizada de U es menor que la planteada ($R^2 \approx 0.01$–0.09 con T).

Tabla 6.12: Recuperación de efectos heterogéneos (escenario E5)

Grupo	θ verdadero	Media GATE	Sesgo	RMSE	Cobertura IC 95 %	Potencia Wald (%)
clase1	0.030	0.034	0.004	0.020	96	24
clase2	0.050	0.045	-0.005	0.021	94	24
clase3	0.080	0.077	-0.003	0.025	91	24

Fuente: `notebook4_semisintetico.ipynb` → `R6_gate.csv`.

Heterogeneidad: los GATE son insesgados, pero con baja potencia (E5). Con efectos verdaderos de 0.03, 0.05 y 0.08 por clase, los GATE estimados tienen sesgos de menos de 0.005 y coberturas de 91–96 % (tabla 6.12). El efecto promedio se recupera sin sesgo (0.050 frente a un estimando de 0.0503). Sin embargo, la prueba de Wald detecta las diferencias solo en el 24 % de las réplicas, *a pesar de que el efecto de la clase3 es casi el triple del de la clase1*. Con este tamaño de muestra, la ausencia de heterogeneidad significativa en los datos reales (sección R7) es poco informativa: el diseño no tiene potencia para detectar diferencias de esa magnitud.

Dependencia espacial: la inferencia debe agruparse al nivel de la dependencia (E6). Con choques comunes por bloque de 1 km, el DML sigue siendo insesgado (-0.003), pero la cobertura del IC iid cae al 81 %. El IC agrupado por edificio llega al 88 % y el agrupado por bloque al 94 %, cercano al nominal. La inferencia corrige la subcobertura solo si se agrupa al nivel en que realmente opera la dependencia. En los datos reales, el error estándar por bloque de 1 km es un 6 % mayor que el agrupado por edificio, y ambos IC excluyen el cero.

6.8. Resultados desfavorables

Por transparencia, se resumen los hallazgos que limitan la conclusión: (i) la fragilidad moderada frente a confusores del tamaño de la ubicación; (ii) la ausencia de evidencia de heterogeneidad, que impide recomendaciones diferenciadas por zona; (iii) la autocorrelación espacial residual, que indica variables de entorno no capturadas; y (iv) la pérdida de información de antigüedad en un cuarto de la muestra, concentrada

en algunos distritos.

Capítulo 7

Discusión

7.1. Interpretación económica

La estimación principal indica que, entre departamentos publicados con igual área, dormitorios, antigüedad y ubicación, uno con un baño adicional se ofrece en promedio un 5.3 % más caro. Para un alquiler mediano de S/ 2 500 son unos S/ 133 al mes, con un intervalo de S/ 49 a S/ 220. Es una prima apreciable, pero muy lejana del 45 % que sugiere la comparación directa. Alrededor del 86 % de la diferencia bruta (en log-precio) de precio entre departamentos con distinto número de baños se explica por que los que tienen más baños son más grandes, más nuevos o están mejor ubicados.

Esta magnitud debe leerse con tres cautelas. Primero, es una prima sobre el precio *de oferta*: no informa cuánto se paga finalmente ni cuánto tarda en alquilarse el departamento. Segundo, es un promedio ponderado: refleja sobre todo los pasos de uno a dos y de dos a tres baños, donde se concentra la variación, y no debería extrapolarse a departamentos con cuatro o cinco. Tercero, no es una recomendación de inversión. El efecto sobre el precio pedido no dice si construir un baño adicional es rentable, porque no considera su costo ni el área que resta a otros ambientes. Como el área se mantiene fija, el contrafactual es "el mismo departamento redistribuido con un baño más", no "el mismo departamento ampliado".

7.2. Comparación con los antecedentes

El resultado es coherente con la evidencia hedónica local. Mundaca y Sánchez (2018) encuentran que el número de baños está entre las características más valoradas en el mercado de venta de Lima. Esta tesis agrega que, en el mercado de alquiler, una parte de esa valoración sobrevive a un ajuste flexible por los confusores observados y a una auditoría de los datos. Agrega también que su tamaño causal es menor que el

sugerido por una regresión hedónica lineal. Esa diferencia, de 8.4 % a 5.3 %, no es un artefacto de esta muestra: la validación semisintética muestra que, con la estructura de covariables del mercado limeño, el hedónico lineal sobreestima el efecto incluso sin confusores omitidos, porque no absorbe la confusión no lineal por tamaño y ubicación. Es una advertencia práctica para los estudios que interpretan coeficientes hedónicos como precios implícitos.

La comparación con los trabajos predictivos (Cacñahuaray y Jiménez, 2024; Barrientos et al., 2026) es de naturaleza distinta. Esos modelos buscan predecir bien, y para ello les conviene incluir cualquier variable correlacionada con el precio. La grilla de especificaciones muestra por qué eso no sirve para inferencia causal: agregar el precio por m^2, una variable excelente para predecir, anula el efecto, y agregar baños por dormitorio lo vuelve errático. El resultado coincide con la advertencia de Hünermund et al. (2023): la flexibilidad del DML no protege contra malos controles, y la selección de covariables debe venir del modelo causal.

En cuanto a la heterogeneidad, los resultados recomiendan prudencia. El efecto puntual en los distritos de mayor precio (clase1) es casi el doble que en los demás, pero la diferencia no es significativa. La simulación muestra además que, con este tamaño de muestra, una diferencia real de esa magnitud se detectaría solo una de cada cuatro veces. Esto concuerda con Knaus et al. (2021): en muestras moderadas, los efectos heterogéneos son difíciles de distinguir del ruido.

7.3. Por qué el efecto podría estar sesgado

El análisis de sensibilidad da la medida de la fragilidad. Para anular el efecto, un confusor omitido tendría que explicar a la vez el 7.5 % de la variación residual del número de baños y del precio, una vez descontados área, ubicación, antigüedad y dormitorios. El candidato natural es la calidad de la construcción y los acabados: edificios de mayor estándar tienden a tener más baños por departamento y a cobrar más. La evidencia no permite descartar un confusor así. Uno tan fuerte como la antigüedad no anularía el efecto, pero uno con la influencia de la ubicación sobre el precio sí haría que el IC incluyera el cero. La validación semisintética confirma que la cota de sensibilidad es fiel cuando se conoce la fuerza del confusor, así que el problema no es la herramienta, sino que esa fuerza es desconocida.

Dos elementos atenúan esta preocupación. Primero, el confusor tendría que estar correlacionado con el número de baños *dentro* de departamentos de igual área, dormitorios, antigüedad y ubicación, lo que excluye la parte de la calidad que ya se refleja en esas variables. Segundo, la especificación que excluye las coordenadas aproximadas, que es la de mejor medición de la ubicación, da un efecto de 4.2 %, cercano al principal.

Aun así, la conclusión prudente es que el efecto es *positivo bajo los supuestos del DAG* y que su magnitud podría estar sobreestimada si la calidad no observada está asociada al número de baños.

7.4. Amenazas a la validez y alcance

Validez interna. Además de los confusores no observados, persisten el error de medición del tratamiento (el portal no distingue medios baños), la antigüedad faltante en un cuarto de la muestra y la autocorrelación espacial residual del precio, que señala factores de entorno no capturados. Esta última no sesga el efecto, en la medida en que no esté relacionada con el número de baños (los residuos del tratamiento no muestran autocorrelación). Sí obliga a usar inferencia agrupada.

Validez externa. La población es la de los avisos de un portal en 13 distritos durante un mes. No se observan los departamentos que se alquilan sin publicarse, los de otros portales ni los de distritos periféricos. Tampoco se sabe si la prima de oferta se traslada al precio de contrato.

Validez de la medición. La deduplicación es heurística. Los casos D2, misma ubicación y mismos atributos con texto distinto, podrían ser unidades idénticas de un mismo edificio. La especificación sin deduplicar da un efecto similar (4.3 %), de modo que la conclusión no depende de esa decisión.

7.5. Alcance de las aplicaciones

El resultado sirve como referencia cuantitativa, con su incertidumbre y su fragilidad declaradas, para la tasación de alquileres y para entender cómo el mercado valora la distribución interna de un departamento. No justifica afirmar que agregar un baño a un departamento existente aumentará su renta en un 5.3 %, porque esa intervención física implica costos y cambios no representados en los datos. Tampoco autoriza recomendaciones diferenciadas por distrito.

Capítulo 8

Conclusiones y recomendaciones

8.1. Respuesta a la pregunta de investigación

Dentro de la población de avisos de alquiler publicados en 13 distritos de Lima Metropolitana, y bajo el supuesto de que área, dormitorios, antigüedad y ubicación capturan los factores que determinan a la vez el número de baños y el precio, **un baño adicional eleva el precio de oferta en un 5.3 % (IC 95 %: 1.9–8.8 %)**, unos S/ 133 mensuales sobre un alquiler de S/ 2 500. La estimación es estable ante cambios de algoritmo, de depuración de datos y de partición de la muestra, y sensible a los errores de especificación que el modelo causal advierte. Su fragilidad es moderada: un factor no observado con una influencia comparable a la de la ubicación sobre el precio bastaría para que el efecto dejara de ser distinguible de cero.

8.2. Conclusiones por objetivo específico

OE1 (auditoría). De 3 739 avisos se obtuvo una muestra de 3 028, con cada exclusión documentada. La auditoría reveló 243 duplicados (83 de ellos, el mismo aviso registrado bajo dos distritos) y 26 errores de geocodificación que el análisis previo no detectaba. Los resultados son válidos para avisos publicados de 13 distritos en marzo de 2025.

OE2 (identificación). El estimando es el coeficiente θ del modelo parcialmente lineal, interpretado como el efecto promedio, ponderado por la varianza condicional, de un baño adicional. Se identifica por el criterio *back-door* con el conjunto de ajuste del DAG. Se defiende con el orden temporal de las decisiones de diseño y queda limitado por la calidad no observada y por la selección de publicación.

OE3 (estimación). La asociación sin ajustar (45.1 %) se reduce a 8.4 % con el hedónico lineal y a 5.3 % con DML. Los modelos auxiliares explican el 68 % de la varianza del log-precio y el 62 % de la del número de baños fuera de fold, y los tres *learners* basados en árboles coinciden. **H1 se confirma.**

OE4 (variación y sensibilidad). Omitir el área cuadruplica el efecto, y los controles inadmisibles lo anulan o lo vuelven errático, mientras que las alternativas defendibles lo mantienen entre 4.2 y 5.8 %. **H2 se confirma**: la composición causal de los controles importa mucho más que el algoritmo. No hay evidencia de heterogeneidad por clase de distrito ni por tamaño ($p > 0.6$), pero el diseño tiene baja potencia para detectarla. **H3 no se respalda**, y el resultado debe leerse como no concluyente, no como evidencia de homogeneidad. El valor de robustez es 0.075, y la conclusión cambia ante un confusor tan fuerte como la ubicación pero no ante uno tan fuerte como la antigüedad. **H4 se confirma.** Los residuos del precio presentan autocorrelación espacial (I de Moran = 0.061), que se trata con inferencia agrupada.

OE5 (medición con IA). No se ejecutó en este entregable. La sección 4.5 justifica la decisión y describe el diseño. La especificación S5 queda reservada.

OE6 (validación semisintética). Con las covariables reales y un efecto conocido, el DML es insesgado y tiene una cobertura del 95 % cuando no hay confusión omitida. El hedónico lineal, en cambio, se sesga y cubre solo el 50 %. Con confusión omitida, el DML se sesga en proporción a su fuerza, y la cota de sensibilidad recupera la cobertura (92–96 %). Con dependencia espacial, la cobertura solo se aproxima al 95 % si se agrupa al nivel de la dependencia. Los GATE son insesgados, pero la prueba de heterogeneidad tiene una potencia del 24 %.

OE7 (trazabilidad). Cada tabla y figura indica el notebook y el archivo que la generan, y las semillas están fijadas. La ejecución con un único comando y la estructura definitiva del repositorio quedan pendientes (anexo C).

8.3. Tres tipos de afirmaciones

Hallazgos observacionales (sin supuestos causales). En la muestra, los departamentos con un baño más se ofrecen un 45 % más caros. Los avisos con un baño más son también más grandes, más nuevos y están mejor ubicados. Los residuos del precio están espacialmente autocorrelacionados. El 6.9 % de los avisos con datos completos eran duplicados.

Conclusiones causales condicionadas a los supuestos. Si el DAG es correcto y no hay confusores omitidos más fuertes que la antigüedad, un baño adicional eleva el precio de oferta entre un 1.9 y un 8.8 %, con un valor central de 5.3 %.

Hipótesis para trabajos futuros (no contrastadas). Que la prima por baño sea mayor en los distritos de mayor precio. Que parte del efecto estimado se deba a calidad no observada medible en el texto de los avisos. Que la prima de oferta se traslade al precio de contrato.

8.4. Límites del trabajo

- La identificación descansa en la ignorabilidad condicional, que solo puede acotarse, no probarse.
- No se realizó el diagnóstico formal de soporte común (distribución del tratamiento condicional a X por perfil). Se recomienda incorporarlo en el siguiente entregable.
- La muestra es un corte transversal de un solo portal y un solo mes.
- No se usó la información textual de los avisos (OE5).
- El tratamiento es un conteo con un efecto lineal supuesto; la forma del efecto entre uno y tres baños no se estimó por separado.

8.5. Recomendaciones y continuidad

1. **Medición de calidad con IA (OE5).** Extraer del texto atributos de calidad (vista, ascensor, acabados, remodelación), validarlos con 200–300 avisos etiquetados a mano y re-estimar con la especificación S5. Es la vía más directa para reducir la amenaza principal.
2. **Tratamiento binario y soporte común.** Si el portal permite recuperar la disponibilidad de estacionamiento, estimar su efecto con un modelo interactivo (DML-IRM o AIPW) e incluir diagnósticos de propensión y solapamiento.
3. **Más datos y repetición temporal.** Repetir la captura en varios meses y portales permitiría aumentar la potencia para estudiar la heterogeneidad y evaluar la estabilidad del efecto.
4. **Reproducibilidad.** Consolidar los notebooks en módulos con pruebas automáticas (ausencia de fuga, recuperación de la verdad en la simulación) y una orden única que regenere todas las tablas y figuras.

Referencias

Advani, A., Kitagawa, T., & Słoczyński, T. (2019). Mostly harmless simulations? Using Monte Carlo studies for estimator selection. *Journal of Applied Econometrics, 34*(6), 893–910. https://doi.org/10.1002/jae.2724

Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized random forests. *The Annals of Statistics, 47*(2), 1148–1178. https://doi.org/10.1214/18-AOS1709

Bach, P., Chernozhukov, V., Kurz, M. S., & Spindler, M. (2022). DoubleML: An object-oriented implementation of double machine learning in Python. *Journal of Machine Learning Research, 23*(53), 1–6. https://www.jmlr.org/papers/v23/21-0862.html

Barrientos, R., Delgado, R., Escalante, L., Febres, G., Hisbes, B., Chavez-Bedoya, L., Rosales, F., & Vargas, W. (2026). Using machine learning to predict apartment prices in Lima. En *Entrepreneurship and human-centric business strategies for social and economic resilience* (pp. 2725–2737). Springer. https://doi.org/10.1007/978-981-95-6415-6_168

Black, S. E. (1999). Do better schools matter? Parental valuation of elementary education. *The Quarterly Journal of Economics, 114*(2), 577–599. https://doi.org/10.1162/003355399556070

Cacñahuaray Huaraca, J. C., & Jiménez Novoa, S. M. (2024). *Modelo predictivo de precios de alquiler de departamentos en la provincia de Lima usando técnicas de machine learning* [Tesis de segunda especialidad, Universidad Peruana Unión]. Repositorio institucional UPeU.

Cameron, A. C., & Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources, 50*(2), 317–372. https://doi.org/10.3368/jhr.50.2.317

Chay, K. Y., & Greenstone, M. (2005). Does air quality matter? Evidence from the housing market. *Journal of Political Economy, 113*(2), 376–424. https://doi.org/10.1086/427462

Chen, Z., Moeltner, K., & Mair, M. (2026). *Recovering direct price effects of environmental amenities in housing markets: Regression and causal machine learning model assessment with empirical Monte Carlo simulation* (arXiv:2606.02795). arXiv.

https://arxiv.org/abs/2606.02795

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal, 21*(1), C1–C68. https://doi.org/10.1111/ectj.12097

Chernozhukov, V., Cinelli, C., Newey, W., Sharma, A., & Syrgkanis, V. (2022). *Long story short: Omitted variable bias in causal machine learning* (NBER Working Paper No. 30302). National Bureau of Economic Research. https://www.nber.org/papers/w30302

Cinelli, C., Forney, A., & Pearl, J. (2024). A crash course in good and bad controls. *Sociological Methods & Research, 53*(3), 1071–1104. https://doi.org/10.1177/00491241221099552

Cinelli, C., & Hazlett, C. (2020). Making sense of sensitivity: Extending omitted variable bias. *Journal of the Royal Statistical Society: Series B, 82*(1), 39–67. https://doi.org/10.1111/rssb.12348

Gyger, T., Hauri, S., Bühlmann, S., Lehner, M., Schlesinger, J., & Sigrist, F. (2026). Explainable spatial machine learning for hedonic real estate modeling. *Real Estate Economics, 54*(3), 761–806. https://doi.org/10.1111/1540-6229.70030

Hernán, M. A., & Robins, J. M. (2020). *Causal inference: What if*. Chapman & Hall/CRC.

Hünermund, P., Louw, B., & Caspi, I. (2023). Double machine learning and automated confounder selection: A cautionary tale. *Journal of Causal Inference, 11*(1), 20220078. https://doi.org/10.1515/jci-2022-0078

Imbens, G. W., & Rubin, D. B. (2015). *Causal inference for statistics, social, and biomedical sciences: An introduction*. Cambridge University Press.

Keele, L. J., & Titiunik, R. (2015). Geographic boundaries as regression discontinuities. *Political Analysis, 23*(1), 127–155. https://doi.org/10.1093/pan/mpu014

Knaus, M. C., Lechner, M., & Strittmatter, A. (2021). Machine learning estimation of heterogeneous causal effects: Empirical Monte Carlo evidence. *The Econometrics Journal, 24*(1), 134–161. https://doi.org/10.1093/ectj/utaa014

Malpezzi, S. (2003). Hedonic pricing models: A selective and applied review. En T. O'Sullivan & K. Gibb (Eds.), *Housing economics and public policy* (pp. 67–89). Blackwell.

Moran, P. A. P. (1950). Notes on continuous stochastic phenomena. *Biometrika, 37*(1/2), 17–23. https://doi.org/10.2307/2332142

Mundaca, F., & Sánchez, E. (2018). Índice de precios de inmuebles: un enfoque hedó-

nico. *Revista Estudios Económicos, 36*, 55–74. Banco Central de Reserva del Perú.

Pearl, J. (2009). *Causality: Models, reasoning, and inference* (2.ª ed.). Cambridge University Press.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rivera Romero, L. A. (2018). *Caso: determinantes del precio por metro cuadrado para departamentos en Lima Metropolitana: período 2005–2017* [Trabajo académico, Universidad de Lima].

Robinson, P. M. (1988). Root-N-consistent semiparametric regression. *Econometrica, 56*(4), 931–954. https://doi.org/10.2307/1912705

Rosen, S. (1974). Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy, 82*(1), 34–55. https://doi.org/10.1086/260169

Sirmans, G. S., Macpherson, D. A., & Zietz, E. N. (2005). The composition of hedonic pricing models. *Journal of Real Estate Literature, 13*(1), 1–44. https://doi.org/10.1080/10835547.2005.12090154

Tapia, J., Chavez-Garzon, N., Pezoa, R., Suarez-Aldunate, P., & Pilleux, M. (2025). Comparing automated valuation models for real estate assessment in the Santiago Metropolitan Region: A study on machine learning algorithms and hedonic pricing with spatial adjustments. *PLOS ONE, 20*(3), e0318701. https://doi.org/10.1371/journal.pone.0318701

VanderWeele, T. J., & Ding, P. (2017). Sensitivity analysis in observational research: Introducing the E-value. *Annals of Internal Medicine, 167*(4), 268–274. https://doi.org/10.7326/M16-2607

Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association, 113*(523), 1228–1242. https://doi.org/10.1080/01621459.2017.1319839

Apéndice A

Diccionario de variables

Tabla A.1: Variables del archivo crudo y faltantes (N = 3 739)

Variable	Faltantes	% faltante	Descripción
longitud	0	0.0	Longitud geocodificada desde la dirección
descripcion	16	0.4	Texto libre del aviso (solo para deduplicar; no se exporta)
area	160	4.3	Área (m2) declarada en el aviso
banos	30	0.8	Número de baños. Tratamiento T
precio	62	1.7	Precio de oferta mensual (S/). Resultado Y = log(precio)
latitud	0	0.0	Latitud geocodificada desde la dirección
dormitorios	44	1.2	Número de dormitorios
fecha_publicacion	5	0.1	Días desde la publicación del aviso
distrito	2	0.1	Distrito de búsqueda del portal (13 distritos)
antiguedad	1,149	30.7	Años de antigüedad del inmueble
direccion	0	0.0	Dirección (dato sensible; no se exporta)
precision	0	0.0	Precisión de la geocodificación (ROOFTOP, APPROXIMATE, ...)
type	0	0.0	Tipo de lugar devuelto por el geocodificador

Fuente: `notebook2_auditoria.ipynb` → `R1_diccionario.csv`.

Apéndice B

Registro de la búsqueda bibliográfica

Pregunta orientadora (PCC). Población: mercados de vivienda urbana, en especial de alquiler. Concepto: efecto de atributos de la vivienda sobre el precio, estimado con métodos hedónicos, predictivos o causales. Contexto: Perú y comparadores internacionales.

Fuentes. Google Scholar, RePEc/IDEAS, arXiv, NBER, repositorios institucionales peruanos (UPeU, Universidad de Lima, UNALM, ESAN) y publicaciones del BCRP. Los metadatos de las referencias con DOI se verificaron contra Crossref el 21 de octubre de 2026.

Cadenas principales.

- `("doublemachinelearning"OR"causalforest"OR"doublyrobust")AND("housing "OR"rental"OR"realestate"OR"hedonic")`
- `("precioshedónicos"OR"índicedepreciosdeinmuebles")ANDLima`
- `("machinelearning"OR"aprendizajeautomático")AND("alquiler"OR"departa mentos")ANDLima`
- `("omittedvariablebias"OR"sensitivityanalysis")AND("causalmachinelear ning"OR"doublemachinelearning")`

Criterios. Inclusión: estudios con datos de vivienda que estimen precios implícitos, predigan precios o identifiquen efectos de atributos o amenidades; y trabajos metodológicos usados directamente en la tesis. Exclusión: estudios sin acceso a los metadatos

completos, trabajos duplicados entre versiones (se cita la versión publicada cuando existe) y estudios de valuación comercial sin método documentado.

Tabla B.1: Matriz de extracción resumida de los antecedentes

Trabajo	Resultado / datos	Identificación	Límite respecto de esta tesis
Mundaca y Sánchez (2018)	Precio de venta, Lima	Hedónico (no causal)	Índice de precios; baños "muy valorados" sin estrategia causal
Rivera (2018)	Precio/m², Lima 2005–2017	Regresión de determinantes	Usa una transformación del resultado como variable dependiente
Cacñahuaray y Jiménez (2024)	Alquiler, Lima	Predicción	No estima efectos contrafactuales
Barrientos et al. (2026)	Venta, Lima (BCRP, 40 000 registros)	Predicción + importancias	Importancias ≠ efectos causales
Tapia et al. (2025)	Venta, Santiago	Valuación automática	Objetivo predictivo
Gyger et al. (2026)	Alquiler, Alemania	Predicción explicable	Modela dependencia espacial, sin identificación causal
Chen et al. (2026)	Venta, Nueva York	DiD y Monte Carlo empírico	Tratamiento distinto (amenidad ambiental)
Sirmans et al. (2005)	Revisión de estudios hedónicos	–	Evidencia de la variabilidad de los coeficientes según la especificación

Apéndice C

Inventario de artefactos y trazabilidad

Artefacto	Contenido
`notebooks/notebook0_data_wrangling.ipynb`	Construcción del CSV usado por el análisis exploratorio previo
`notebooks/notebook1.ipynb`	Análisis exploratorio y pruebas de hipótesis asociativas (entregable previo)
`notebooks/notebook_causal.ipynb`	Primer DML, PC/LiNGAM y refutadores (entregable previo)
`notebooks/notebook2_auditoria.ipynb`	OE1 · R1: auditoría, deduplicación, exclusiones, agrupamientos, F2
`notebooks/notebook3_estimacion_causal.ipynb`	OE2–OE4 · R3, R4, R5, R7 y dependencia espacial; F1, F4, F5, F7
`notebooks/notebook4_semisintetico.ipynb`	OE6 · R6: validación semisintética; F6
`notebooks/causal_utils.py`	Funciones compartidas: muestra, DML-PLR agrupado, GATE, sensibilidad, Moran
`notebooks/semisintetico.py`	Proceso generador y réplicas de la simulación
`notebooks/resultados/tablas/*.csv|.tex`	Tablas de resultados (una por bloque R1–R7)
`notebooks/resultados/figuras/*.png`	Figuras F1–F7
`notebooks/resultados/resumen_principal.json`	Cifras del estimador principal citadas en el texto
`informe/tablas_manuscrito.py`	Convierte los CSV en las tablas compactas del manuscrito
`csv/data_causal_base.csv`	Base auditada sin textos ni direcciones (no se publica)

Orden de ejecución. `notebook2` → `notebook3` → `notebook4` → `informe/tablas_manuscrito.py` → compilación del manuscrito. Todas las semillas están fijadas (`SEED=42`). La automatización en un único comando y la estructura definitiva del repositorio quedan para el siguiente entregable.

Privacidad. Los archivos de datos (`data/`, `csv/`) están excluidos del control de versiones. La base auditada no contiene descripciones, direcciones, teléfonos ni identificadores de anunciantes.

Apéndice D

Versiones de software

Python 3.13.15; pandas 3.0.6; NumPy 2.5.3; scikit-learn 1.9.1 (Pedregosa et al., 2011); SciPy 1.18.1; statsmodels 0.15.0; matplotlib 3.11.2; seaborn 0.13.2; NetworkX 3.7; joblib 1.6.0; nbclient 0.11.0. En el entregable previo se usaron además EconML 0.17.0, DoWhy 0.14 y causal-learn 0.1.4.8. El manuscrito se compiló con Tectonic 0.15.0 (XeTeX).

Apéndice E

Tablas suplementarias

Tabla E.1: Variantes de la muestra analítica

Variante de muestra	N
Principal (dedup + G1 + F1-F6)	3,028
Sin deduplicar (G1 + F1-F6)	3,248
Dedup + G1 + filtro mínimo	3,243
Principal sin geocodificación APPROXIMATE	2,508

Fuente: `notebook2_auditoria.ipynb` → `R1_variantes_muestra.csv`.

Tabla E.2: Agrupamientos usados para la partición y la inferencia (muestra principal)

Agrupamiento	N grupos	Tamaño mediano	Tamaño máximo	% avisos en grupos >1
edificio_id	2,178	1.0	68	37.2
celda_1km	183	8.0	103	99.0
distrito	13	218	460	100

Fuente: `notebook2_auditoria.ipynb` → `R1_agrupamientos.csv`.

Tabla E.3: Indicadores de robustez frente a confusores no observados

Indicador	Valor
RV ($\theta \to 0$)	0.075
RV_α (límite inferior IC → 0)	0.029
E-value (VanderWeele-Ding, escala d = θ/DE(Y))	1.402

Fuente: `notebook3_estimacion_causal.ipynb`, sección 4 → `R5_robustez.csv`.