[UNIVERSIDAD]
[FACULTAD]
[ESCUELA PROFESIONAL]

INFERENCIA CAUSAL ESPACIAL ASISTIDA POR INTELIGENCIA ARTIFICIAL PARA LA VALORACIÓN CONTRAFACTUAL DE ATRIBUTOS RESIDENCIALES: EL EFECTO DE LA COCHERA INCLUIDA EN EL PRECIO DE OFERTA DE ALQUILER EN LIMA METROPOLITANA

TESIS

Para optar el título profesional de [título]

Elaborada por

Luis Azaña

Asesor

[Nombre del asesor]

Lima, Perú

2026

Resumen

Esta tesis estima el efecto causal de que un departamento en alquiler incluya cochera sobre su precio de oferta en Lima Metropolitana. A diferencia de los trabajos locales previos, que predicen precios, el objetivo es separar la asociación hedónica del efecto atribuible al atributo bajo supuestos explícitos. Se auditaron 3 739 avisos obtenidos por *web scraping* en 13 distritos (marzo de 2025): se eliminaron 243 duplicados (83 de ellos, el mismo aviso registrado en dos distritos) y se conservaron solo las direcciones geocodificadas con precisión exacta (`ROOFTOP`), con lo que la muestra queda en 2 220 avisos. La disponibilidad de cochera no figuraba en los datos: se extrajo del texto de cada aviso combinando un filtro con expresiones regulares y un modelo de lenguaje (`gpt-4.1-mini`, salida JSON con esquema fijo), con un costo total de 0.76 USD. Un grafo acíclico dirigido justifica el conjunto de ajuste: área, dormitorios, baños, antigüedad, ubicación, días publicado y tipo de geocodificación. El estimador principal es Double Machine Learning interactivo (IRM/AIPW), con *cross-fitting* agrupado por edificio, errores estándar agrupados y recorte al soporte común (propensión entre 0.05 y 0.95; 1 949 avisos). La diferencia bruta es del 63 %; el efecto estimado es de **7.5 % (IC 95 %: 3.7–11.4 %)**, unos S/ 199 mensuales sobre un alquiler de referencia de S/ 2 650. El efecto es heterogéneo: casi nulo en los distritos de mayor precio (1.5 %) y mayor donde las cocheras son escasas (10 % y 18 %; Wald, $p < 0.001$). Como análisis secundario, un baño adicional eleva el precio en 3.8 % (1.7–6.0 %). Ambos resultados son moderadamente frágiles: un confusor omitido tan fuerte como la antigüedad los llevaría cerca de cero. Una validación semisintética con 800 réplicas muestra que los estimadores recuperan el efecto cuando no hay confusión omitida, pero que la cota de sensibilidad del estimador binario es optimista. Los resultados son causales solo de forma condicional a los supuestos, válidos para la población de avisos publicados y exploratorios mientras la extracción con IA no se valide con etiquetas humanas.

Palabras clave: inferencia causal; Double Machine Learning; precios hedónicos; alquiler; cochera; modelos de lenguaje; análisis de sensibilidad; Lima.

Abstract

This thesis estimates the causal effect of an included parking space on the asking rent of apartments in Metropolitan Lima. Unlike previous local studies, which predict prices, the goal is to separate hedonic association from the effect attributable to the attribute under explicit assumptions. We audited 3,739 web-scraped listings from 13 districts (March 2025), removed 243 duplicates (83 of them the same listing recorded under two districts) and kept only exactly geocoded addresses (`ROOFTOP`), leaving 2,220 listings. Parking availability was not a structured field: it was extracted from each listing's text with a regular-expression filter followed by a language model (`gpt-4.1-mini`, fixed JSON schema), at a total cost of USD 0.76. A directed acyclic graph justifies the adjustment set: floor area, bedrooms, bathrooms, building age, location, days on market and geocoding type. The main estimator is an interactive Double Machine Learning model (IRM/AIPW) with building-grouped cross-fitting, cluster-robust standard errors and trimming to the common-support population (propensity between 0.05 and 0.95; 1,949 listings). The raw difference is 63 %; the estimated effect is **7.5 % (95 % CI: 3.7–11.4 %)**, about PEN 199 per month for a reference rent of PEN 2,650. The effect is heterogeneous: almost zero in the most expensive districts (1.5 %) and larger where parking is scarce (10 % and 18 %; Wald $p < 0.001$). As a secondary analysis, an additional bathroom raises rent by 3.8 % (1.7–6.0 %). Both results are moderately fragile: an omitted confounder as strong as building age would bring them close to zero. A semi-synthetic validation with 800 replications shows that the estimators recover the effect without omitted confounding, but that the sensitivity bound of the binary estimator is optimistic. The findings are causal only conditionally on the stated assumptions, apply to published listings, and remain exploratory until the AI extraction is validated against human labels.

Keywords: causal inference; double machine learning; hedonic pricing; rental housing; parking; large language models; sensitivity analysis; Lima.

Índice general

Resumen I

Abstract II

1. Introducción **1**

1.1. Contexto 1

1.2. Punto de partida: el avance previo 1

1.3. Problema 2

1.4. Pregunta de investigación 2

1.5. Objetivos 3

1.5.1. Objetivo general 3

1.5.2. Objetivos específicos 3

1.6. Hipótesis 4

1.7. Alcance y aportes 4

1.8. Organización del documento 5

2. Antecedentes y estado del arte **6**

2.1. Marco de referencia: precios hedónicos 6

2.2. Antecedentes peruanos 7

2.3. La cochera como atributo residencial 7

2.4. Del aprendizaje automático predictivo al causal 8

2.5. Avisos en línea y su texto como fuente de datos 9

2.6. Síntesis y vacío 10

3. Fundamentos y modelo causal **11**

3.1. Resultados potenciales y estimando 11

3.2. Supuestos de identificación 12
3.3. Grafo causal (DAG) 12
3.4. Papel de cada variable: buenos y malos controles 14
3.5. Selección, causalidad espacial y amenazas a la validez 14

4. Datos y metodología **16**
4.1. Fuente de datos 16
4.2. Auditoría y construcción de la muestra 16
4.3. Medición de la cochera con inteligencia artificial (OE5) 17
4.4. Variables 18
4.5. Estimadores 19
4.5.1. Línea base 19
4.5.2. Double ML interactivo (IRM/AIPW) para la cochera 19
4.5.3. Double ML parcialmente lineal (PLR) para los baños 20
4.5.4. Inferencia agrupada 20
4.5.5. Efectos por grupos (GATE) 20
4.5.6. Sensibilidad a confusores omitidos 20
4.5.7. Autocorrelación espacial 21

5. Diseño experimental y validación **22**
5.1. Comparadores y métricas 22
5.2. Grillas congeladas de especificaciones 22
5.3. Estrategia de sensibilidad 24
5.4. Validación semisintética 24

6. Resultados **25**
6.1. Población y muestra (R1) 25
6.2. Medición de la cochera con IA (R8) 27
6.3. Soporte común y balance (R2) 29
6.4. Efecto de la cochera incluida (R3) 30
6.5. Grilla de especificaciones (R4) 32
6.6. Robustez a confusores no observados (R5) 32
6.7. Heterogeneidad preespecificada (R7) 34

6.8. Análisis secundario: un baño adicional 35
6.9. Validación semisintética (R6) 36
6.10. Resultados desfavorables 39

7. Discusión **40**
7.1. Interpretación económica 40
7.2. Comparación con los antecedentes 41
7.3. Por qué el efecto podría estar sesgado 42
7.4. Amenazas a la validez y alcance 42
7.5. Alcance de las aplicaciones 43

8. Conclusiones y recomendaciones **44**
8.1. Respuesta a la pregunta de investigación 44
8.2. Conclusiones por objetivo específico 44
8.3. Análisis secundario 45
8.4. Tres tipos de afirmaciones 46
8.5. Límites del trabajo 46
8.6. Recomendaciones y continuidad 46

Referencias **48**

A. Diccionario de variables **52**

B. Registro de la búsqueda bibliográfica **53**

C. Inventario de artefactos y trazabilidad **56**

D. Versiones de software **58**

E. Tablas suplementarias **59**

Índice de tablas

2.1. Cuadro comparativo de antecedentes 10

3.1. Papel de cada variable respecto del efecto de la cochera sobre el precio 14

5.1. Grilla de especificaciones para la cochera (preespecificada) 23
5.2. Grilla de especificaciones para los baños (preespecificada) 23

6.1. Flujo de exclusiones de la muestra (R1) 26
6.2. Cobertura y perfil por distrito, muestra principal ROOFTOP (N = 2 220) 26
6.3. Pre-filtro con expresiones regulares 27
6.4. Clasificación de la cochera y uso en el análisis 28
6.5. Perfil de los grupos de tratamiento 28
6.6. Diagnósticos de la propensión y del soporte común (R2) 29
6.7. Balance de covariables: diferencias de medias estandarizadas 30
6.8. Efecto de tener cochera incluida sobre el precio de oferta (R3). EE agrupados por edificio 30
6.9. Efecto de la cochera bajo cada especificación (R4). DML-IRM, soporte común, 3 repeticiones 32
6.10. Efecto corregido si existiera un confusor omitido tan fuerte como un bloque observado (R5) 33
6.11. Efecto de la cochera por grupo preespecificado (GATE, R7) 34
6.12. Efecto de un baño adicional (muestra ROOFTOP, N = 2 220) 35
6.13. Diagnóstico de los modelos auxiliares y efecto por *learner* (baños) . . . 35
6.14. Efecto de un baño adicional bajo cada especificación 35
6.15. Sensibilidad del efecto de un baño adicional 36
6.16. Validación semisintética del estimador binario: sesgo, RMSE y cobertura (R6) 36

6.17. Validación semisintética del estimador de baños: sesgo, RMSE y cobertura del IC 95 % (%) 38

A.1. Variables del archivo crudo y faltantes (N = 3 739) 52

B.1. Matriz de extracción resumida de los antecedentes 55

E.1. Variantes de la muestra analítica 59

E.2. Agrupamientos usados para la partición y la inferencia (muestra principal) 59

E.3. Indicadores de robustez del efecto de un baño adicional 59

E.4. Indicadores de robustez del efecto de la cochera 60

Índice de figuras

3.1. DAG del efecto de la cochera (F1b). Azul: confusores ajustados; gris punteado: confusor no observado U; lila punteado: la cochera se observa a través del texto del aviso. 12

3.2. DAG del análisis secundario: efecto de un baño adicional (F1). 13

6.1. Distribución territorial de la muestra ROOFTOP (F2). Izquierda: avisos por distrito. Derecha: bloques espaciales de 1 km. 27

6.2. Porcentaje de avisos con cochera incluida por distrito (muestra ROOFTOP). 29

6.3. Soporte común (F3). Izquierda: propensión por brazo con los límites de recorte. Derecha: balance antes y después de ponderar. 30

6.4. Estimadores del efecto de la cochera con IC 95 % (F4). 31

6.5. Contorno de sensibilidad del efecto de la cochera (F5). Línea continua: efecto cero; discontinua: límite inferior del IC igual a cero. 33

6.6. Efecto de la cochera por clase de distrito y por quintil de área (F7). . . 34

6.7. Error del estimador binario en los escenarios B1 y B2 (F6). 37

6.8. Validación semisintética de los baños. Izquierda: error por escenario; derecha: cobertura del IC del DML. 38

Capítulo 1

Introducción

1.1. Contexto

El alquiler es una vía de acceso a la vivienda cada vez más importante en Lima Metropolitana. En los distritos consolidados del centro y del sur de la ciudad, la oferta de departamentos se publica sobre todo en portales inmobiliarios, donde cada aviso informa el precio pedido, un conjunto de atributos estructurados (área, dormitorios, baños, antigüedad, ubicación) y una descripción libre. Muchos atributos relevantes, como la cochera, el amoblado o la vista, solo aparecen en ese texto.

Los estudios peruanos sobre el precio de la vivienda han seguido dos caminos (capítulo 2). Unos construyen índices o modelos hedónicos (Mundaca y Sánchez, 2018; Mayo, 2017). Otros aplican aprendizaje automático para *predecir* precios (Cacñahuaray y Jiménez, 2024; Barrientos et al., 2026). Varios coinciden en que la cochera es uno de los atributos más relevantes, pero ninguno responde una pregunta contrafactual: *¿cuánto cambiaría el precio de un departamento si incluyera cochera, sin cambiar nada más?*

1.2. Punto de partida: el avance previo

Esta tesis parte de un análisis exploratorio propio sobre los mismos avisos (`notebook0` y `notebook1`). Ese trabajo limpió la base, describió el mercado (el precio y el área tienen una correlación de 0.83; los distritos de "Lima Top" son en promedio un 36 % más caros por m²; los departamentos más antiguos son más grandes y más baratos por m²) y contrastó ocho aseveraciones con pruebas de Tukey, Kruskal-Wallis, t, Spearman y regresión lineal. La octava ya planteaba, sin llamarla así, una pregunta causal: *controlando el área, ¿cuánto aporta un baño adicional al precio?* La regresión respondía que entre S/ 195 y S/ 298.

Ese avance tenía cuatro límites que motivan la tesis:

(I) sus resultados eran asociaciones, no efectos;

(II) las variables de control se eligieron sin un modelo causal explícito y con una forma funcional lineal;

(III) no detectaba duplicados ni errores de ubicación;

(IV) no podía estudiar atributos que solo aparecen en el texto, como la cochera.

Las observaciones del asesor llevaron a reformular el trabajo como un estudio causal con un tratamiento binario bien definido, la cochera incluida. Se conserva el efecto de los baños como análisis secundario, en continuidad con la aseveración 8.

1.3. Problema

La respuesta no puede leerse en una correlación ni en un coeficiente predictivo. En los datos de esta tesis, los departamentos con cochera incluida se ofrecen un 63 % más caros que los que no la tienen. Pero son, en promedio, mucho más grandes (96 frente a 65 m^2), tienen más baños y se concentran en los distritos más caros. Separar el valor de la cochera del de esas características es el problema central.

Se suman tres dificultades. Primero, **la cochera no es una variable de la base**: hay que medirla a partir del texto del aviso, y esa medición tiene error. Segundo, **la ubicación es el confusor más importante**, pero solo es confiable cuando la dirección se geocodifica con exactitud. Tercero, **atributos no observados**, como la calidad del edificio, pueden influir a la vez en que exista cochera y en el precio.

El aprendizaje automático causal, en particular *Double/Debiased Machine Learning* (Chernozhukov et al., 2018), permite ajustar por muchos confusores de forma flexible y conservar una inferencia válida. Pero la flexibilidad del estimador no sustituye la estrategia de identificación (Hünermund et al., 2023). La contribución de esta tesis es aplicar ese marco a un atributo concreto de Lima, medido con inteligencia artificial, haciendo explícitos los supuestos, auditando los datos y midiendo la fragilidad de la conclusión.

1.4. Pregunta de investigación

> ¿En qué medida un diseño de aprendizaje causal con ajuste espacial y medición de atributos asistida por IA permite estimar, dentro de la población

de avisos comparables, la prima contrafactual sobre el precio de oferta de alquiler asociada a que el departamento incluya cochera, y cuán estable es esa estimación frente a confusión no observada y a las decisiones de modelado?

1.5. Objetivos

1.5.1. Objetivo general

Estimar y evaluar la robustez del efecto causal de que un departamento incluya cochera sobre su precio de oferta de alquiler en Lima Metropolitana. Para ello se usan métodos de aprendizaje causal doblemente robustos, controles espaciales precisos, inferencia que respeta la dependencia entre avisos y una medición del tratamiento asistida por IA.

1.5.2. Objetivos específicos

OE1. Auditar, depurar y caracterizar los avisos y la selección de la muestra (procedencia, duplicados, precisión de la geocodificación, exclusiones y perfil territorial).

OE2. Definir la intervención y justificar su identificación (estimando, DAG, conjunto de ajuste, soporte común y amenazas no identificables).

OE3. Estimar y comparar la asociación hedónica con el ML causal (efecto principal con IC 95 %, diagnósticos de propensión y de los modelos auxiliares, comparación de estimadores).

OE4. Evaluar la variación socioespacial y la sensibilidad de los resultados (efectos por grupos, grilla de especificaciones, confusión no observada y dependencia espacial).

OE5. Medir el tratamiento a partir del texto con IA, documentar la cobertura y el costo, y preparar su validación humana.

OE6. Verificar el comportamiento de los estimadores con una verdad conocida (validación semisintética: sesgo, RMSE y cobertura).

OE7. Garantizar la trazabilidad: cada tabla y figura indica el notebook y el archivo que la generan.

Como **análisis secundario** se estima, sobre la misma muestra, el efecto de un baño adicional. Era la pregunta del entregable anterior y permite contrastar los resultados con un tratamiento estructurado, medido sin IA.

1.6. Hipótesis

Las hipótesis no exigen por anticipado un efecto significativo ni positivo:

H1. La magnitud de la asociación inicial cambia de forma mensurable tras el ajuste preespecificado.

H2. La omisión de confusores o la inclusión de controles causalmente inadecuados altera la estimación más que la elección del algoritmo de predicción.

H3. Existe heterogeneidad del efecto según el contexto territorial o el tamaño del departamento, y solo se afirmará si la precisión estadística la respalda.

H4. La solidez de la conclusión depende de la fuerza que se postule para los confusores no observados.

1.7. Alcance y aportes

Alcance. El objeto son los precios *de oferta* mensuales de departamentos publicados en un portal, no contratos ni bienestar de los hogares. La cobertura son 13 distritos de Lima Metropolitana con avisos activos en marzo de 2025 cuya dirección se geocodificó con precisión exacta. La unidad de análisis es el aviso, con un manejo explícito de los duplicados y de la agrupación por edificio y por zona. Los resultados no se extrapolan al parque residencial ni a avisos con dirección imprecisa.

Aportes verificables. (i) Una auditoría reproducible de la base, que documenta duplicados entre distritos y la proporción de direcciones imprecisas. (ii) Un procedimiento barato y trazable para medir atributos desde el texto con IA (regex + fragmentos + esquema JSON fijo). (iii) La estimación del efecto de la cochera con soporte común, inferencia agrupada y comparación con el enfoque hedónico. (iv) Evidencia de que ese efecto varía según la escasez de cocheras en la zona. (v) Un análisis de sensibilidad calibrado y una validación semisintética anclada en las covariables reales, que también revela sus propias limitaciones.

Limitaciones principales. El tratamiento no se asignó al azar, por lo que la interpretación causal depende de la ausencia de confusores omitidos importantes, supuesto que solo puede acotarse. La medición con IA aún no tiene validación humana. Además,

se supone que un aviso que no menciona cochera no la tiene. La muestra es un único corte de un portal.

1.8. Organización del documento

El capítulo 2 revisa la literatura. El 3 presenta el modelo causal, el estimando y el DAG. El 4 describe los datos, la auditoría, la medición con IA y los estimadores. El 5 fija las pruebas de robustez y la validación semisintética. El 6 reporta los resultados, el 7 los discute y el 8 presenta las conclusiones por objetivo.

Capítulo 2

Antecedentes y estado del arte

Este capítulo resume una revisión focalizada y documentada, no una revisión sistemática PRISMA. Las cadenas de búsqueda, las fuentes y los criterios están en el anexo B. Se organiza en cinco frentes, del más cercano al más general:

(i) los antecedentes peruanos sobre el precio de la vivienda;

(ii) la cochera como atributo residencial y su contexto en Lima;

(iii) el paso del aprendizaje automático predictivo al causal;

(iv) el uso de avisos en línea y de su texto como fuente de datos;

(v) la síntesis y el vacío que aborda esta tesis.

Las afirmaciones de originalidad se limitan a las fuentes consultadas.

2.1. Marco de referencia: precios hedónicos

Rosen (1974) formalizó la idea de que el precio de un bien diferenciado depende de sus atributos y de que la derivada de esa función respecto de un atributo es su precio implícito. El modelo hedónico se convirtió en la herramienta estándar para valorar atributos de la vivienda (Malpezzi, 2003). La revisión de Sirmans et al. (2005) muestra, sin embargo, que el coeficiente de un mismo atributo varía mucho entre estudios según qué otras variables se controlen. Un precio implícito es *condicional a la especificación*: no indica por sí mismo cuánto cambiaría el precio si se modificara el atributo. Esa distinción entre asociación y efecto organiza todo el capítulo.

2.2. Antecedentes peruanos

Índices hedónicos. Mundaca y Sánchez (2018), del BCRP, construyen un índice de precios de departamentos *en venta* para diez distritos de Lima (unos 30 000 avisos, 2008–2016). En sus regresiones semilogarítmicas, el número de cocheras y el de baños son las características con mayor valoración por unidad. Su objetivo es el índice, no identificar efectos. Los propios autores reportan variables omitidas en sus modelos y señalan como principal limitación la falta de un buen indicador de ubicación. Mayo (2017) elabora en la Universidad Nacional de Ingeniería un índice hedónico de viviendas *nuevas* con datos del Fondo MiVivienda (2001–2015), y Rivera (2018) estudia los determinantes del precio por metro cuadrado (2005–2017). Los tres trabajan con precios de venta y modelos lineales.

Aprendizaje automático predictivo. Cacñahuaray y Jiménez (2024) predicen el alquiler de departamentos en la provincia de Lima con 3 675 avisos de 2023 y técnicas de AutoML. Entre los predictores más importantes que reportan están el área y el número de cocheras. Barrientos et al. (2026) comparan árboles de decisión y XGBoost con la regresión hedónica sobre más de 40 000 registros del BCRP (2014–2024) e identifican el tamaño, la cochera y la ubicación como los determinantes principales. Ambos confirman que la cochera es relevante para *predecir* el precio en Lima, pero no estiman cuánto lo cambia.

Inferencia causal sobre vivienda en Lima. El único antecedente local con una estrategia de identificación explícita es Contreras et al. (2024). Con diferencias en diferencias, aprovechan la apertura escalonada de la Línea 1 del Metro para estimar su efecto sobre la informalidad de la vivienda. Su variable de interés no es el precio, pero muestra que el razonamiento causal ya se aplica a la vivienda limeña.

2.3. La cochera como atributo residencial

Evidencia sobre su valor en alquileres. La referencia más directa por el tipo de tratamiento es Gabbe y Pierce (2017). Con más de 38 000 viviendas en alquiler de áreas metropolitanas de Estados Unidos, estiman que una cochera incluida en el alquiler eleva la renta en alrededor de 17 %. Manville (2013) encuentra en Los Ángeles que la cochera incluida añade unos 200 dólares mensuales al alquiler. Ambos estudian mercados con una tenencia de automóviles muy superior a la de Lima, por lo que sirven para contrastar la dirección y el orden de magnitud, no para comparar cifras directamente.

Contexto limeño. Tres hechos locales son relevantes para interpretar el valor de la cochera en Lima:

- **Regulación.** En los distritos centrales, la normativa municipal fija un número mínimo de estacionamientos por unidad de vivienda: Miraflores lo hace en el artículo 10 de la Ordenanza 342-MM (Municipalidad de Miraflores, 2011) y San Isidro en la Ordenanza 523-MSI (Municipalidad de San Isidro, 2020). Ahí la cochera tiende a ser un componente estándar de los edificios nuevos.
- **Mercado.** El índice de referencia del mercado de alquiler, que también usa el BCRP, toma como unidad típica un departamento de 60 o 100 m^2 *con un estacionamiento* (Urbania, 2025).
- **Demanda.** Solo alrededor del 17 % de los hogares de Lima y Callao tenía al menos un automóvil en 2015 (Lima Cómo Vamos, 2016), frente a una mayoría en los mercados estadounidenses citados.

Estos hechos sugieren que el valor de la cochera en Lima debería ser menor que en Estados Unidos y distinto según la zona. Esta tesis lo pone a prueba.

2.4. Del aprendizaje automático predictivo al causal

Predicción. Además de los estudios peruanos, la literatura internacional usa el aprendizaje automático para valuar inmuebles. Tapia et al. (2025) comparan modelos automáticos de valuación con hedónicos espaciales en Santiago de Chile. Gyger et al. (2026) combinan un proceso gaussiano espacial con *tree boosting* para modelar alquileres en Alemania. Estos trabajos mejoran la predicción, pero las importancias de variables o los valores SHAP describen cómo usa el modelo cada variable, no el efecto de intervenirla.

Identificación causal en vivienda. La economía urbana estima el valor de amenidades con diseños cuasiexperimentales, como discontinuidades en fronteras (Black, 1999; Keele y Titiunik, 2015) o cambios regulatorios (Chay y Greenstone, 2005). Cuando no hay una fuente de variación casi aleatoria, como ocurre con la cochera de un departamento, la alternativa es ajustar por los confusores observados bajo ignorabilidad condicional y acotar el sesgo por confusores omitidos.

Double Machine Learning. Chernozhukov et al. (2018) muestran que, si se estiman las funciones auxiliares con aprendizaje automático, se ortogonaliza el problema y se usa *cross-fitting*, el efecto es consistente y admite inferencia válida. Para tratamientos binarios, la versión interactiva (IRM/AIPW) es doblemente robusta. El marco tiene limitaciones conocidas. Hünermund et al. (2023) muestran que DML es muy sensible a la inclusión de malos controles, y Cinelli et al. (2024) sistematizan qué variables deben y no deben ajustarse. Wager y Athey (2018) y Athey et al. (2019) extienden el enfoque a efectos heterogéneos, cuya estimación es frágil en muestras moderadas (Knaus et al., 2021).

Robustez y validación. Cinelli y Hazlett (2020) y Chernozhukov et al. (2022) formulan cotas de sesgo por confusores omitidos que se calibran con confusores observados. Moran (1950) y Cameron y Miller (2015) proveen herramientas para la dependencia espacial y la inferencia agrupada. Advani et al. (2019) recomiendan validar los estimadores con simulaciones ancladas en los datos reales, y Chen et al. (2026) lo hacen al comparar regresiones hedónicas y aprendizaje causal en vivienda.

2.5. Avisos en línea y su texto como fuente de datos

Avisos como datos. Boeing y Waddell (2017) muestran que los avisos de alquiler extraídos por *web scraping* permiten estudiar mercados de alquiler a gran escala. También advierten que exigen limpieza, deduplicación y cuidado al interpretarlos como precios de oferta.

Información en el texto. Nowak y Smith (2017) encuentran que el texto libre de los avisos reduce en más de 25 % el error de precio de un modelo hedónico, y Shen y Ross (2021) que la información "blanda" de la descripción tiene un valor significativo en el precio. Los atributos relevantes no siempre están en los campos estructurados.

Modelos de lenguaje para medir atributos. Faxvaag et al. (2026) usan modelos GPT para extraer de los avisos de Oslo variables cuantitativas, entre ellas el estacionamiento, e incorporarlas a un modelo de valuación. Es el precedente metodológico más cercano a la medición de la cochera de esta tesis. Egami et al. (2023) advierten que usar etiquetas producidas por un modelo de lenguaje directamente en un análisis estadístico produce sesgo e intervalos inválidos, incluso con un 80–90 % de acierto. Proponen combinarlas con una muestra etiquetada por personas mediante un estimador doblemente robusto, lo que justifica la validación humana prevista en esta tesis.

2.6. Síntesis y vacío

Tabla 2.1: Cuadro comparativo de antecedentes

Trabajo	Objeto / datos	Qué aporta y límite	Método
Mundaca y Sánchez (2018)	Venta, Lima, 2008–2016	Cochera y baños, lo más valorado; asociativo, ubicación por distrito	Hedónico
Mayo (2017); Rivera (2018)	Venta, Lima	Índice y determinantes del precio/m²; asociativo	Hedónico / regresión
Cacñahuaray y Jiménez (2024)	Alquiler, Lima, 2023	La cochera, entre los predictores más fuertes; no estima efecto	ML predictivo
Barrientos et al. (2026)	Venta, Lima (BCRP)	La cochera como determinante clave; predictivo	XGBoost vs. hedónico
Contreras et al. (2024)	Informalidad, Lima	Único causal local; no estudia precios	Diferencias en diferencias
Gabbe y Pierce (2017)	Alquiler, EE. UU.	Cochera incluida +17 % del alquiler; otro mercado	Hedónico
Faxvaag et al. (2026)	Avisos, Oslo	Estacionamiento extraído con GPT; objetivo predictivo	LLM + valuación
Egami et al. (2023)	Metodológico	Uso válido de etiquetas de LLM con validación humana	DSL (doblemente robusto)
Esta tesis	**Alquiler, Lima, 2025**	**Efecto causal de la cochera medida con IA, con soporte común y sensibilidad**	**DML-IRM + validación semisintética**

La tabla 2.1 resume la posición de la tesis. Los estudios peruanos coinciden en que la cochera es un atributo relevante del precio, pero la abordan con modelos asociativos o predictivos y sobre precios de venta. La literatura internacional ofrece evidencia sobre el valor de la cochera en alquileres y herramientas para estimar efectos causales y medir atributos desde el texto. En las fuentes consultadas no se encontró un estudio sobre Lima que combine las tres piezas: estimar causalmente el valor de un atributo del alquiler, medir ese atributo desde el texto con IA y acotar la fragilidad del resultado. Ese es el espacio en que se sitúa esta tesis.

Capítulo 3

Fundamentos y modelo causal

3.1. Resultados potenciales y estimando

Sea i un aviso de alquiler y $D_i \in \{0, 1\}$ el tratamiento: $D_i = 1$ si el departamento incluye cochera en el alquiler y $D_i = 0$ si no tiene cochera. El resultado es $Y_i = \ln P_i$, el logaritmo del precio mensual de oferta. En el lenguaje de resultados potenciales (Imbens y Rubin, 2015; Hernán y Robins, 2020), $Y_i(1)$ y $Y_i(0)$ son los log-precios que se pedirían por el mismo departamento con y sin cochera incluida, con el resto de sus atributos fijos. El estimando principal es el efecto promedio del tratamiento en la población con soporte común:

$$\theta = E\big[\, Y(1) - Y(0) \;\big|\; X \in \mathcal{S} \,\big], \qquad \mathcal{S} = \{x : \; 0.05 \le m(x) \le 0.95\}, \tag{3.1}$$

donde $m(x) = P(D = 1 \mid X = x)$ es la propensión. El efecto en porcentaje es $100\,(e^{\theta} - 1)$. En soles se reporta solo para un alquiler de referencia fijado de antemano: la mediana de la muestra (S/ 2 650).

La restricción a $\mathcal{S}$ es deliberada. Para un departamento cuyo perfil hace casi seguro que tenga cochera (o que no la tenga), los datos no contienen comparaciones creíbles, y el efecto en ese perfil solo podría obtenerse extrapolando. Recortar cambia la población a la que se refiere el resultado; por eso se reporta también el efecto sin recorte.

Tratamiento secundario. Para el número de baños $T \in \{1, \ldots, 5\}$, un conteo, el estimando es el coeficiente θ_T del modelo parcialmente lineal (Robinson, 1988):

$$Y = \theta_T \, T + g(X) + \varepsilon, \qquad T = m_T(X) + V, \tag{3.2}$$

interpretado como el efecto medio de un baño adicional, ponderado por la varianza condicional de T.

3.2. Supuestos de identificación

1. **Ignorabilidad condicional.** $Y(1), Y(0) \perp D \mid X$: entre departamentos iguales en X, que uno tenga cochera no depende de su precio potencial. Se viola si un factor omitido (por ejemplo, la calidad del edificio) afecta a la vez la cochera y el precio.

2. **Positividad (soporte común).** $0 < m(X) < 1$. Se diagnostica con la distribución de la propensión por brazo y se impone con el recorte $[0.05, 0.95]$.

3. **Consistencia y versiones del tratamiento.** "Cochera incluida" agrupa una o más cocheras, techadas o no. Los avisos con cochera de *costo extra* son otra versión del tratamiento (el precio no la incluye) y se excluyen del análisis principal.

4. **Medición del tratamiento.** D se mide desde el texto. Se supone que un aviso que no menciona cochera no la tiene. Un error de clasificación no diferencial tiende a atenuar el efecto; uno diferencial puede sesgarlo en cualquier dirección.

5. **Ausencia de interferencia.** La cochera de un departamento no afecta el precio de otro. Los choques comunes de edificio o de zona se tratan con inferencia agrupada.

3.3. Grafo causal (DAG)

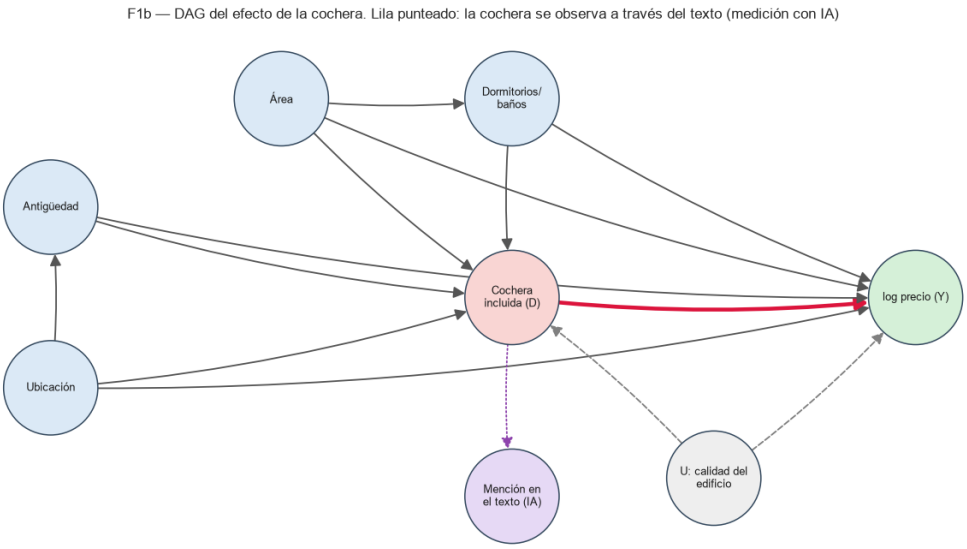


Figura 3.1: DAG del efecto de la cochera (F1b). Azul: confusores ajustados; gris punteado: confusor no observado U; lila punteado: la cochera se observa a través del texto del aviso.
Fuente: `notebook3b_efecto_cochera.ipynb`, sección 1 → `F1b_dag_cochera.png`.

La figura 3.1 presenta el modelo causal supuesto, construido con conocimiento del dominio y con el orden temporal de las decisiones. La ubicación y la época de construc-

ción del edificio preceden al diseño. El área, los dormitorios, los baños y la dotación de cocheras se definen en el proyecto. El precio se fija al publicar. Por el criterio *back-door* (Pearl, 2009), el **conjunto de ajuste** es: log del área, dormitorios, baños, antigüedad (con un indicador de faltante), latitud, longitud, días publicado, distrito y tipo de lugar devuelto por el geocodificador. El camino $D \leftarrow U \rightarrow Y$ no puede bloquearse con los datos; es la amenaza principal.

Para los baños (análisis secundario) se usa el DAG del entregable anterior (figura 3.2). Su conjunto de ajuste es el mismo sin los baños; la cochera se agrega como control en una especificación alternativa.

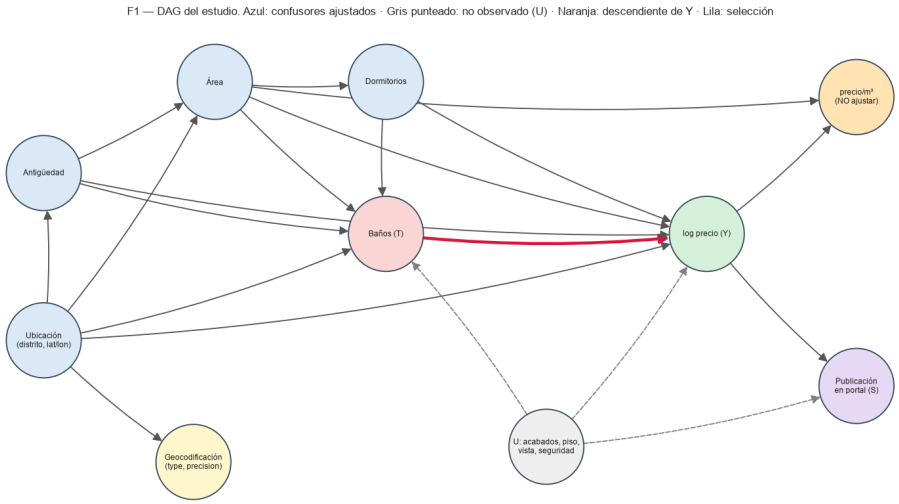


Figura 3.2: DAG del análisis secundario: efecto de un baño adicional (F1).
Fuente: `notebook3_estimacion_causal.ipynb`, sección 1 → `F1_dag.png`.

3.4. Papel de cada variable: buenos y malos controles

Tabla 3.1: Papel de cada variable respecto del efecto de la cochera sobre el precio

Variable	Papel	¿Ajustar?	Justificación
Ubicación (distrito, lat., lon.)	Confusor	Sí	Precede al proyecto; define la escasez de cocheras y el precio
Área	Confusor	Sí	Departamentos grandes suelen venir con cochera y cuestan más
Baños y dormitorios	Confusores	Sí	Reflejan el estándar del proyecto; no son consecuencia de la cochera
Antigüedad	Confusor	Sí	Los edificios antiguos tienen menos cocheras y distinto precio
Días publicado, tipo de geocodificación	Previas / artefacto	Sí	Absorben diferencias del aviso y error de ubicación
Precio por m^2	Descendiente de Y	**No**	Es el resultado dividido por el área
Mención de cochera en el texto	Medición de D	–	Define el tratamiento; su error es una amenaza
Calidad del edificio, amenidades	Confusor no observado U	Imposible	Amenaza principal; se acota con análisis de sensibilidad
Publicación en el portal	Selección	Por diseño	Los resultados valen para avisos publicados

3.5. Selección, causalidad espacial y amenazas a la validez

Selección. La muestra contiene solo departamentos publicados, vigentes en la fecha de captura y con dirección geocodificada con exactitud. Las direcciones exactas son algo más caras y se concentran en los distritos de mayor precio. Por eso los resultados valen para esa población y no se transportan al parque residencial ni a los precios de contrato.

Dependencia espacial. Departamentos cercanos comparten entorno y los avisos de un mismo edificio comparten su calidad. El *cross-fitting* se agrupa por edificio, los errores estándar se agrupan por edificio (y, como alternativa, por bloques de 1 km) y la autocorrelación residual se mide con el I de Moran.

Amenazas. (i) Confusores no observados de calidad. (ii) Error de medición del tratamiento: omisiones en el texto, descripciones truncadas por el portal y errores del modelo de lenguaje. (iii) Duplicados que inflan la precisión. (iv) Reglas de depuración basadas en el precio. (v) Extrapolación fuera del soporte común. Cada una se aborda con una especificación alternativa (capítulo 5).

Capítulo 4

Datos y metodología

4.1. Fuente de datos

Los datos provienen del *web scraping* de un portal inmobiliario peruano, realizado en marzo de 2025 sobre avisos de alquiler de departamentos en 13 distritos de Lima Metropolitana. Un *pipeline* previo geocodificó cada dirección con la API de Google, que devuelve latitud, longitud, el tipo de lugar encontrado y la precisión de la ubicación:

- `ROOFTOP`: se ubicó el edificio exacto.
- `RANGE_INTERPOLATED`: la posición se interpoló dentro de la cuadra.
- `GEOMETRIC_CENTER`: se devolvió el centro de una calle o zona.
- `APPROXIMATE`: se devolvió el centro del barrio o del distrito; muchos avisos caen en el mismo punto.

El archivo crudo tiene 3 739 avisos y 13 variables (anexo A). La descripción libre se usa para deduplicar y para medir la cochera. Ni la descripción ni la dirección se exportan a los archivos de análisis.

4.2. Auditoría y construcción de la muestra

La auditoría (`notebook2_auditoria.ipynb`) aplica, en orden, las reglas siguientes (tabla 6.1):

1. **Variables núcleo.** Se excluyen los avisos sin dormitorios, baños, área, precio o distrito.

2. **Deduplicación.** *D1 (re-publicación)*: mismo texto normalizado, mismos área, dormitorios y baños, y precio a ±10 %. La mitad de estos casos eran el mismo aviso capturado bajo dos distritos. *D2 (publicación cruzada)*: mismas coordenadas (unos 11 m), área, dormitorios, baños y precio con texto distinto. En cada grupo se conserva el aviso más reciente.

3. **Geocodificación incoherente (G1).** Se excluyen los avisos a más de 8 km de la mediana de las coordenadas de su distrito.

4. **Geocodificación no exacta (G2).** Como la ubicación es el confusor más importante, el análisis principal usa **solo direcciones `ROOFTOP`**. Con las otras precisiones, las coordenadas pueden errar por cientos de metros o kilómetros. La muestra con todas las precisiones se conserva como especificación alternativa para los baños.

5. **Reglas de depuración F1–F6.** Son las del análisis exploratorio previo: rangos plausibles, combinaciones incoherentes, precio menor de S/ 600, combinaciones raras de dormitorios y baños, y precio por m² atípico dentro de su distrito. Como varias usan el precio, se define además un **filtro mínimo** alternativo, que solo elimina errores groseros.

Unidades de dependencia. El `edificio_id` reúne los avisos con las mismas coordenadas redondeadas a cuatro decimales; es la unidad que no se reparte entre folds y el cluster principal de los errores estándar. La `celda_1km` es un bloque espacial de unos 1×1 km.

4.3. Medición de la cochera con inteligencia artificial (OE5)

La disponibilidad de cochera no es un campo de la base: hay que leerla en la descripción. El procedimiento (`notebook2b_extraccion_ia.ipynb` y `extraccion_ia.py`) se diseñó para minimizar el costo y ser reproducible:

1. **Pre-filtro con expresiones regulares.** Se buscan menciones de *cochera, estacionamiento, parqueo, parking, garaje* y sus variantes. Si no hay ninguna mención, el aviso se clasifica como *sin cochera* sin llamar a la API.

2. **Fragmentos.** Para cada mención en la posición x se toma `texto[x-200 : x+200]`, sin salirse de los límites del texto. Los fragmentos que se solapan se unen.

3. **Privacidad.** Antes de enviar el texto se enmascaran teléfonos, correos y enlaces.

4. **Modelo de lenguaje.** Se usa `gpt-4.1-mini-2025-04-14`, una versión fechada que no cambia con el tiempo, con temperatura 0 y **salida JSON con esquema estricto**:

```
{"cochera": "si"|"no", "tipo":
"incluida"|"costo_extra"|"no_tiene"|"ambigua",
"precio_extra": 0 | monto | null, "moneda", "incluida_explicita",
"num_cocheras", "motivo"}
```

   El prompt define cada categoría con ejemplos y aclara qué no cuenta como cochera del departamento: estacionamiento de visitas, en la calle o para bicicletas. Se probó en un piloto de 25 avisos, que reveló tres errores del prompt v1 (marcar como ambigua una cochera sin precio, leer "ALQUILER CON COCHERA $700" como costo extra y no reconocer "sin cochera, pero se puede alquilar"). La versión final (v2) los corrige.

5. **Caché.** Cada respuesta se guarda localmente con una clave que combina el modelo, la versión del prompt y el fragmento; volver a ejecutar no repite llamadas.

6. **Validación humana.** Se generó una muestra estratificada de 249 avisos para etiquetar a ciegas. Al cierre de este documento está pendiente, así que la medición se considera *exploratoria*.

Supuestos de medición. (i) Si el aviso no menciona cochera, se asume que no la tiene. (ii) Si tiene cochera y no indica un pago adicional, se asume incluida en el precio; la variable `incluida_explicita` marca cuándo el texto lo dice literalmente. (iii) Si indica un monto o un pago aparte, la cochera es de costo extra.

Definición del tratamiento. $D = 1$ si la cochera está incluida; $D = 0$ si el aviso no la menciona o la IA determina que no tiene. Se excluyen los casos de costo extra y los ambiguos. La definición estricta ($D = 1$ solo si la inclusión es explícita) y la que considera tratadas también las cocheras de costo extra se reportan como alternativas.

4.4. Variables

- **Resultado** Y: logaritmo del precio mensual de oferta.
- **Tratamiento principal** D: cochera incluida (binario).
- **Tratamiento secundario** T: número de baños (1–5).

- **Confusores** X: log del área, dormitorios, baños (solo para D), antigüedad (con 0 e indicador si falta, sin usar información de otras filas), latitud, longitud, días publicado, distrito (12 indicadores) y tipo de lugar de geocodificación.
- **Segmentos**: clase de distrito (clase1: Miraflores, San Isidro, Barranco y Lince; clase2: Magdalena, Surquillo, Jesús María, San Borja y Surco; clase3: Cercado, San Miguel, Chorrillos y La Molina) y quintiles de área.

4.5. Estimadores

4.5.1. Línea base

La diferencia sin ajustar es la pendiente de una regresión de Y sobre el tratamiento. El modelo hedónico lineal agrega las columnas de X. Ambos usan errores estándar agrupados por edificio.

4.5.2. Double ML interactivo (IRM/AIPW) para la cochera

Siguiendo a Chernozhukov et al. (2018), con $K = 5$ folds **agrupados por edificio**:

1. En cada fold se entrenan, con los otros cuatro: un clasificador para la propensión $\hat{m}(X) = \hat{P}(D = 1 \mid X)$ y dos regresores para $\hat{g}_1(X) = \hat{E}[Y \mid D = 1, X]$ y $\hat{g}_0(X) = \hat{E}[Y \mid D = 0, X]$, ajustados en tratados y controles. Todos son *histogram gradient boosting* (300 iteraciones, tasa 0.05, profundidad 4, mínimo de 20 observaciones por hoja, regularización L_2 igual a 1).
2. Con las predicciones fuera de fold se calcula, para cada aviso, el score doblemente robusto

$$\phi_i = \hat{g}_1(X_i) - \hat{g}_0(X_i) + \frac{D_i\,(Y_i - \hat{g}_1(X_i))}{\hat{m}(X_i)} - \frac{(1 - D_i)\,(Y_i - \hat{g}_0(X_i))}{1 - \hat{m}(X_i)}.$$

3. El efecto es el promedio de ϕ_i entre los avisos con $\hat{m} \in [0.05, 0.95]$. Sin recorte, se usa $\hat{m}$ acotada a $[0.01, 0.99]$.
4. Se repite con 10 particiones; se reporta la mediana, y el error estándar incorpora la dispersión entre particiones.

El score es *doblemente robusto*: si el modelo de la propensión o el del resultado es correcto, el estimador es consistente. Su ortogonalidad hace que los errores de primer orden de los modelos auxiliares no contaminen el efecto. Para la propensión se reportan,

fuera de fold, el AUC, el log-loss y el Brier, y el **balance** de covariables (diferencias de medias estandarizadas) antes y después de ponderar por $1/\hat{m}$ y $1/(1-\hat{m})$.

4.5.3. Double ML parcialmente lineal (PLR) para los baños

Para el tratamiento continuo se estima (3.2): se predicen Y y T desde X fuera de fold y se regresa el residuo de Y sobre el de T. Con el tratamiento binario, el PLR se reporta como comparador del IRM.

4.5.4. Inferencia agrupada

Con ψ_i el score centrado, el error estándar agrupado (CR1) es

$$\widehat{\mathrm{EE}} = \frac{1}{n}\sqrt{\frac{G}{G-1}\sum_{g}\Big(\sum_{i\in g}\psi_i\Big)^2}$$

para el IRM (análogo para el PLR, dividido por $\frac{1}{n}\sum \tilde{T}^2$). El cluster principal es el edificio; la alternativa, el bloque de 1 km.

4.5.5. Efectos por grupos (GATE)

Para el IRM, el GATE del grupo s es el promedio de ϕ_i dentro de s; para el PLR, la pendiente de los residuos dentro de s. La covarianza conjunta entre grupos se agrupa por edificio, y con ella se construyen intervalos simultáneos (Bonferroni) y una prueba de Wald de igualdad.

4.5.6. Sensibilidad a confusores omitidos

Siguiendo a Chernozhukov et al. (2022), el sesgo por un confusor omitido U queda acotado por

$$|\hat{\theta}-\theta| \le \sqrt{\frac{C_Y^2\, C_D^2}{1-C_D^2}}\,\sqrt{\sigma^2\,\nu^2}, \tag{4.1}$$

donde σ^2 es la varianza del error del resultado y $\nu^2 = E[\alpha^2]$ el segundo momento del representante de Riesz. En el IRM, $\alpha = D/m - (1-D)/(1-m)$; en el PLR, $\nu^2 = 1/E[\tilde{T}^2]$. C_Y^2 y C_D^2 miden la fuerza de U con el resultado y con el tratamiento, en escala de R^2 parcial. A partir de la cota se calculan:

- el **valor de robustez** RV: la fuerza común que lleva el efecto a cero (Cinelli y Hazlett, 2020), y RV_α, la que lleva a cero el límite inferior del IC;

- los **benchmarks**: se re-estima omitiendo un bloque de confusores observados y se mide cuánto cambian σ^2 y ν^2, lo que responde "¿y si U fuera tan fuerte como la antigüedad?";
- el **contorno de sensibilidad**.

4.5.7. Autocorrelación espacial

Se calcula el I de Moran (Moran, 1950) de los residuos con 10 vecinos más cercanos y 999 permutaciones.

Capítulo 5

Diseño experimental y validación

Este capítulo fija, antes de ver los resultados, cómo se comparan los estimadores, qué decisiones se varían y cómo se valida el procedimiento con una verdad conocida. Los protocolos están en la primera celda de `notebook3b_efecto_cochera.ipynb` (cochera) y de `notebook3_estimacion_causal.ipynb` (baños).

5.1. Comparadores y métricas

- **Cochera**: diferencia sin ajustar, hedónico OLS, DML-PLR, DML-IRM sin recorte y DML-IRM con soporte común (principal).
- **Baños**: asociación sin ajustar, hedónico OLS y DML-PLR con cuatro *learners* (*histogram gradient boosting* como principal; *gradient boosting*, *random forest* y Lasso como comparadores).
- **Modelos auxiliares**: R^2 y error absoluto fuera de fold para el resultado; AUC, log-loss y Brier para la propensión. No se usan para elegir el estimador por su coeficiente.
- **Soporte común**: histograma de la propensión por brazo, porcentaje fuera de $[0.05, 0.95]$ y balance antes y después de ponderar.

5.2. Grillas congeladas de especificaciones

Cada especificación cambia *una sola* decisión respecto de la principal.

Tabla 5.1: Grilla de especificaciones para la cochera (preespecificada)

Código	Especificación	Propósito
C1	Conjunto de ajuste del DAG, soporte común	Estimador principal
C2	Sin área	Confusión por tamaño
C3	Sin ubicación	Confusión por localización
C4	Sin baños ni dormitorios	Confusión por estándar del proyecto
C5	Sin antigüedad	Confusión por época de construcción
C6	+ precio por m²	Control derivado de Y (demostración de sesgo)
C7	Tratamiento estricto ("incluida" explícita)	Sensibilidad a la medición
C8	Cochera de costo extra también como $D = 1$	Versiones del tratamiento
C9	+ indicador de descripción truncada	Error de medición por texto incompleto
P1	Folds y EE por bloque de 1 km	Dependencia espacial más gruesa

Tabla 5.2: Grilla de especificaciones para los baños (preespecificada)

Código	Especificación	Propósito
S1	Conjunto de ajuste del DAG	Estimador principal
S2 / S3 / S4	Sin área / sin ubicación / sin antigüedad	Confusión omitida
S4b	Sin dormitorios	Efecto "paquete"
S6a / S6b	+ precio por m² / + baños por dormitorio	Controles inadmisibles
S7a	Sin tipo de geocodificación	Artefacto de medición
S8	+ cochera medida con IA	Confusor señalado por el BCRP
D1 / D2	Sin deduplicar / filtro mínimo	Decisiones de depuración
D3	Todas las precisiones de geocodificación	Efecto de la ubicación imprecisa
P1 / P2	Folds por bloque de 1 km / folds aleatorios con EE iid	Dependencia

Para ahorrar cómputo, las grillas usan 3 repeticiones del *cross-fitting* en lugar de 10. Por eso la especificación principal de la grilla difiere levemente del estimador principal.

5.3. Estrategia de sensibilidad

Se reportan el valor de robustez (RV y RV_α), los benchmarks con cuatro bloques de confusores observados ($1\times$ y $2\times$ su fuerza) y el contorno de sensibilidad. Un resultado se considera *robusto* si un confusor omitido tan fuerte como el más fuerte de los observados no lo anula, y *frágil* en caso contrario.

5.4. Validación semisintética

La validación (`notebook4_semisintetico.ipynb`) responde: *¿los estimadores recuperan el efecto cuando se conoce la respuesta?* Se conservan las covariables reales de la muestra ROOFTOP (ubicaciones, edificios y bloques), y las funciones de confusión se ajustan una vez sobre los datos reales. Así, la confusión simulada tiene la forma no lineal del mercado limeño. Se simulan el tratamiento y el resultado con un efecto conocido.

Tratamiento binario (cochera). Sobre los 2 051 avisos con tratamiento definido:

$$P(D = 1 \mid X, U) = \mathrm{logit}^{-1}\big(\mathrm{logit}\, m_0(X) + a\, U\big),$$
$$Y = g_0(X) + 0.10\, D + b\, \sigma_\varepsilon U + \sqrt{1 - b^2}\, \sigma_\varepsilon Z.$$

B1: sin confusor omitido ($a = 0$). B2: confusor moderado ($a = 0.8$, $b^2 = 0.07$). En B2 se mide la fuerza real de U comparando con un modelo que sí lo observa, y se evalúa si la cota (4.1) contiene el efecto verdadero.

Tratamiento continuo (baños). Con efecto verdadero $\theta_0 = 0.05$, en seis escenarios: E1 sin U; E2–E4 con U débil, moderado y fuerte (R^2 planteado de 0.02, 0.07 y 0.15); E5 con efecto heterogéneo por clase (0.03, 0.05 y 0.08); E6 con choques comunes por bloque de 1 km. En E1 se agrega el control inadmisible precio por m^2.

Métricas. Con 100 réplicas por escenario (800 en total): sesgo medio, RMSE, cobertura del IC 95 % y longitud media del IC; para los escenarios con U, cobertura del intervalo ampliado con la cota de sensibilidad; para E5, cobertura de los GATE y potencia de la prueba de Wald.

La simulación *no* demuestra que los efectos estimados con los datos reales sean causales. Muestra en qué condiciones los estimadores funcionan y en cuáles fallan.

Capítulo 6

Resultados

Todas las cifras provienen de las ejecuciones finales de los notebooks 2, 2b, 3, 3b y 4. Cada tabla y figura indica su archivo de origen.

6.1. Población y muestra (R1)

De los 3 739 avisos del archivo crudo, la muestra analítica conserva 2 220 (59.4 %). La tabla 6.1 detalla las pérdidas:

- **Duplicados:** se marcaron 243 (166 re-publicaciones, de las cuales 83 eran el mismo aviso capturado bajo dos distritos, y 77 publicaciones cruzadas).
- **Geocodificación incoherente:** 26 avisos estaban a más de 8 km de su distrito.
- **Geocodificación no exacta:** la exclusión más grande. De los 3 247 avisos restantes, solo 2 280 (70 %) tienen dirección `ROOFTOP`; el resto (626 `APPROXIMATE`, 313 `GEOMETRIC_CENTER` y 28 `RANGE_INTERPOLATED`) se excluye.
- **Reglas de depuración:** dentro de la muestra ROOFTOP excluyen solo 60 avisos. Los valores atípicos se concentraban en las direcciones imprecisas.

Tabla 6.1: Flujo de exclusiones de la muestra (R1)

Paso	N restante	Excluidos	% del crudo
Archivo crudo del scraping	3,739	0	100
Sin dormitorios/baños/área/precio/distrito	3,516	223	94.0
Duplicados D1 (re-publicación)	3,350	166	89.6
Duplicados D2 (publicación cruzada)	3,273	77	87.5
G1 geocodificación incoherente (>8 km del distrito)	3,247	26	86.8
G2 geocodificación no exacta (distinta de ROOFTOP)	2,280	967	61.0
F1 rangos (dorm>6, área>600, precio/m2 fuera de [8,120])	2,263	17	60.5
F2 área incoherente (<=2 dorm, 1 baño, >=160 m2)	2,262	1	60.5
F4 precio < 600	2,254	8	60.3
F5 combinación dorm-baños rara (<=3 casos)	2,244	10	60.0
F6 precio/m2 atípico en su distrito	2,220	24	59.4

Fuente: `notebook2_auditoria.ipynb` → `R1_exclusiones.csv`. La regla F3 no excluyó avisos.

La tabla 6.2 describe la muestra por distrito. Miraflores aporta el 19.2 % de los avisos y Magdalena el 4.7 %. El precio mediano va de S/ 1 850 (Chorrillos) a S/ 3 771 (San Isidro). La antigüedad falta en el 9.2 % de los avisos, frente al 25 % de la muestra con todas las precisiones: las direcciones exactas vienen de avisos más completos. La muestra tiene 1 948 edificios distintos; el 22 % de los avisos comparte edificio con otro, con un máximo de 7 por edificio.

Tabla 6.2: Cobertura y perfil por distrito, muestra principal ROOFTOP (N = 2 220)

Distrito	Clase	N	% muestra	Precio med. (S/)	Área med. (m^2)	Baños prom.	% antig. faltante
barranco	clase1	239	10.8	2,775	63	1.59	0.0
lince	clase1	137	6.2	2,400	60	1.66	19.0
miraflores	clase1	427	19.2	3,640	97	1.98	0.0
san-isidro	clase1	180	8.1	3,771	90	1.87	10.0
jesus-maria	clase2	118	5.3	2,500	72	1.85	16.9
magdalena	clase2	105	4.7	2,636	80	2.00	10.5
san-borja	clase2	164	7.4	3,000	102	1.98	15.9
surco	clase2	166	7.5	2,875	90	2.11	4.8
surquillo	clase2	126	5.7	2,316	70	1.75	15.9
cercado	clase3	119	5.4	1,900	61	1.59	24.4
chorrillos	clase3	116	5.2	1,850	70	1.73	9.5
la-molina	clase3	118	5.3	2,350	95	1.86	9.3
san-miguel	clase3	205	9.2	2,000	70	1.72	11.7

Fuente: `notebook2_auditoria.ipynb` → `R1_cobertura_distrito.csv`.

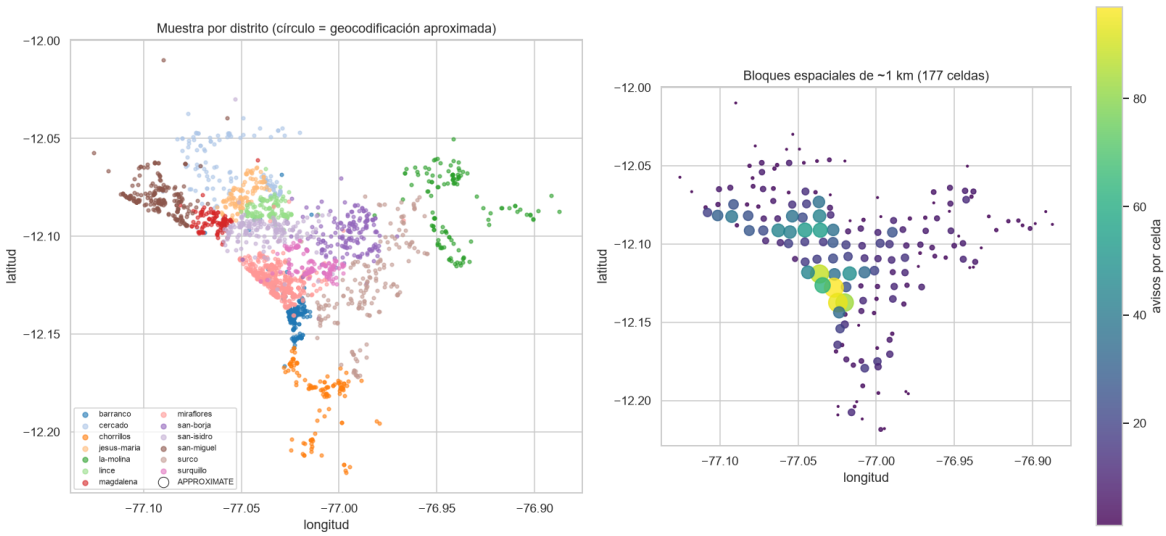


Figura 6.1: Distribución territorial de la muestra ROOFTOP (F2). Izquierda: avisos por distrito. Derecha: bloques espaciales de 1 km.

Fuente: `notebook2_auditoria.ipynb`, sección 6 → `F2_territorio.png`.

6.2. Medición de la cochera con IA (R8)

De los 2 220 avisos, 659 (29.7 %) no mencionan cochera ni estacionamiento y se clasificaron sin llamar a la API. Los 1 561 restantes se enviaron como fragmentos de unos 458 caracteres, frente a 1 012 de la descripción completa (tabla 6.3). El costo total fue de **0.76 USD**: 0.74 de la extracción completa y 0.02 de los dos pilotos.

Tabla 6.3: Pre-filtro con expresiones regulares

Concepto	Valor
Avisos ROOFTOP	2,220
Sin mención de cochera (no se envían a la API)	659
Con mención (se envían a la API)	1,561
Fragmentos únicos enviados	1,530
Largo medio del fragmento (caracteres)	458
Largo medio de la descripción completa	1,012
Descripciones que terminan en 'Leer descripción completa'	1,602

Fuente: `notebook2b_extraccion_ia.ipynb` → `R8_prefiltro.csv`.

Tabla 6.4: Clasificación de la cochera y uso en el análisis

Clasificación	N	%	Uso en el análisis
Ambigua	19	0.9	excluido
Cochera con costo extra	150	6.8	excluido
Cochera incluida	1,095	49.3	T = 1
No tiene (según la IA)	297	13.4	T = 0
Sin mención (no se envía a la API)	659	29.7	T = 0

Fuente: `notebook2b_extraccion_ia.ipynb` → `R8_distribucion.csv`.

La tabla 6.4 muestra el resultado:

- **Cochera incluida:** 1 095 avisos (49 %), el grupo tratado.
- **No tiene, según la IA:** 297 avisos. Mencionaban la palabra pero el modelo detectó "no tiene cochera", estacionamiento de visitas o en la calle, casos que una regex no distingue.
- **Costo extra:** 150 avisos. 110 indican un monto, con una mediana de S/ 250 mensuales.
- **Ambiguos:** 19 avisos.

Solo 155 avisos dicen literalmente que la cochera está incluida, lo que confirma que el supuesto "sin pago adicional = incluida" es necesario para tener un grupo tratado de tamaño útil.

Tabla 6.5: Perfil de los grupos de tratamiento

Grupo	N	Precio med. (S/)	Área med. (m^2)	Baños prom.	% en clase1
Sin cochera (T=0)	956	2,198	65	1.58	31.9
Cochera incluida (T=1)	1,095	3,200	96	2.08	56.0

Fuente: `notebook2b_extraccion_ia.ipynb` → `R8_perfil_grupos.csv`.

Los grupos son muy distintos (tabla 6.5 y figura 6.2). Los departamentos con cochera incluida tienen un área mediana de 96 m^2 frente a 65 m^2, medio baño más en promedio, y el 56 % está en los distritos de la clase1 (frente al 32 %). Es la confusión que el diseño debe resolver.

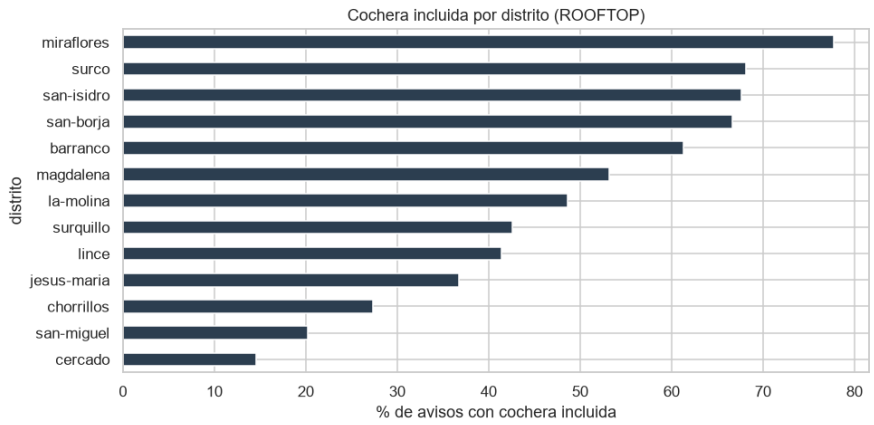


Figura 6.2: Porcentaje de avisos con cochera incluida por distrito (muestra ROOFTOP).
Fuente: `notebook2b_extraccion_ia.ipynb`, sección 5 → `F8_cochera_distrito.png`.

6.3. Soporte común y balance (R2)

La propensión fuera de fold discrimina bien entre tratados y controles: AUC de 0.82 (tabla 6.6). Solo el 5 % de los avisos tiene una propensión fuera de $[0.05, 0.95]$, de modo que la población con soporte común conserva 1 949 avisos (1 046 tratados y 903 controles). Antes de ponderar, las diferencias estandarizadas son grandes: 0.92 en el área y 0.71 en los baños. Después de ponderar dentro del soporte común, todas quedan por debajo de 0.05 en valor absoluto (tabla 6.7, figura 6.3). Por debajo de 0.1 se suele considerar que hay balance.

Tabla 6.6: Diagnósticos de la propensión y del soporte común (R2)

Diagnóstico	Valor
AUC de la propensión (fuera de fold)	0.824
Log-loss	0.516
Brier	0.171
R^2 de E[Y|D,X] (fuera de fold)	0.824
Propensión mínima / máxima	0.004 / 0.992
% fuera de [0.05, 0.95]	5.0 %
N en soporte común	1,949
Tratados / controles en soporte común	1,046 / 903

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 2 → `R2_soporte.csv`.

Tabla 6.7: Balance de covariables: diferencias de medias estandarizadas

Variable	SMD sin ponderar	SMD ponderado (soporte común)
area_log	0.924	-0.033
dormitorios	0.494	-0.016
banos	0.709	-0.023
antig	0.090	-0.021
antig_na	-0.207	-0.019
latitud	-0.295	0.042
longitud	0.279	0.028
dias_pub	-0.016	-0.023

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 2 → `R2_balance.csv`.

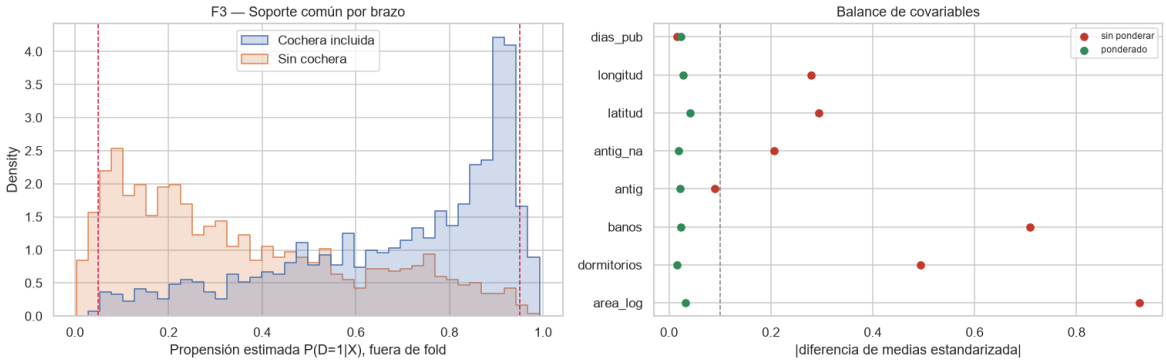


Figura 6.3: Soporte común (F3). Izquierda: propensión por brazo con los límites de recorte. Derecha: balance antes y después de ponderar.

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 2 → `F3_soporte_cochera.png`.

6.4. Efecto de la cochera incluida (R3)

Tabla 6.8: Efecto de tener cochera incluida sobre el precio de oferta (R3). EE agrupados por edificio

Estimador	N	θ	EE	IC 95 % (θ)	% efecto	IC 95 % (%)	S/ al mes
Diferencia sin ajustar (OLS)	2,051	0.4883	0.0197	[0.450, 0.527]	63.0	[56.8, 69.4]	1,668
Hedónico OLS	2,051	0.0748	0.0133	[0.049, 0.101]	7.8	[5.0, 10.6]	206
DML parcialmente lineal (PLR)	2,051	0.0683	0.0119	[0.045, 0.092]	7.1	[4.6, 9.6]	187
DML-IRM, muestra completa	2,051	0.0425	0.0356	[-0.027, 0.112]	4.3	[-2.7, 11.9]	115
DML-IRM, soporte común (principal)	1,949	0.0724	0.0184	[0.036, 0.108]	7.5	[3.7, 11.4]	199

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 3 → `R3c_principal.csv`. Alquiler de referencia: S/ 2 650.

La tabla 6.8 presenta el resultado central:

- **Sin ajustar**, los departamentos con cochera incluida se ofrecen un 63 % más caros.

- **Con el DML-IRM en la población con soporte común**, el efecto es de **7.5 % (IC 95 %: 3.7–11.4 %)**, unos **S/ 199 mensuales** (IC: S/ 98–303) sobre un alquiler de S/ 2 650.
- **Comparadores:** el hedónico OLS (7.8 %) y el DML-PLR (7.1 %) dan valores muy parecidos.
- **Sin recorte**, el IRM es inestable (4.3 %, con un IC de −2.7 a 11.9 %). Unos pocos avisos con propensión extrema dominan el promedio, lo que confirma que el recorte al soporte común es necesario.
- **Repeticiones:** las 10 particiones dieron entre 6.8 y 9.4 %.
- **Modelos auxiliares:** el modelo del resultado explica el 82 % de la varianza del log-precio fuera de fold.

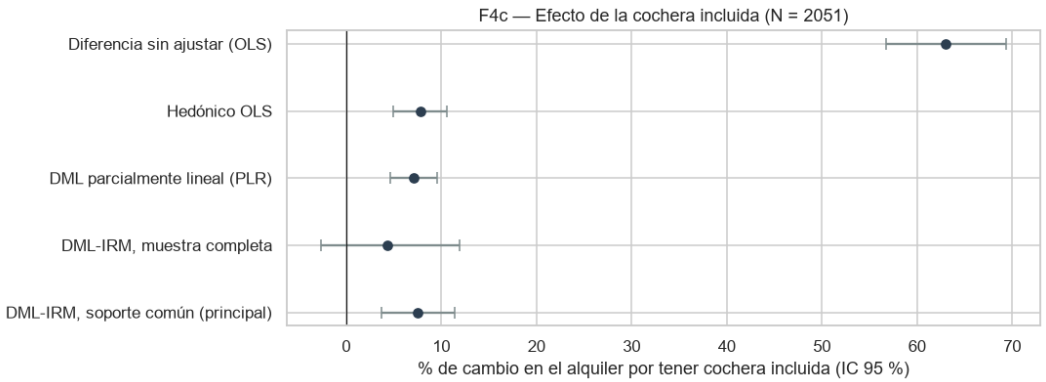


Figura 6.4: Estimadores del efecto de la cochera con IC 95 % (F4).

Fuente: `notebook3b_efecto_cochera.ipynb` → `F4c_estimadores_cochera.png`.

Que el hedónico y el DML coincidan aquí, y no en el caso de los baños (sección 6.8), es informativo. Con un tratamiento binario y buen balance tras el ajuste, la forma funcional importa menos; la validación semisintética (escenario B1) muestra el mismo patrón.

6.5. Grilla de especificaciones (R4)

Tabla 6.9: Efecto de la cochera bajo cada especificación (R4). DML-IRM, soporte común, 3 repeticiones

Cód.	Especificación	Tipo	N	θ	EE	IC 95 %	% efecto
C1	Principal	válida	1,931	0.0732	0.0166	[0.041, 0.106]	7.6
C2	Sin área	omite confusor	1,972	0.1081	0.0272	[0.055, 0.161]	11.4
C3	Sin ubicación (distrito, lat, lon)	omite confusor	1,975	0.1961	0.0201	[0.157, 0.236]	21.7
C4	Sin baños ni dormitorios	omite confusor	1,941	0.0868	0.0183	[0.051, 0.123]	9.1
C5	Sin antigüedad	omite confusor	1,930	0.0775	0.0173	[0.044, 0.111]	8.1
C6	+ precio/m^2 (descendiente de Y)	control inadmisible	1,820	-0.0046	0.0080	[-0.020, 0.011]	-0.5
C7	Tratamiento estricto (incluida explícita)	medición	547	0.0764	0.0342	[0.009, 0.143]	7.9
C8	Cochera con costo extra también como D=1	medición	2,113	0.0515	0.0156	[0.021, 0.082]	5.3
C9	+ indicador de descripción cortada	medición	1,926	0.0717	0.0181	[0.036, 0.107]	7.4
P1	Folds y EE por bloque de 1 km	partición	1,953	0.0738	0.0204	[0.034, 0.114]	7.7

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 4 → `R4c_especificaciones.csv`.

La tabla 6.9 muestra tres patrones:

1. **Omitir confusores sesga hacia arriba.** Sin la ubicación, el efecto casi se triplica (21.7 %): las cocheras abundan en los distritos caros. Sin el área sube a 11.4 %, sin baños ni dormitorios a 9.1 % y sin la antigüedad a 8.1 %.

2. **El control inadmisible lo destruye.** Con el precio por m^2, el efecto cae a -0.5 %.

3. **La medición importa poco en la dirección esperada.** Con la definición estricta (solo inclusión explícita; N = 547) el efecto es de 7.9 %, con un intervalo más amplio. Si se cuentan como tratadas también las cocheras de costo extra, baja a 5.3 %, lo esperable porque su precio no las incluye. Controlar por la descripción truncada no cambia nada (7.4 %), y tampoco agrupar por bloques de 1 km (7.7 %).

6.6. Robustez a confusores no observados (R5)

El valor de robustez es RV = 0.105: un confusor omitido que explicara el 10.5 % de la variación residual del tratamiento y del precio anularía el efecto. Para que el IC incluya el cero bastaría uno de fuerza 0.054. La tabla 6.10 lo compara con los confusores observados:

- Un U **tan fuerte como la antigüedad** reduciría el efecto a 0.4 %.
- Un U **tan fuerte como la ubicación** lo invertiría.
- Para el área y para baños y dormitorios, el benchmark del tratamiento resulta cero: omitirlos no aumenta ν^2 en la población recortada, de modo que la cota no los

penaliza. La validación semisintética muestra que esta cota es optimista para el estimador binario (sección 6.9), así que estos valores deben leerse como un mínimo.

El resultado es, por tanto, **frágil frente a un confusor de la magnitud de la antigüedad**. El candidato natural es la calidad del edificio, que se asocia tanto con tener cochera como con el precio.

Tabla 6.10: Efecto corregido si existiera un confusor omitido tan fuerte como un bloque observado (R5)

Escenario de confusor omitido	R^2 con D	R^2 con Y	θ ajustado	IC inf. ajustado	% ajustado
Estimación DML-IRM principal	–	–	0.0724	0.0364	7.5
U 1× tan fuerte como área	0.000	0.446	0.0724	0.0364	7.5
U 2× tan fuerte como área	0.000	0.892	0.0724	0.0364	7.5
U 1× tan fuerte como ubicación	0.120	0.365	-0.0730	-0.1089	-7.0
U 2× tan fuerte como ubicación	0.241	0.729	-0.2406	-0.2765	-21.4
U 1× tan fuerte como baños y dormitorios	0.000	0.023	0.0724	0.0364	7.5
U 2× tan fuerte como baños y dormitorios	0.000	0.046	0.0724	0.0364	7.5
U 1× tan fuerte como antigüedad	0.121	0.080	0.0041	-0.0319	0.4
U 2× tan fuerte como antigüedad	0.241	0.161	-0.0747	-0.1107	-7.2

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 5 → `R5c_sensibilidad.csv`.

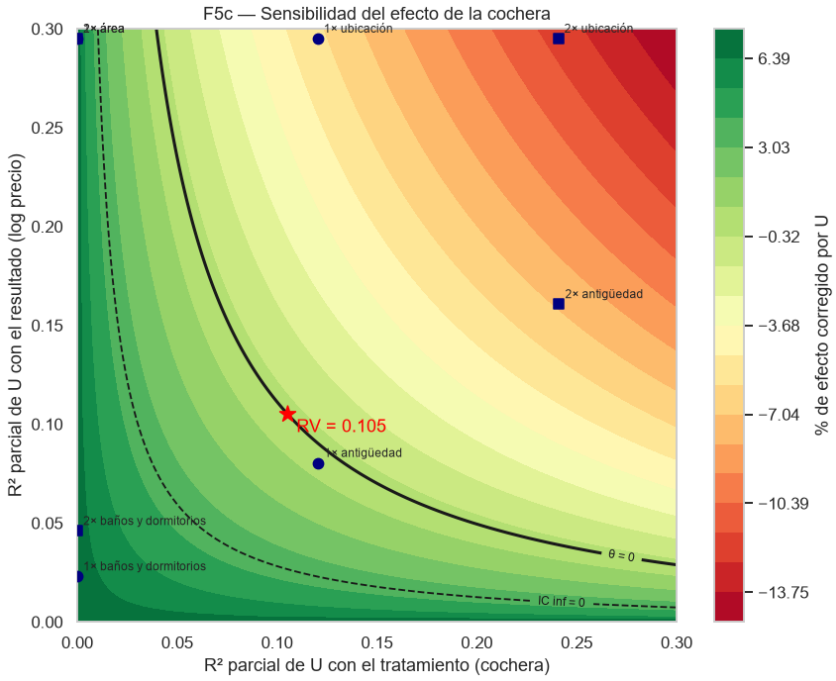


Figura 6.5: Contorno de sensibilidad del efecto de la cochera (F5). Línea continua: efecto cero; discontinua: límite inferior del IC igual a cero.

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 5 → `F5c_sensibilidad_cochera.png`.

6.7. Heterogeneidad preespecificada (R7)

A diferencia de los baños, aquí **sí hay evidencia de heterogeneidad** (tabla 6.11, figura 6.6). Por clase de distrito:

- **Clase1** (Miraflores, San Isidro, Barranco y Lince): 1.5 %, con un IC que incluye el cero.
- **Clase2**: 10.3 %.
- **Clase3**: 17.8 %.

La prueba de Wald rechaza la igualdad ($\chi^2_2 = 18.3$, $p = 0.0001$), y los intervalos simultáneos de la clase1 y la clase3 no se superponen. Por tamaño no hay diferencias significativas ($p = 0.35$).

Tabla 6.11: Efecto de la cochera por grupo preespecificado (GATE, R7)

Segmentación	Grupo	n	θ_g	EE	IC 95 %	IC simultáneo	% efecto	p Wald
clase de distrito	clase1	876	0.0149	0.0192	[-0.023, 0.053]	[-0.031, 0.061]	1.5	0.000
clase de distrito	clase2	605	0.0976	0.0308	[0.037, 0.158]	[0.024, 0.171]	10.3	0.000
clase de distrito	clase3	468	0.1638	0.0307	[0.104, 0.224]	[0.090, 0.237]	17.8	0.000
quintil de área	Q1 (25-55 m2)	420	0.1126	0.0258	[0.062, 0.163]	[0.046, 0.179]	11.9	0.348
quintil de área	Q2 (56-70 m2)	385	0.0964	0.0242	[0.049, 0.144]	[0.034, 0.159]	10.1	0.348
quintil de área	Q3 (70-89 m2)	374	0.0410	0.0300	[-0.018, 0.100]	[-0.036, 0.118]	4.2	0.348
quintil de área	Q4 (90-116 m2)	380	0.0528	0.0327	[-0.011, 0.117]	[-0.032, 0.137]	5.4	0.348
quintil de área	Q5 (117-440 m2)	390	0.0743	0.0481	[-0.020, 0.169]	[-0.050, 0.198]	7.7	0.348

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 6 → `R7c_gate.csv`.

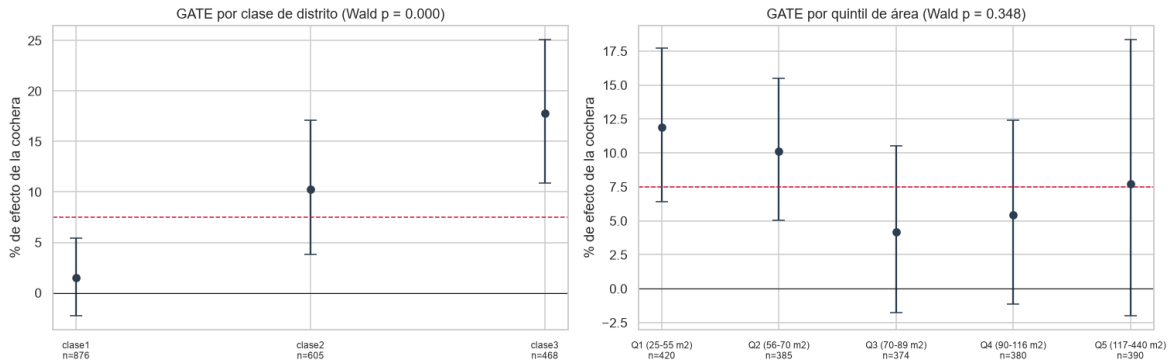


Figura 6.6: Efecto de la cochera por clase de distrito y por quintil de área (F7).

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 6 → `F7c_heterogeneidad_cochera.png`.

Dependencia espacial. El residuo del resultado tiene una autocorrelación pequeña pero significativa (I de Moran = 0.019, $p = 0.025$). El error estándar por bloque de 1 km (0.022) es mayor que el agrupado por edificio (0.018); con ambos, el IC excluye el cero.

6.8. Análisis secundario: un baño adicional

Sobre los mismos 2 220 avisos ROOFTOP, la asociación sin ajustar de un baño adicional es de 45.7 %. El hedónico lineal la reduce a 7.4 % y el DML-PLR a **3.8 % (IC 95 %: 1.7–6.0 %)**, unos S/ 100 mensuales (tabla 6.12). Los modelos auxiliares explican fuera de fold el 81 % de la varianza del log-precio y el 63 % de la de los baños. Los *learners* de árboles coinciden (3.8–4.4 %), mientras que Lasso, lineal, da 7.6 %, igual que el hedónico (tabla 6.13).

Tabla 6.12: Efecto de un baño adicional (muestra ROOFTOP, N = 2 220)

Estimador	θ	EE	IC 95 % (θ)	% por baño	IC 95 % (%)	S/ al mes
Asociación sin ajustar (OLS)	0.3764	0.0127	[0.351, 0.401]	45.7	[42.1, 49.4]	1,200
Hedónico OLS (S1 lineal)	0.0712	0.0111	[0.049, 0.093]	7.4	[5.1, 9.7]	194
Double ML PLR (HGB, S1)	0.0375	0.0103	[0.017, 0.058]	3.8	[1.7, 5.9]	100

Fuente: `notebook3_estimacion_causal.ipynb`, sección 2 → `R3_principal.csv`. Alquiler de referencia: S/ 2 625.

Tabla 6.13: Diagnóstico de los modelos auxiliares y efecto por *learner* (baños)

Learner	R^2 E[Y|X]	MAE E[Y|X]	R^2 E[T|X]	MAE E[T|X]	θ	EE	% por baño
HGB	0.814	0.152	0.627	0.330	0.0375	0.0103	3.8
GBR	0.809	0.154	0.628	0.333	0.0388	0.0102	4.0
RF	0.802	0.156	0.619	0.320	0.0434	0.0108	4.4
Lasso	0.754	0.179	0.609	0.357	0.0728	0.0113	7.6

Fuente: `notebook3_estimacion_causal.ipynb`, sección 2 → `R3_learners.csv`.

Tabla 6.14: Efecto de un baño adicional bajo cada especificación

Cód.	Especificación	Tipo	N	θ	EE	IC 95 %	% por baño
S1	Principal (conjunto del DAG)	válida	2,220	0.0378	0.0102	[0.018, 0.058]	3.9
S2	Sin área	omite confusor	2,220	0.1781	0.0157	[0.147, 0.209]	19.5
S3	Sin ubicación (distrito, lat, lon)	omite confusor	2,220	0.0802	0.0135	[0.054, 0.107]	8.4
S4	Sin antigüedad	omite confusor	2,220	0.0593	0.0102	[0.039, 0.079]	6.1
S4b	Sin dormitorios (efecto 'paquete')	variante del DAG	2,220	0.0539	0.0098	[0.035, 0.073]	5.5
S5	S1 + proxy textual validado	no ejecutada (OE5 diferido)	–	–	–	–	–
S6a	+ precio/m^2 (descendiente de Y)	control inadmisible	2,220	-0.0032	0.0024	[-0.008, 0.002]	-0.3
S6b	+ baños/dormitorio (función de T)	control inadmisible	2,220	-0.0124	0.1621	[-0.330, 0.305]	-1.2
S7a	Sin tipo de geocodificación	artefacto de medición	2,220	0.0364	0.0106	[0.016, 0.057]	3.7
S8	+ cochera extraída con IA (incluida / costo extra / ambigua)	confusor medido con IA	2,220	0.0340	0.0103	[0.014, 0.054]	3.5
D1	Sin deduplicar	depuración	2,366	0.0377	0.0107	[0.017, 0.059]	3.8
D2	Filtro mínimo (sin reglas de precio/m^2)	depuración	2,278	0.0454	0.0131	[0.020, 0.071]	4.6
D3	Todas las precisiones de geocodificación (no solo ROOFTOP)	depuración	3,028	0.0497	0.0163	[0.018, 0.082]	5.1
P1	Folds y EE por bloque espacial de 1 km	partición	2,220	0.0378	0.0122	[0.014, 0.062]	3.9
P2	Folds aleatorios (sin agrupar), EE iid	partición	2,220	0.0427	0.0103	[0.023, 0.063]	4.4

Fuente: `notebook3_estimacion_causal.ipynb`, sección 3 → `R4_especificaciones.csv`.

La grilla (tabla 6.14) repite los patrones del entregable anterior:

- **Confusores omitidos:** sin el área el efecto sube a 19.5 % y sin la ubicación a 8.4 %.

- **Control inadmisible:** con el precio por m² cae a −0.3 %.
- **Nuevo (S8):** agregar la cochera como control apenas lo cambia (3.5 %). La cochera, que el BCRP identifica como la característica más valorada, no explica el efecto de los baños.
- **Todas las precisiones de geocodificación (D3):** el efecto sube a 5.1 %. La ubicación imprecisa inflaba el efecto del baño en el entregable anterior.

Por clase de distrito ($p = 0.31$) y por tamaño ($p = 0.65$) no hay diferencias significativas. Con direcciones exactas, la autocorrelación espacial residual deja de ser significativa (I de Moran = 0.012, $p = 0.10$), y el error estándar agrupado por edificio es igual al iid. El valor de robustez es 0.079: un confusor tan fuerte como la antigüedad llevaría el efecto a 0.7 %, con un IC que incluye el cero (tabla 6.15).

Tabla 6.15: Sensibilidad del efecto de un baño adicional

Escenario de confusor omitido	R^2 con T	R^2 con Y	θ ajustado	IC inf. ajustado	% ajustado
Estimación DML principal	–	–	0.0375	0.0172	3.8
U 1× tan fuerte como área	0.152	0.445	-0.0912	-0.1115	-8.7
U 2× tan fuerte como área	0.304	0.890	-0.2466	-0.2669	-21.9
U 1× tan fuerte como ubicación	0.023	0.398	-0.0067	-0.0270	-0.7
U 2× tan fuerte como ubicación	0.046	0.796	-0.0520	-0.0723	-5.1
U 1× tan fuerte como dormitorios	0.204	0.017	0.0077	-0.0126	0.8
U 2× tan fuerte como dormitorios	0.408	0.034	-0.0316	-0.0519	-3.1
U 1× tan fuerte como antigüedad	0.044	0.095	0.0073	-0.0130	0.7
U 2× tan fuerte como antigüedad	0.089	0.190	-0.0243	-0.0446	-2.4

Fuente: `notebook3_estimacion_causal.ipynb`, sección 4 → `R5_sensibilidad.csv`.

6.9. Validación semisintética (R6)

Tratamiento binario (cochera)

Tabla 6.16: Validación semisintética del estimador binario: sesgo, RMSE y cobertura (R6)

Escenario	Estimador	θ verdadero	Sesgo	RMSE	Cobertura IC 95 %	Long. IC
B1	Hedónico OLS	0.10	0.0002	0.0147	94	0.058
B1	DML PLR	0.10	-0.0040	0.0145	95	0.055
B1	DML-IRM (soporte común)	0.10	-0.0036	0.0198	96	0.081
B2	Hedónico OLS	0.10	0.0412	0.0434	19	0.057
B2	DML PLR	0.10	0.0392	0.0418	20	0.053
B2	DML-IRM (soporte común)	0.10	0.0421	0.0462	45	0.078

Fuente: `notebook4_semisintetico.ipynb` → `R6b_simulacion_binaria.csv`. 100 réplicas por escenario; N = 2 051; efecto verdadero 0.10.

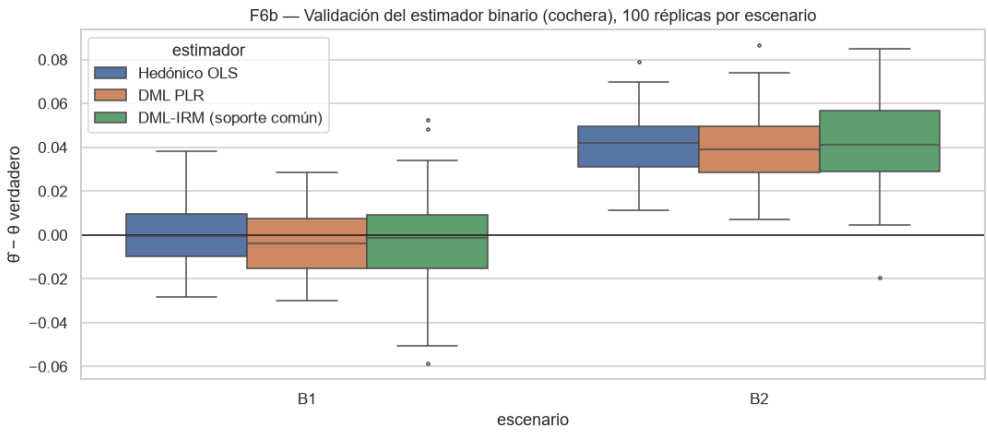


Figura 6.7: Error del estimador binario en los escenarios B1 y B2 (F6).

Fuente: `notebook4_semisintetico.ipynb` → `F6b_semisintetico_binario.png`.

Sin confusor omitido (B1). Los tres estimadores recuperan el efecto: el sesgo es de 0.000 a −0.004 y la cobertura del 94 al 96 % (tabla 6.16). El IRM con soporte común tiene un IC algo más ancho (0.081 frente a 0.055 del PLR), el precio de no imponer una forma funcional. El hedónico lineal no se sesga en este caso, igual que en los datos reales, donde coincide con el IRM.

Con confusor moderado (B2). Todos se sesgan en torno a +0.04, el 40 % del efecto verdadero, y la cobertura cae al 19–45 %. Ningún estimador corrige la confusión no observada. Además, la cota de sensibilidad evaluada con la fuerza real de U fue de 0.024 en promedio, por debajo del sesgo real (0.042). El intervalo ampliado con la cota contuvo el efecto verdadero en solo el 1 % de las réplicas. **La cota es optimista para el estimador binario**: con el recorte al soporte común, la fuerza de U medida a través de ν^2 subestima su efecto real sobre el tratamiento. Por eso los benchmarks de la sección R5 deben leerse como cotas inferiores de la fragilidad.

Tratamiento continuo (baños)

Tabla 6.17: Validación semisintética del estimador de baños: sesgo, RMSE y cobertura del IC 95 % (%)

Escenario	Estimador	θ verdadero	Sesgo	RMSE	Cob. iid	Cob. edificio	Cob. celda	Long. IC
E1	OLS sin ajustar	0.0500	0.2980	0.2981	–	0	–	0.053
E1	Hedónico OLS (S1)	0.0500	0.0215	0.0241	–	50	–	0.043
E1	DML PLR (S1)	0.0500	-0.0008	0.0108	93	93	94	0.040
E1	DML + precio/m^2 (inadmisible)	0.0500	-0.0493	0.0493	0	0	–	0.007
E2	OLS sin ajustar	0.0500	0.3017	0.3019	–	0	–	0.052
E2	Hedónico OLS (S1)	0.0500	0.0292	0.0311	–	19	–	0.043
E2	DML PLR (S1)	0.0500	0.0070	0.0130	88	89	87	0.040
E3	OLS sin ajustar	0.0500	0.3098	0.3100	–	0	–	0.052
E3	Hedónico OLS (S1)	0.0500	0.0459	0.0472	–	2	–	0.042
E3	DML PLR (S1)	0.0500	0.0246	0.0271	30	30	29	0.039
E4	OLS sin ajustar	0.0500	0.3242	0.3244	–	0	–	0.051
E4	Hedónico OLS (S1)	0.0500	0.0733	0.0740	–	0	–	0.042
E4	DML PLR (S1)	0.0500	0.0537	0.0547	0	0	0	0.039
E5	OLS sin ajustar	0.0488	0.2937	0.2938	–	0	–	0.051
E5	Hedónico OLS (S1)	0.0488	0.0212	0.0238	–	51	–	0.043
E5	DML PLR (S1)	0.0488	-0.0007	0.0109	93	94	94	0.040
E6	OLS sin ajustar	0.0500	0.2710	0.2715	–	0	–	0.054
E6	Hedónico OLS (S1)	0.0500	0.0179	0.0233	–	65	–	0.044
E6	DML PLR (S1)	0.0500	-0.0012	0.0127	91	91	93	0.041

Fuente: `notebook4_semisintetico.ipynb` → `R6_simulacion.csv`. 100 réplicas por escenario; N = 2 220.

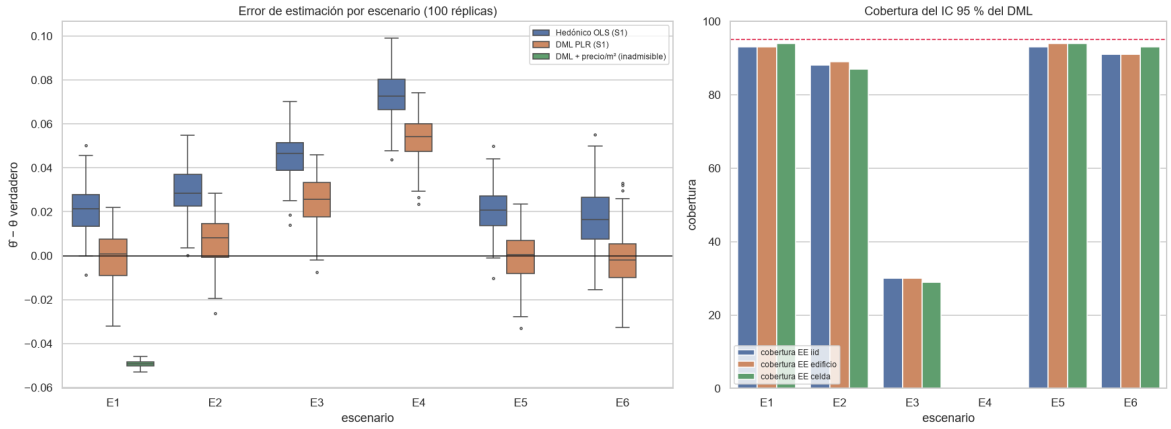


Figura 6.8: Validación semisintética de los baños. Izquierda: error por escenario; derecha: cobertura del IC del DML.

Fuente: `notebook4_semisintetico.ipynb` → `F6_semisintetico.png`.

La tabla 6.17 confirma los resultados del entregable anterior sobre la muestra ROOFTOP:

- **Sin confusión omitida (E1):** el DML es insesgado (-0.001) con una cobertura del 93 %. El hedónico lineal sobreestima en 0.022 y cubre el 50 %, porque no absorbe la confusión no lineal, lo que explica su diferencia con el DML en los datos reales. El control inadmisible lleva el efecto a cero.

- **Con confusión omitida (E2–E4):** el DML se sesga (0.007, 0.025 y 0.054). En este caso la **cota de sensibilidad sí es fiel**: con la fuerza real de U reproduce el sesgo (0.007, 0.023 y 0.050) y el intervalo ampliado cubre el 96, 98 y 95 %.
- **Efecto heterogéneo (E5):** los GATE son insesgados (cobertura del 91–94 %) y la prueba de Wald detecta las diferencias el 49 % de las veces.
- **Dependencia espacial (E6):** la cobertura iid es del 91 %, la agrupada por edificio del 91 % y la agrupada por bloque del 93 %.

6.10. Resultados desfavorables

Por transparencia, se resumen los hallazgos que limitan la conclusión:

(i) Ambos efectos son frágiles frente a un confusor omitido del tamaño de la antigüedad.

(ii) La cota de sensibilidad del estimador binario resultó optimista en la simulación.

(iii) La medición de la cochera no tiene validación humana todavía.

(iv) Restringir a direcciones exactas descarta el 30 % de los avisos, que son más baratos.

(v) En la clase1 no se detecta efecto de la cochera.

Capítulo 7

Discusión

7.1. Interpretación económica

Entre departamentos publicados con dirección exacta y con igual área, dormitorios, baños, antigüedad y ubicación, los que incluyen cochera se ofrecen en promedio un 7.5 % más caros: unos S/ 199 al mes sobre un alquiler de S/ 2 650, con un intervalo de S/ 98 a 303. Es una prima apreciable, pero muy lejana del 63 % de la comparación directa. Casi toda la diferencia bruta se explica porque los departamentos con cochera son más grandes y están en zonas más caras.

El hallazgo más interesante es la **heterogeneidad**. En los distritos de mayor precio (Miraflores, San Isidro, Barranco y Lince), la prima es casi nula (1.5 %), y crece al 10 % y al 18 % en las clases 2 y 3. Una explicación coherente con la teoría hedónica y con el contexto local es la escasez relativa. En Miraflores y San Isidro, la normativa municipal fija un número mínimo de estacionamientos por unidad de vivienda (Municipalidad de Miraflores, 2011; Municipalidad de San Isidro, 2020). En la muestra, la mayoría de los avisos de esos distritos incluye cochera: el 78 % en Miraflores y el 68 % en San Isidro, frente al 15 % en Cercado y el 20 % en San Miguel (figura 6.2). Lince, también en la clase1, es una excepción (41 %). Donde la cochera es parte del estándar de la oferta comparable, no distingue a un aviso de otro y su precio implícito es bajo. Donde es escasa, el mercado la paga. Es una hipótesis explicativa, coherente con los datos, pero no contrastada formalmente aquí.

Tres cautelas: (i) es una prima sobre el precio *de oferta*; (ii) se refiere a la población con soporte común y dirección exacta; y (iii) no es una recomendación de inversión. El efecto no dice si construir o asignar una cochera es rentable, porque no considera su costo.

7.2. Comparación con los antecedentes

Frente al propio avance previo. El análisis exploratorio estimaba, con regresiones lineales por clase de distrito, que un baño adicional se asociaba con S/ 195–298 más de alquiler. El análisis causal sobre direcciones exactas lo reduce a unos S/ 100 (3.8 %). La diferencia se explica por el ajuste flexible de la confusión y por la calidad de la ubicación: con todas las precisiones de geocodificación el efecto sube a 5.1 %. La calidad de la geocodificación cambia el resultado y debe reportarse.

Frente a los estudios peruanos. Los trabajos predictivos (Cacñahuaray y Jiménez, 2024; Barrientos et al., 2026) identifican la cochera entre los determinantes más importantes del precio en Lima, y esta tesis lo confirma: el atributo importa. La diferencia está en qué se mide. Esos modelos cuantifican cuánto ayuda la cochera a *predecir* el precio, una medida que mezcla su efecto con el del tamaño y la zona que la acompañan. Aquí se cuantifica cuánto cambia el precio por la cochera misma, y resulta mucho menos de lo que sugiere la asociación (7.5 % frente a 63 %). La grilla confirma además que la flexibilidad del DML no protege contra los malos controles (Hünermund et al., 2023).

Mundaca y Sánchez (2018) no son comparables en magnitud con esta tesis, aunque coinciden en la dirección. Estudian precios de venta y el número de cocheras, mientras que esta tesis estudia el alquiler y la inclusión o no de la cochera. Ambos estudios coinciden en que la cochera es el atributo con mayor valoración y en que la ubicación es el principal confusor, que ellos señalan como su limitación.

Frente al propio mercado. La comparación más directa en magnitud la ofrece la misma base de datos. Los avisos que cobran la cochera aparte piden una mediana de S/ 250 mensuales (sección 6.2), del mismo orden que el efecto estimado de la cochera incluida (unos S/ 199). Que el efecto sea algo menor es razonable: el inquilino que la paga aparte la eligió porque la necesita.

Frente a la evidencia internacional. Gabbe y Pierce (2017) estiman que la cochera incluida eleva el alquiler en alrededor de 17 % en Estados Unidos. Que en Lima la prima sea menor (7.5 %) es coherente con una tenencia de automóviles mucho más baja, de alrededor del 17 % de los hogares (Lima Cómo Vamos, 2016).

7.3. Por qué el efecto podría estar sesgado

Confusión no observada. Un confusor tan fuerte como la antigüedad llevaría la prima de la cochera a cerca de cero, y la simulación muestra que la cota del estimador binario es optimista. El candidato natural es la *calidad del edificio*: los proyectos de mayor estándar suelen incluir cochera y cobrar más por razones que el área y los baños no capturan del todo. La heterogeneidad atenúa en parte esta preocupación: si la prima fuera solo calidad omitida, cabría esperar que fuera mayor donde los edificios son de mayor estándar, y ocurre lo contrario.

Medición del tratamiento. La clasificación depende del texto, y el 72 % de las descripciones termina con la marca "Leer descripción completa". Un aviso que no menciona su cochera queda como control. Si ese error es no diferencial, atenúa el efecto, y el valor real sería mayor. La especificación estricta (7.9 %) y la que controla por truncamiento (7.4 %) no sugieren un sesgo grande, pero la validación humana pendiente es la prueba que falta.

Selección por precisión de la dirección. Las direcciones exactas son más caras y se concentran en los distritos caros. El efecto estimado no se transporta automáticamente a los avisos con dirección vaga.

7.4. Amenazas a la validez y alcance

Validez interna. Persisten la confusión no observada, el error de medición del tratamiento y la autocorrelación espacial residual del precio. Esta última se trata con inferencia agrupada.

Validez externa. La población es la de los avisos de un portal en 13 distritos, durante un mes y con dirección exacta. No se sabe si la prima de oferta se traslada al precio de contrato.

Validez de la medición con IA. El modelo de lenguaje, con salida estructurada y temperatura 0, distinguió casos que una regex no puede ("no tiene cochera", estacionamiento de visitas, costo aparte), y el piloto permitió corregir el prompt. Sin embargo, la guía metodológica exige una validación humana independiente antes de tratar la medición como confiable. Hasta entonces, los resultados de la cochera son exploratorios.

7.5. Alcance de las aplicaciones

El resultado sirve como referencia cuantitativa, con su incertidumbre y su fragilidad declaradas, para la tasación de alquileres y para entender cómo el mercado valora la cochera según la zona. No justifica afirmar que agregar una cochera elevará la renta en un 7.5 % en cualquier distrito, ni hacer recomendaciones sin considerar costos.

Capítulo 8

Conclusiones y recomendaciones

8.1. Respuesta a la pregunta de investigación

Dentro de la población de avisos de alquiler publicados en 13 distritos de Lima Metropolitana con dirección exacta, y bajo el supuesto de que área, dormitorios, baños, antigüedad y ubicación capturan los factores que determinan a la vez la cochera y el precio, **tener cochera incluida eleva el precio de oferta en 7.5 % (IC 95 %: 3.7–11.4 %)**, unos S/ 199 mensuales sobre un alquiler de S/ 2 650. La prima es casi nula en los distritos más caros y llega al 18 % donde las cocheras son escasas. La estimación es estable ante cambios de estimador, de definición del tratamiento y de partición, y sensible a los errores de especificación que advierte el modelo causal. Su fragilidad es considerable: un factor no observado tan influyente como la antigüedad del edificio bastaría para llevarla cerca de cero.

8.2. Conclusiones por objetivo específico

OE1 (auditoría). De 3 739 avisos se obtuvo una muestra de 2 220, con cada exclusión documentada. La auditoría reveló 243 duplicados (83 de ellos, el mismo aviso registrado en dos distritos), 26 errores de geocodificación y que solo el 70 % de las direcciones se ubicó con exactitud.

OE2 (identificación). El estimando es el ATE en la población con soporte común (propensión entre 0.05 y 0.95). Se identifica por el criterio *back-door* con el conjunto de ajuste del DAG y queda limitado por la calidad no observada, el error de medición y la selección de publicación.

OE3 (estimación). La diferencia bruta del 63 % se reduce a 7.5 % con el DML-IRM; el hedónico (7.8 %) y el PLR (7.1 %) coinciden. La propensión tiene un AUC de 0.82, solo el 5 % de los avisos queda fuera del soporte común y, tras ponderar, todas las diferencias estandarizadas son menores que 0.05. **H1 se confirma.**

OE4 (variación y sensibilidad). Omitir la ubicación triplica el efecto y el precio por m² lo anula; las alternativas de medición lo mantienen entre 5.3 y 7.9 %. **H2 se confirma.** El efecto varía por clase de distrito (1.5 %, 10.3 % y 17.8 %; $p = 0.0001$), así que **H3 se confirma** para la cochera. No se respalda para los baños ni por tamaño. El valor de robustez es 0.105, y un confusor tan fuerte como la antigüedad llevaría el efecto a cerca de cero. **H4 se confirma.**

OE5 (medición con IA). Con un pre-filtro de regex, fragmentos de ±200 caracteres y un modelo de lenguaje con esquema JSON fijo, se clasificaron 2 220 avisos por 0.76 USD. La IA distinguió 297 menciones que no implicaban cochera del departamento y 150 cocheras de costo extra. La validación humana de 249 avisos está preparada y pendiente.

OE6 (validación semisintética). Sin confusión omitida, los estimadores binarios recuperan el efecto (sesgo ≤ 0.004, cobertura del 94–96 %) y el DML de baños también (cobertura del 93 %), mientras que el hedónico lineal de baños se sesga. Con confusión omitida, todos se sesgan. La cota de sensibilidad es fiel para los baños (cobertura del 95–98 %), pero optimista para el estimador binario.

OE7 (trazabilidad). Cada tabla y figura indica su notebook y archivo de origen, las semillas están fijadas y las respuestas de la API quedan en caché. La orden única de ejecución queda pendiente.

8.3. Análisis secundario

Un baño adicional eleva el precio en 3.8 % (1.7–6.0 %), unos S/ 100 mensuales. Controlar por la cochera apenas lo cambia (3.5 %). Con todas las precisiones de geocodificación sería 5.1 %: la ubicación imprecisa inflaba el resultado del entregable anterior.

8.4. Tres tipos de afirmaciones

Hallazgos observacionales. Los avisos con cochera incluida se ofrecen un 63 % más caros y son más grandes y céntricos. El 6.9 % de los avisos con datos completos estaba duplicado y el 30 % tenía dirección imprecisa.

Conclusiones causales condicionadas a los supuestos. Si el DAG es correcto y no hay confusores omitidos de la fuerza de la antigüedad, la cochera incluida eleva el precio de oferta entre 3.7 y 11.4 %, y más donde es escasa.

Hipótesis para trabajos futuros. Que la heterogeneidad responda a la escasez de cocheras en la zona. Que la calidad del edificio explique parte de la prima. Que la prima de oferta se traslade al precio de contrato.

8.5. Límites del trabajo

- La identificación descansa en la ignorabilidad condicional, que solo puede acotarse, no probarse.
- La medición del tratamiento con IA no tiene validación humana todavía.
- Se supone que un aviso que no menciona cochera no la tiene, y gran parte de las descripciones está truncada por el portal.
- La cota de sensibilidad del estimador binario es optimista.
- La muestra es un corte transversal de un portal, de un mes y solo con direcciones exactas.

8.6. Recomendaciones y continuidad

1. **Validar la medición.** Etiquetar a mano los 249 avisos preparados, reportar precisión, *recall* y kappa, y repetir la estimación corrigiendo por error de clasificación.
2. **Medir la calidad del edificio.** Extraer del texto, con el mismo procedimiento, amenidades y acabados (ascensor, piscina, seguridad), y usarlos como *proxies* del confusor principal.
3. **Mejorar la sensibilidad binaria.** Revisar la calibración de la cota con el recorte al soporte común, o usar la implementación de referencia de DoubleML.

4. **Recuperar direcciones imprecisas** volviendo a geocodificarlas con referencias del texto (parques, avenidas).

5. **Reproducibilidad.** Consolidar los notebooks en módulos con pruebas automáticas y una orden única.

Referencias

Advani, A., Kitagawa, T., & Słoczyński, T. (2019). Mostly harmless simulations? Using Monte Carlo studies for estimator selection. *Journal of Applied Econometrics, 34*(6), 893–910. https://doi.org/10.1002/jae.2724

Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized random forests. *The Annals of Statistics, 47*(2), 1148–1178. https://doi.org/10.1214/18-AOS1709

Bach, P., Chernozhukov, V., Kurz, M. S., & Spindler, M. (2022). DoubleML: An object-oriented implementation of double machine learning in Python. *Journal of Machine Learning Research, 23*(53), 1–6. https://www.jmlr.org/papers/v23/21-0862.html

Barrientos, R., Delgado, R., Escalante, L., Febres, G., Hisbes, B., Chavez-Bedoya, L., Rosales, F., & Vargas, W. (2026). Using machine learning to predict apartment prices in Lima. En *Entrepreneurship and human-centric business strategies for social and economic resilience* (pp. 2725–2737). Springer. https://doi.org/10.1007/978-981-95-6415-6_168

Boeing, G., & Waddell, P. (2017). New insights into rental housing markets across the United States: Web scraping and analyzing Craigslist rental listings. *Journal of Planning Education and Research, 37*(4), 457–476. https://doi.org/10.1177/0739456X16664789

Black, S. E. (1999). Do better schools matter? Parental valuation of elementary education. *The Quarterly Journal of Economics, 114*(2), 577–599. https://doi.org/10.1162/003355399556070

Cacñahuaray Huaraca, J. C., & Jiménez Novoa, S. M. (2024). *Modelo predictivo de precios de alquiler de departamentos en la provincia de Lima usando técnicas de machine learning* [Tesis de segunda especialidad, Universidad Peruana Unión]. Repositorio institucional UPeU.

Cameron, A. C., & Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources, 50*(2), 317–372. https://doi.org/10.3368/jhr.50.2.317

Chay, K. Y., & Greenstone, M. (2005). Does air quality matter? Evidence from the housing market. *Journal of Political Economy, 113*(2), 376–424.

https://doi.org/10.1086/427462

Chen, Z., Moeltner, K., & Mair, M. (2026). *Recovering direct price effects of environmental amenities in housing markets: Regression and causal machine learning model assessment with empirical Monte Carlo simulation* (arXiv:2606.02795). arXiv. https://arxiv.org/abs/2606.02795

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal, 21*(1), C1–C68. https://doi.org/10.1111/ectj.12097

Chernozhukov, V., Cinelli, C., Newey, W., Sharma, A., & Syrgkanis, V. (2022). *Long story short: Omitted variable bias in causal machine learning* (NBER Working Paper No. 30302). National Bureau of Economic Research. https://www.nber.org/papers/w30302

Cinelli, C., Forney, A., & Pearl, J. (2024). A crash course in good and bad controls. *Sociological Methods & Research, 53*(3), 1071–1104. https://doi.org/10.1177/00491241221099552

Cinelli, C., & Hazlett, C. (2020). Making sense of sensitivity: Extending omitted variable bias. *Journal of the Royal Statistical Society: Series B, 82*(1), 39–67. https://doi.org/10.1111/rssb.12348

Contreras, C., Aguilar, D., & Lázaro, J. (2024). Impacto del transporte masivo en la informalidad de vivienda: el caso de la Línea 1 del Metro de Lima. *Argumentos, 5*(1). Instituto de Estudios Peruanos. https://doi.org/10.46476/ra.v5i1.183

Egami, N., Hinck, M., Stewart, B. M., & Wei, H. (2023). Using imperfect surrogates for downstream inference: Design-based supervised learning for social science applications of large language models. En *Advances in Neural Information Processing Systems 36* (NeurIPS 2023).

Faxvaag, H., Aarsnes, U., & Oust, A. (2026). Incorporating large language models in automated real estate valuation. *Journal of Real Estate Research, 48*(3), 454–479. https://doi.org/10.1080/08965803.2025.2587313

Gabbe, C. J., & Pierce, G. (2017). Hidden costs and deadweight losses: Bundled parking and residential rents in the metropolitan United States. *Housing Policy Debate, 27*(2), 217–229. https://doi.org/10.1080/10511482.2016.1205647

Gyger, T., Hauri, S., Bühlmann, S., Lehner, M., Schlesinger, J., & Sigrist, F. (2026). Explainable spatial machine learning for hedonic real estate modeling. *Real Estate Economics, 54*(3), 761–806. https://doi.org/10.1111/1540-6229.70030

Hernán, M. A., & Robins, J. M. (2020). *Causal inference: What if*. Chapman & Hall/CRC.

Hünermund, P., Louw, B., & Caspi, I. (2023). Double machine learning and automated confounder selection: A cautionary tale. *Journal of Causal Inference, 11*(1), 20220078. https://doi.org/10.1515/jci-2022-0078

Imbens, G. W., & Rubin, D. B. (2015). *Causal inference for statistics, social, and biomedical sciences: An introduction*. Cambridge University Press.

Keele, L. J., & Titiunik, R. (2015). Geographic boundaries as regression discontinuities. *Political Analysis, 23*(1), 127–155. https://doi.org/10.1093/pan/mpu014

Knaus, M. C., Lechner, M., & Strittmatter, A. (2021). Machine learning estimation of heterogeneous causal effects: Empirical Monte Carlo evidence. *The Econometrics Journal, 24*(1), 134–161. https://doi.org/10.1093/ectj/utaa014

Lima Cómo Vamos. (2016). *Cómo vamos en movilidad: sexto informe de resultados sobre calidad de vida en Lima y Callao 2015*. Lima Cómo Vamos.

Manville, M. (2013). Parking requirements and housing development: Regulation and reform in Los Angeles. *Journal of the American Planning Association, 79*(1), 49–66. https://doi.org/10.1080/01944363.2013.785346

Mayo Urtecho, H. M. (2017). *Elaboración de un índice de precios de viviendas nuevas para Lima Metropolitana mediante precios hedónicos* [Tesis de grado, Universidad Nacional de Ingeniería]. http://hdl.handle.net/20.500.14076/13730

Municipalidad de Miraflores. (2011). *Ordenanza N.° 342/MM: aprueban parámetros urbanísticos y edificatorios y las condiciones generales de edificación en el distrito* (art. 10: número mínimo de estacionamientos por unidad de vivienda; modificada por las Ordenanzas 385-MM y 466-MM).

Municipalidad de San Isidro. (2020). *Ordenanza N.° 523-MSI* (parámetros de estacionamiento para edificaciones multifamiliares).

Malpezzi, S. (2003). Hedonic pricing models: A selective and applied review. En T. O'Sullivan & K. Gibb (Eds.), *Housing economics and public policy* (pp. 67–89). Blackwell.

Moran, P. A. P. (1950). Notes on continuous stochastic phenomena. *Biometrika, 37*(1/2), 17–23. https://doi.org/10.2307/2332142

Mundaca, F., & Sánchez, E. (2018). Índice de precios de inmuebles: un enfoque hedónico. *Revista Estudios Económicos, 36*, 55–74. Banco Central de Reserva del Perú.

Nowak, A., & Smith, P. (2017). Textual analysis in real estate. *Journal of Applied Econometrics, 32*(4), 896–918. https://doi.org/10.1002/jae.2550

Pearl, J. (2009). *Causality: Models, reasoning, and inference* (2.ª ed.). Cambridge University Press.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et

al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rivera Romero, L. A. (2018). *Caso: determinantes del precio por metro cuadrado para departamentos en Lima Metropolitana: período 2005–2017* [Trabajo académico, Universidad de Lima].

Robinson, P. M. (1988). Root-N-consistent semiparametric regression. *Econometrica, 56*(4), 931–954. https://doi.org/10.2307/1912705

Rosen, S. (1974). Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy, 82*(1), 34–55. https://doi.org/10.1086/260169

Shen, L., & Ross, S. (2021). Information value of property description: A machine learning approach. *Journal of Urban Economics, 121*, 103299. https://doi.org/10.1016/j.jue.2020.103299

Sirmans, G. S., Macpherson, D. A., & Zietz, E. N. (2005). The composition of hedonic pricing models. *Journal of Real Estate Literature, 13*(1), 1–44. https://doi.org/10.1080/10835547.2005.12090154

Tapia, J., Chavez-Garzon, N., Pezoa, R., Suarez-Aldunate, P., & Pilleux, M. (2025). Comparing automated valuation models for real estate assessment in the Santiago Metropolitan Region: A study on machine learning algorithms and hedonic pricing with spatial adjustments. *PLOS ONE, 20*(3), e0318701. https://doi.org/10.1371/journal.pone.0318701

Urbania. (2025). *Urbania Index: índice de venta y alquiler, informe de mercado Lima, julio 2025*. https://urbania.pe/blog/urbania-index-lima/

VanderWeele, T. J., & Ding, P. (2017). Sensitivity analysis in observational research: Introducing the E-value. *Annals of Internal Medicine, 167*(4), 268–274. https://doi.org/10.7326/M16-2607

Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association, 113*(523), 1228–1242. https://doi.org/10.1080/01621459.2017.1319839

Apéndice A

Diccionario de variables

Tabla A.1: Variables del archivo crudo y faltantes (N = 3 739)

Variable	Faltantes	% faltante	Descripción
longitud	0	0.0	Longitud geocodificada desde la dirección
descripcion	16	0.4	Texto libre del aviso (solo para deduplicar; no se exporta)
area	160	4.3	Área (m2) declarada en el aviso
banos	30	0.8	Número de baños. Tratamiento T
precio	62	1.7	Precio de oferta mensual (S/). Resultado Y = log(precio)
latitud	0	0.0	Latitud geocodificada desde la dirección
dormitorios	44	1.2	Número de dormitorios
fecha_publicacion	5	0.1	Días desde la publicación del aviso
distrito	2	0.1	Distrito de búsqueda del portal (13 distritos)
antiguedad	1,149	30.7	Años de antigüedad del inmueble
direccion	0	0.0	Dirección (dato sensible; no se exporta)
precision	0	0.0	Precisión de la geocodificación (ROOFTOP, APPROXIMATE, ...)
type	0	0.0	Tipo de lugar devuelto por el geocodificador

Fuente: `notebook2_auditoria.ipynb` → `R1_diccionario.csv`.

Apéndice B

Registro de la búsqueda bibliográfica

Pregunta orientadora (PCC). Población: mercados de vivienda urbana, en especial de alquiler. Concepto: efecto de atributos de la vivienda sobre el precio, estimado con métodos hedónicos, predictivos o causales. Contexto: Perú y comparadores internacionales.

Fuentes. Google Scholar, RePEc/IDEAS, arXiv, NBER, repositorios institucionales peruanos (UPeU, Universidad de Lima, UNALM, ESAN) y publicaciones del BCRP. Los metadatos de las referencias con DOI se verificaron contra Crossref el 21 de octubre de 2026.

Cadenas principales.

- `("doublemachinelearning"OR"causalforest"OR"doublyrobust")AND("housing "OR"rental"OR"realestate"OR"hedonic")`
- `("precioshedónicos"OR"índicedepreciosdeinmuebles")ANDLima`
- `("machinelearning"OR"aprendizajeautomático")AND("alquiler"OR"departa mentos")ANDLima`
- `("omittedvariablebias"OR"sensitivityanalysis")AND("causalmachinelear ning"OR"doublemachinelearning")`

Cadenas adicionales (frente peruano y cochera).

- `"precioalquilerdepartamentosLima"AND("hedónico"OR"machinelearning"O R"estacionamiento"OR"cochera")`

- `("inferenciacausal"OR"diferenciasendiferencias"OR"doublemachinelearning")ANDviviendaAND(LimaORPerú)`
- `("bundledparking"OR"parkingpremium")AND(rentORrental)`
- `("largelanguagemodel"ORGPT)AND("realestate"OR"housing")AND(listingORadvertisement)`
- Normativa: ordenanzas de parámetros urbanísticos de Miraflores y San Isidro (estacionamientos mínimos por unidad de vivienda).

Repositorios peruanos consultados: ALICIA (CONCYTEC), UNI, UPeU, ESAN, Universidad de Lima, Universidad del Pacífico, IEP y BCRP.

Criterios. Inclusión: estudios con datos de vivienda que estimen precios implícitos, predigan precios o identifiquen efectos de atributos o amenidades; y trabajos metodológicos usados directamente en la tesis. Exclusión: estudios sin acceso a los metadatos completos, trabajos duplicados entre versiones (se cita la versión publicada cuando existe) y estudios de valuación comercial sin método documentado.

Tabla B.1: Matriz de extracción resumida de los antecedentes

Trabajo	Resultado / datos	Identificación	Límite respecto de esta tesis
Mundaca y Sánchez (2018)	Precio de venta, Lima 2008–2016	Hedónico (no causal)	Índice de precios; cocheras y baños "muy valorados" sin estrategia causal; ubicación solo por distrito
Mayo (2017)	Venta de vivienda nueva, Lima (Fondo MiVivienda)	Índice hedónico	Objetivo de índice; no estudia atributos ni alquiler
Rivera (2018)	Precio/m², Lima 2005–2017	Regresión de determinantes	Usa una transformación del resultado como variable dependiente
Cacñahuaray y Jiménez (2024)	Alquiler, Lima 2023	Predicción (AutoML)	Cochera entre los predictores más fuertes; no estima efectos
Barrientos et al. (2026)	Venta, Lima (BCRP, 40 000 registros)	Predicción + importancias	Importancias ≠ efectos causales
Contreras et al. (2024)	Informalidad, Lima	Diferencias en diferencias	Causal, pero no estudia precios
Gabbe y Pierce (2017)	Alquiler, EE. UU.	Hedónico	Cochera incluida +17 %; mercado con alta tenencia de autos
Faxvaag et al. (2026)	Avisos, Oslo	LLM + valuación	Extrae el estacionamiento con GPT; objetivo predictivo
Egami et al. (2023)	Metodológico	DSL (doblemente robusto)	Requiere validar las etiquetas de LLM con personas
Tapia et al. (2025)	Venta, Santiago	Valuación automática	Objetivo predictivo
Gyger et al. (2026)	Alquiler, Alemania	Predicción explicable	Modela dependencia espacial, sin identificación causal
Chen et al. (2026)	Venta, Nueva York	DiD y Monte Carlo empírico	Tratamiento distinto (amenidad ambiental)
Sirmans et al. (2005)	Revisión de estudios hedónicos	–	Evidencia de la variabilidad de los coeficientes según la especificación

Apéndice C

Inventario de artefactos y trazabilidad

Artefacto	Contenido
notebooks/notebook0_data_wrangling.ipynb	Construcción del CSV usado por el análisis exploratorio previo
notebooks/notebook1.ipynb	Análisis exploratorio y pruebas de hipótesis asociativas (entregable previo)
notebooks/notebook_causal.ipynb	Primer DML, PC/LiNGAM y refutadores (entregable previo)
notebooks/notebook2_auditoria.ipynb	OE1 · R1: auditoría, deduplicación, exclusiones, agrupamientos, F2
notebooks/notebook2b_extraccion_ia.ipynb	OE5 · R8: extracción de la cochera con regex + OpenAI; muestra de validación
notebooks/notebook3b_efecto_cochera.ipynb	OE2–OE4 · tratamiento principal: R2, R3, R4, R5, R7; F1b, F3, F4c, F5c, F7c
notebooks/notebook3_estimacion_causal.ipynb	Análisis secundario (baños): R3, R4, R5, R7 y dependencia espacial
notebooks/notebook4_semisintetico.ipynb	OE6 · R6: validación semisintética (baños y cochera); F6, F6b
notebooks/causal_utils.py	Funciones compartidas: muestra, DML-PLR agrupado, GATE, sensibilidad, Moran
notebooks/semisintetico.py	Proceso generador y réplicas de la simulación
notebooks/extraccion_ia.py	Regex, fragmentos, enmascarado, prompt, esquema JSON y caché de la API
csv/cochera_llm_cache.jsonl	Respuestas de la API (privado, no se versiona)
csv/validacion_cochera_para_etiquetar.csv	249 avisos para la validación humana (privado)
notebooks/resultados/tablas/*.csv|.tex	Tablas de resultados (una por bloque R1–R7)
notebooks/resultados/figuras/*.png	Figuras F1–F7
notebooks/resultados/resumen_principal.json	Cifras del estimador principal citadas en el texto
informe/tablas_manuscrito.py	Convierte los CSV en las tablas compactas del manuscrito
csv/data_causal_base.csv	Base auditada sin textos ni direcciones (no se publica)

Orden de ejecución. `notebook2` → `notebook2b` → `notebook3b` → `notebook3` → `notebook4` → `informe/tablas_manuscrito.py` → compilación del manuscrito. Todas las semillas están fijadas (`SEED=42`). El `notebook2b` requiere la variable `API_KEY_OPENAI` en el archivo `.env`; si la caché está completa, no realiza llamadas. La automatización en un único comando y la estructura definitiva del repositorio quedan para el siguiente entregable.

Privacidad. Los archivos de datos (`data/`, `csv/`) están excluidos del control de versiones. La base auditada no contiene descripciones, direcciones, teléfonos ni identificadores de anunciantes.

Apéndice D

Versiones de software

Python 3.13.15; pandas 3.0.6; NumPy 2.5.3; scikit-learn 1.9.1 (Pedregosa et al., 2011); SciPy 1.18.1; statsmodels 0.15.0; matplotlib 3.11.2; seaborn 0.13.2; NetworkX 3.7; joblib 1.6.0; nbclient 0.11.0; httpx 0.28.1. Modelo de lenguaje: OpenAI extttgpt-4.1-mini-2025-04-14, temperatura 0, prompt versión v2 (en `extraccion_ia.py`). En el entregable previo se usaron además EconML 0.17.0, DoWhy 0.14 y causal-learn 0.1.4.8. El manuscrito se compiló con Tectonic 0.15.0 (XeTeX).

Apéndice E

Tablas suplementarias

Tabla E.1: Variantes de la muestra analítica

Variante de muestra	N
Principal (dedup + G1 + ROOFTOP + F1-F6)	2,220
Sin deduplicar (G1 + ROOFTOP + F1-F6)	2,366
Dedup + G1 + ROOFTOP + filtro mínimo	2,278
Todas las precisiones de geocodificación (dedup + G1 + F1-F6)	3,028

Fuente: `notebook2_auditoria.ipynb` → `R1_variantes_muestra.csv`.

Tabla E.2: Agrupamientos usados para la partición y la inferencia (muestra principal)

Agrupamiento	N grupos	Tamaño mediano	Tamaño máximo	% avisos en grupos >1
edificio_id	1,948	1.0	7	21.7
celda_1km	177	7.0	97	98.6
distrito	13	137	427	100

Fuente: `notebook2_auditoria.ipynb` → `R1_agrupamientos.csv`.

Tabla E.3: Indicadores de robustez del efecto de un baño adicional

Indicador	Valor
RV ($\theta \to 0$)	0.079
RV_α (límite inferior IC $\to 0$)	0.037
E-value (VanderWeele-Ding, escala d = θ/DE(Y))	1.352

Fuente: `notebook3_estimacion_causal.ipynb`, sección 4 → `R5_robustez.csv`.

Tabla E.4: Indicadores de robustez del efecto de la cochera

Indicador	Valor
RV ($\theta \to 0$)	0.105
RV_α (límite inferior IC $\to 0$)	0.054

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 5 → `R5c_robustez.csv`.