

Universidad Nacional de Ingeniería
Facultad de Ciencias
Escuela Profesional de Ciencia de la Computación

SEMINARIO DE TESIS

Inferencia causal espacial asistida por inteligencia artificial para la valoración contrafactual de atributos residenciales: el efecto de la cochera incluida en el precio de oferta de alquiler de departamentos en Lima Metropolitana

Autor: Luis Angel Azaña Vega
Código: 20212195D
Carrera: Ciencia de la Computación
Asesor: Cesar Jesús Lara Ávila

Octubre, 2026

Resumen

Esta tesis estima el efecto causal de que un departamento en alquiler en Lima Metropolitana incluya cochera sobre su precio de oferta. Los estudios peruanos previos coinciden en que la cochera es un atributo relevante, pero la abordan con modelos asociativos o predictivos. Se auditaron 3 739 avisos de 13 distritos obtenidos por *web scraping* (marzo de 2025): se eliminaron 243 duplicados y se conservaron solo las direcciones geocodificadas con exactitud, con lo que quedaron 2 220 avisos. La cochera se midió desde el texto de cada aviso combinando expresiones regulares y un modelo de lenguaje con salida estructurada, por 0.76 USD. Un grafo causal justifica el ajuste por área, dormitorios, baños, antigüedad y ubicación. El estimador es Double Machine Learning interactivo (AIPW), con *cross-fitting* agrupado por edificio y recorte al soporte común. La diferencia bruta de precios es del 63 %; el efecto estimado es de **7.5 % (IC 95 %: 3.7–11.4 %)**, unos S/ 199 mensuales, del mismo orden que los S/ 250 que piden los avisos que cobran la cochera aparte. El efecto es casi nulo en los distritos donde la normativa exige estacionamientos y la cochera es habitual (1.5 %), y mayor donde escasea (10–18 %; $p < 0.001$). Un baño adicional eleva el precio en 3.8 %. Ambos resultados son moderadamente frágiles: un confusor omitido tan fuerte como la antigüedad los llevaría cerca de cero. Una validación semisintética confirma que los estimadores recuperan el efecto sin confusión omitida y que la cota de sensibilidad binaria es optimista. Los resultados son causales solo bajo los supuestos declarados y exploratorios hasta validar la medición con etiquetas humanas.

Palabras clave: inferencia causal; Double Machine Learning; precios hedónicos; alquiler; cochera; modelos de lenguaje; análisis de sensibilidad; Lima.

Abstract

This thesis estimates the causal effect of an included parking space on the asking rent of apartments in Metropolitan Lima. Previous Peruvian studies agree that parking is a relevant attribute but rely on associative or predictive models. We audited 3,739 web-scraped listings from 13 districts (March 2025), removed 243 duplicates and kept only exactly geocoded addresses, leaving 2,220 listings. Parking was measured from each listing's text with regular expressions and a language model with structured output, at a cost of USD 0.76. A causal graph justifies adjusting for floor area, bedrooms, bathrooms, building age and location. The estimator is an interactive Double Machine Learning model (AIPW) with building-grouped cross-fitting and trimming to common support. The raw price gap is 63 %; the estimated effect is **7.5 % (95 % CI: 3.7–11.4 %)**, about PEN 199 per month, of the same order as the PEN 250 asked by listings that charge for parking separately. The effect is almost zero in districts where regulations require parking and it is common (1.5 %), and larger where it is scarce (10–18 %; $p < 0.001$). An additional bathroom raises rent by 3.8 %. Both results are moderately fragile: an omitted confounder as strong as building age would bring them close to zero. A semi-synthetic validation confirms that the estimators recover the effect without omitted confounding and that the binary sensitivity bound is optimistic. The findings are causal only under the stated assumptions and exploratory until the measurement is validated against human labels.

Keywords: causal inference; double machine learning; hedonic pricing; rental housing; parking; large language models; sensitivity analysis; Lima.

Índice general

Resumen I

Abstract II

1. Introducción **1**

1.1. Contexto y problema 1

1.2. Justificación científica 2

1.3. Pregunta de investigación 3

1.4. Objetivos 3

1.5. Hipótesis 3

1.6. Alcance 4

2. Revisión de antecedentes teóricos y experimentales **5**

2.1. Antecedentes teóricos 5

2.2. Antecedentes experimentales 6

2.3. Síntesis y vacío 8

3. Fundamentos y modelo causal **9**

3.1. Estimando 9

3.2. Supuestos 9

3.3. Grafo causal y conjunto de ajuste 10

4. Datos y metodología **12**

4.1. Datos y auditoría 12

4.2. Medición de la cochera con IA 13

4.3. Estimador: Double ML interactivo 13

4.4. Heterogeneidad, sensibilidad y dependencia 14

5. Diseño experimental y validación **15**

6. Resultados **17**

6.1. Población y muestra (R1) 17

6.2. Medición de la cochera con IA (R8) 18

6.3. Análisis exploratorio: con y sin cochera 19

6.4. Soporte común y balance (R2) 20

6.5. Efecto de la cochera incluida (R3) 21

6.6. Grilla de especificaciones (R4) 21

6.7. Robustez a confusores no observados (R5) 22

6.8. Heterogeneidad y dependencia espacial (R7) 22

6.9. Análisis secundario: un baño adicional 23

6.10. Validación semisintética (R6) 24

7. Discusión **25**

7.1. Interpretación 25

7.2. Contraste con los antecedentes 25

7.3. Amenazas a la validez 26

8. Conclusiones y recomendaciones **27**

8.1. Respuesta a la pregunta 27

8.2. Conclusiones por objetivo 28

8.3. Límites del trabajo 28

8.4. Recomendaciones 29

Referencias **30**

A. Correspondencia con la rúbrica de evaluación **34**

B. Registro de la búsqueda bibliográfica **35**

C. Reproducibilidad y trazabilidad **36**

Capítulo 1

Introducción

1.1. Contexto y problema

El alquiler es una vía de acceso a la vivienda cada vez más importante en Lima Metropolitana, y la oferta de departamentos se publica sobre todo en portales inmobiliarios. Cada aviso informa el precio pedido, algunos atributos estructurados (área, dormitorios, baños, antigüedad, ubicación) y una descripción libre donde aparecen otros, como la cochera. Los estudios peruanos coinciden en que la cochera es uno de los atributos más relevantes del precio (capítulo 2). Sin embargo, la abordan con modelos asociativos o predictivos, que no responden la pregunta contrafactual: *¿cuánto cambiaría el precio de un departamento si incluyera cochera, sin cambiar nada más?*

La respuesta no puede leerse en una comparación directa. En los datos de esta tesis, los avisos con cochera incluida se ofrecen un 63 % más caros, pero también son más grandes (96 frente a 65 m^2), tienen más baños y se concentran en los distritos más caros. A esto se suman tres dificultades:

(i) la cochera no es un campo de la base y hay que medirla desde el texto;

(ii) la ubicación, el confusor más importante, solo es confiable cuando la dirección se geocodifica con exactitud;

(iii) atributos no observados, como la calidad del edificio, pueden influir a la vez en la cochera y en el precio.

Punto de partida. La tesis parte de un análisis exploratorio propio sobre los mismos avisos (`notebook0` y `notebook1`). Ese trabajo describió el mercado y contrastó ocho aseveraciones con pruebas estadísticas. La octava ya planteaba una pregunta causal: controlando el área, una regresión lineal asociaba cada baño adicional con S/ 195–298 más. Sus límites motivan este trabajo:

- eran asociaciones, no efectos;
- los controles se eligieron sin un modelo causal;
- no se detectaban duplicados ni errores de ubicación;
- no podía estudiar la cochera.

Por indicación del asesor, el estudio se reformuló con un tratamiento binario, la cochera incluida. Los baños se conservan como análisis secundario.

1.2. Justificación científica

Vacío de conocimiento. En las fuentes revisadas no se encontró un estudio que estime *causalmente* el valor de un atributo en el mercado de alquiler de Lima, ni que mida la fragilidad de esa estimación frente a confusores no observados.

Justificación teórica. El precio implícito hedónico (Rosen, 1974) depende de la especificación (Sirmans et al., 2005). El marco de resultados potenciales y los grafos causales (Pearl, 2009; Imbens y Rubin, 2015) permiten definir qué se estima y qué controlar.

Justificación metodológica. La tesis integra tres piezas, cuya combinación no se encontró en el contexto peruano:

(I) aprendizaje automático causal doblemente robusto con inferencia espacial (Chernozhukov et al., 2018);

(II) medición de un atributo desde el texto con un modelo de lenguaje, de bajo costo y trazable (Faxvaag et al., 2026), con las precauciones que exige su uso inferencial (Egami et al., 2023);

(III) validación con datos semisintéticos (Advani et al., 2019).

Desde la Ciencia de la Computación, el aporte es un *pipeline* reproducible que va del *web scraping* al efecto causal con su incertidumbre.

Justificación práctica. Saber cuánto vale realmente la cochera, y dónde, informa la tasación de alquileres. También aporta evidencia a la discusión sobre los mínimos de estacionamiento que fijan las normas municipales (Municipalidad de Miraflores, 2011; Municipalidad de San Isidro, 2020).

1.3. Pregunta de investigación

¿En qué medida un diseño de aprendizaje causal con ajuste espacial y medición de atributos asistida por IA permite estimar, entre avisos comparables, la prima sobre el precio de oferta de alquiler asociada a que el departamento incluya cochera, y cuán estable es esa estimación frente a confusión no observada y a las decisiones de modelado?

1.4. Objetivos

Objetivo general. Estimar y evaluar la robustez del efecto causal de que un departamento incluya cochera sobre su precio de oferta de alquiler en Lima Metropolitana.

Objetivos específicos.

OE1. Auditar, depurar y caracterizar los avisos (duplicados, precisión de la geocodificación, exclusiones, perfil territorial).

OE2. Definir la intervención y justificar su identificación (estimando, DAG, conjunto de ajuste, soporte común).

OE3. Estimar el efecto y compararlo con la asociación hedónica, con IC 95 % y diagnósticos.

OE4. Evaluar la heterogeneidad y la sensibilidad (grilla de especificaciones, confusión no observada, dependencia espacial).

OE5. Medir el tratamiento desde el texto con IA y preparar su validación humana.

OE6. Verificar los estimadores con una verdad conocida (validación semisintética).

OE7. Garantizar la trazabilidad de cada tabla y figura hasta su notebook.

1.5. Hipótesis

Hipótesis general. Entre departamentos equivalentes en área, distribución, antigüedad y ubicación, incluir cochera modifica el precio de oferta en una magnitud estimable con aprendizaje causal y menor que la diferencia bruta. Las hipótesis específicas no exigen por anticipado un efecto significativo ni positivo, y cada una tiene un criterio de decisión fijado antes de estimar (tabla 1.1).

Tabla 1.1: Hipótesis específicas, prueba y criterio de decisión

Hipótesis	Prueba y criterio	OE
H1. La asociación inicial cambia tras el ajuste.	Diferencia bruta frente a DML-IRM; se confirma si el IC ajustado excluye la diferencia bruta.	3
H2. Los controles importan más que el algoritmo.	Rango de la grilla de especificaciones frente al de los estimadores ajustados.	3, 4
H3. El efecto varía por zona o tamaño.	GATE preespecificados; se confirma solo si la prueba de Wald da $p < 0.05$.	4
H4. La conclusión depende de confusores no observados.	Valor de robustez y benchmarks; se confirma si un confusor como uno observado anula el efecto.	4, 6

1.6. Alcance

El objeto son los precios *de oferta* mensuales de departamentos publicados en un portal en marzo de 2025, en 13 distritos de Lima y con dirección geocodificada con exactitud. No se trata de contratos ni de todo el parque residencial. La unidad de análisis es el aviso, con un manejo explícito de duplicados y de la agrupación por edificio. Las limitaciones se detallan en la sección 8.3.

Capítulo 2

Revisión de antecedentes teóricos y experimentales

Se trata de una revisión focalizada y documentada, no de una revisión sistemática. Las cadenas de búsqueda y las fuentes están en el anexo B. Las afirmaciones de originalidad se limitan a las fuentes consultadas.

2.1. Antecedentes teóricos

Precios hedónicos. Según Rosen (1974), el precio de un bien diferenciado depende de sus atributos, y la derivada respecto de un atributo es su precio implícito. Es la herramienta estándar para valorar atributos de la vivienda (Malpezzi, 2003). Sin embargo, Sirmans et al. (2005) muestran que el coeficiente de un mismo atributo varía mucho según qué se controle: un precio implícito es *condicional a la especificación*, no un efecto.

Inferencia causal. El marco de resultados potenciales (Imbens y Rubin, 2015; Hernán y Robins, 2020) define el efecto como la diferencia entre los precios que tendría el mismo departamento con y sin el atributo, de los cuales solo uno se observa. El criterio *back-door* (Pearl, 2009) indica qué variables ajustar, y Cinelli et al. (2024) cuáles *no*: mediadores, colisionadores y descendientes del resultado. Sin una fuente de variación casi aleatoria, como las discontinuidades en fronteras (Black, 1999; Keele y Titiunik, 2015) o los cambios regulatorios (Chay y Greenstone, 2005), se ajusta por los confusores observados bajo ignorabilidad condicional.

Double Machine Learning. Chernozhukov et al. (2018) muestran que, si las funciones auxiliares se estiman con aprendizaje automático, se usa un score ortogonal y se

aplica *cross-fitting*, el efecto es consistente y admite inferencia válida. Para tratamientos binarios, la versión interactiva (IRM/AIPW) es doblemente robusta. El modelo parcialmente lineal proviene de Robinson (1988) y está implementado en DoubleML (Bach et al., 2022). El marco es sensible a los malos controles (Hünermund et al., 2023), y los efectos heterogéneos (Wager y Athey, 2018; Athey et al., 2019) son frágiles en muestras moderadas (Knaus et al., 2021).

Robustez. Cinelli y Hazlett (2020) y Chernozhukov et al. (2022) acotan el sesgo por confusores omitidos y lo calibran con confusores observados; VanderWeele y Ding (2017) proponen el *E-value*. Moran (1950) y Cameron y Miller (2015) aportan las herramientas de dependencia espacial e inferencia agrupada. Advani et al. (2019) recomiendan validar los estimadores con simulaciones ancladas en los datos reales.

Medición con modelos de lenguaje. Egami et al. (2023) demuestran que usar etiquetas de un modelo de lenguaje directamente en un análisis estadístico produce sesgo e intervalos inválidos, incluso con un 80–90 % de acierto. Proponen combinarlas con una muestra etiquetada por personas mediante un estimador doblemente robusto, lo que justifica la validación humana de esta tesis.

2.2. Antecedentes experimentales

Estudios peruanos.

- **Índices hedónicos de venta.** Mundaca y Sánchez (2018) (BCRP; unos 30 000 avisos de venta, 2008–2016) encuentran que el número de cocheras y el de baños son lo más valorado por unidad. Reportan variables omitidas y un control de ubicación limitado al distrito. Mayo (2017) (UNI) y Rivera (2018) construyen índices y determinantes del precio de venta con modelos lineales.
- **Aprendizaje automático predictivo.** Cacñahuaray y Jiménez (2024) predicen el alquiler en Lima (3 675 avisos de 2023) y hallan el área y las cocheras entre los predictores más importantes. Barrientos et al. (2026) identifican tamaño, cochera y ubicación como determinantes principales con XGBoost. Ninguno estima cuánto cambia el precio por la cochera.
- **Causalidad.** El único antecedente causal sobre vivienda en Lima que se encontró es Contreras et al. (2024), que estiman el efecto de la Línea 1 del Metro sobre la informalidad con diferencias en diferencias.

El valor de la cochera. En alquileres de Estados Unidos, la cochera incluida eleva la renta en alrededor de 17 % (Gabbe y Pierce, 2017) o unos 200 dólares mensuales (Manville, 2013). Son mercados con mucha más tenencia de auto, útiles para contrastar la dirección, no las cifras. En Lima hay tres hechos relevantes:

- las ordenanzas de Miraflores y San Isidro exigen un número mínimo de estacionamientos por vivienda (Municipalidad de Miraflores, 2011; Municipalidad de San Isidro, 2020);
- el índice de referencia del mercado de alquiler toma como unidad típica un departamento *con* estacionamiento (Urbania, 2025);
- solo alrededor del 17 % de los hogares de Lima y Callao tenía automóvil en 2015 (Lima Cómo Vamos, 2016).

Todo ello sugiere una prima menor que en Estados Unidos y distinta según la zona.

Aprendizaje automático y avisos. Tapia et al. (2025) y Gyger et al. (2026) usan el ML para valuar inmuebles. Las importancias de variables describen la predicción, no el efecto de intervenir. Chen et al. (2026) comparan hedónico y ML causal con simulaciones ancladas en datos reales. Boeing y Waddell (2017) muestran el valor y los riesgos de los avisos obtenidos por *scraping*. Nowak y Smith (2017) y Shen y Ross (2021), que el texto contiene información de precio que no está en los campos estructurados. Faxvaag et al. (2026) extraen el estacionamiento de avisos con GPT, el precedente más cercano a la medición de esta tesis.

2.3. Síntesis y vacío

Tabla 2.1: Cuadro comparativo de antecedentes

Trabajo	Objeto / datos	Aporte y límite	Método
Mundaca y Sánchez (2018)	Venta, Lima	Cochera y baños, lo más valorado; asociativo	Hedónico
Cacñahuaray y Jiménez (2024)	Alquiler, Lima	Cochera, predictor fuerte; no estima efecto	ML predictivo
Barrientos et al. (2026)	Venta, Lima	Cochera, determinante clave; predictivo	XGBoost
Contreras et al. (2024)	Informalidad, Lima	Único causal local; no estudia precios	DiD
Gabbe y Pierce (2017)	Alquiler, EE. UU.	Cochera incluida +17 %; otro mercado	Hedónico
Faxvaag et al. (2026)	Avisos, Oslo	Estacionamiento extraído con GPT; predictivo	LLM
Esta tesis	**Alquiler, Lima**	**Efecto causal de la cochera medida con IA**	**DML-IRM**

En síntesis, la literatura peruana confirma que la cochera es relevante, y la literatura teórica ofrece las herramientas para estimar su efecto causal, acotar su fragilidad y medirla con IA. En las fuentes consultadas no se encontró un estudio sobre Lima que combine estimar causalmente el valor de un atributo del alquiler, medirlo desde el texto con IA y acotar la fragilidad del resultado.

Capítulo 3

Fundamentos y modelo causal

3.1. Estimando

Sea $D_i = 1$ si el departamento i incluye cochera en el alquiler y $D_i = 0$ si no tiene cochera, y sea $Y_i = \ln P_i$ el logaritmo natural del precio mensual de oferta. El logaritmo hace que las diferencias se lean como porcentajes, porque $\ln a - \ln b = \ln(a/b)$, y reduce el peso de los alquileres extremos. $Y_i(1)$ e $Y_i(0)$ son los precios potenciales del mismo departamento con y sin cochera; solo uno se observa. El estimando principal es el efecto promedio en la población con soporte común:

$$\theta = E\big[\, Y(1) - Y(0) \;\big|\; 0.05 \le m(X) \le 0.95 \,\big], \qquad m(X) = P(D = 1 \mid X). \tag{3.1}$$

El efecto en porcentaje es $100\,(e^{\theta} - 1)$; en soles se reporta para un alquiler de referencia de S/ 2 650, la mediana de la muestra. Para el análisis secundario (baños, un conteo) se usa el modelo parcialmente lineal $Y = \theta_T\, T + g(X) + \varepsilon$ (Robinson, 1988).

3.2. Supuestos

1. **Ignorabilidad condicional.** Entre departamentos iguales en X, tener cochera no depende del precio potencial. Se viola si existe un confusor omitido, como la calidad del edificio.
2. **Positividad.** Hay departamentos con y sin cochera para cada perfil; se impone con el recorte $[0.05, 0.95]$.
3. **Consistencia.** "Cochera incluida" agrupa una o más cocheras. Las de costo extra son otra versión del tratamiento y se excluyen.
4. **Medición.** D se lee del texto, y un aviso que no menciona cochera se considera sin

cochera.

5. **No interferencia.** La cochera de un departamento no afecta el precio de otro. Los choques comunes de edificio se tratan con inferencia agrupada.

3.3. Grafo causal y conjunto de ajuste

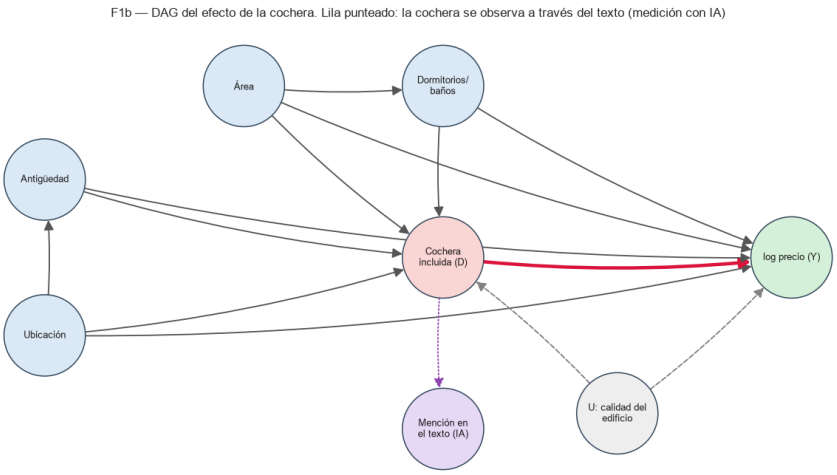


Figura 3.1: DAG del efecto de la cochera. Azul: confusores ajustados; gris punteado: confusor no observado U; lila: la cochera se observa a través del texto.

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 1.

El DAG (figura 3.1) se construyó con conocimiento del dominio y el orden temporal: la ubicación y la antigüedad del edificio preceden al diseño, y el área, la distribución y la dotación de cocheras se definen en el proyecto. Por el criterio *back-door* (Pearl, 2009), el conjunto de ajuste es el de la tabla 3.1. El camino $D \leftarrow U \rightarrow Y$ no puede bloquearse; es la amenaza principal.

Tabla 3.1: Papel de cada variable respecto del efecto de la cochera

Variable	Papel	¿Ajustar?	Razón
Ubicación (distrito, lat., lon.)	Confusor	Sí	Define la escasez de cocheras y el precio
Área, baños, dormitorios	Confusores	Sí	Reflejan el estándar del proyecto
Antigüedad (+ indicador de faltante)	Confusor	Sí	Época de construcción
Días publicado, tipo de geocodificación	Previas / artefacto	Sí	Diferencias del aviso y de medición
Precio por m²	Descendiente de Y	**No**	Es el resultado dividido por el área
Calidad del edificio	Confusor no observado	Imposible	Se acota con sensibilidad

Amenazas a la validez. Las principales son:

(i) la calidad del edificio, no observada;

(ii) el error de medición del texto, incluidas descripciones truncadas por el portal;

(iii) los duplicados;

(iv) las reglas de depuración que usan el precio;

(v) la extrapolación fuera del soporte común;

(vi) la selección: solo se observan avisos publicados con dirección exacta.

Cada una se aborda con una especificación alternativa (capítulo 5). Los resultados valen para esa población, no para los contratos ni para todo el parque residencial.

Capítulo 4

Datos y metodología

4.1. Datos y auditoría

Los datos provienen del *web scraping* de un portal inmobiliario peruano (marzo de 2025): 3 739 avisos de alquiler de departamentos en 13 distritos, geocodificados con la API de Google. Junto con las coordenadas, la API devuelve su precisión:

- `ROOFTOP`: el edificio exacto;
- `RANGE_INTERPOLATED`: una posición interpolada en la cuadra;
- `GEOMETRIC_CENTER`: el centro de una calle;
- `APPROXIMATE`: el centro de la zona.

La auditoría (`notebook2_auditoria`) aplica, en orden:

1. exclusión de avisos sin dormitorios, baños, área, precio o distrito;
2. **deduplicación**: re-publicaciones (mismo texto y atributos; la mitad era el mismo aviso bajo dos distritos) y publicaciones cruzadas (mismas coordenadas, atributos y precio con texto distinto);
3. **geocodificación incoherente**: más de 8 km de la mediana de su distrito;
4. **solo direcciones exactas (ROOFTOP)**, porque la ubicación es el confusor más importante;
5. las reglas de depuración del avance previo (rangos, combinaciones raras, atípicos de precio por m^2).

Se crean dos agrupamientos para la inferencia: el **edificio** (mismas coordenadas) y el **bloque espacial** de 1 km. La descripción y la dirección no se exportan.

4.2. Medición de la cochera con IA

La cochera no es un campo de la base. El procedimiento, implementado en `notebo ok2b_extraccion_ia` y `extraccion_ia.py`, minimiza el costo:

1. una **regex** busca *cochera, estacionamiento, parqueo, parking, garaje* y sus variantes; sin mención, el aviso se clasifica como *sin cochera* y no se llama a la API;
2. se envía solo el **fragmento** `texto[x-200 : x+200]` alrededor de cada mención, con teléfonos y correos enmascarados;
3. el modelo `gpt-4.1-mini-2025-04-14`, con temperatura 0, responde un **JSON de esquema fijo** (`cochera`, `tipo`, `precio_extra`, `incluida_explicita`, `num_cocheras`, `motivo`); un piloto de 25 avisos permitió corregir el prompt;
4. las respuestas se guardan en una **caché**, de modo que reejecutar no cuesta.

Supuestos: sin mención equivale a sin cochera, y con cochera sin pago adicional equivale a incluida. **Tratamiento:** $D = 1$ si está incluida y $D = 0$ si no tiene; se excluyen las de costo extra y las ambiguas. Se preparó una muestra de 249 avisos para validación humana, que está pendiente.

4.3. Estimador: Double ML interactivo

Se usan tres modelos de *histogram gradient boosting* (300 iteraciones, profundidad 4, mínimo de 20 observaciones por hoja), todos con *cross-fitting* de 5 folds **agrupados por edificio**: cada aviso se predice con modelos que no vieron ni ese aviso ni su edificio.

- **Modelo 1, propensión** $\hat{m}(X)$. Es un clasificador que da a cada departamento su probabilidad de tener cochera. Sirve para descartar a quienes no tienen comparables ($\hat{m} < 0.05$ o $\hat{m} > 0.95$) y para ponderar: un caso poco frecuente en su perfil representa a $1/\hat{m}$ departamentos.
- **Modelos 2 y 3, precio** $\hat{g}_1(X)$ y $\hat{g}_0(X)$. Se entrenan con los departamentos con y sin cochera, respectivamente, pero predicen *todos*. Así, cada departamento obtiene su precio estimado con y sin cochera, incluido el contrafactual que no se observa.

Para cada aviso en soporte común se calcula el score doblemente robusto, y el efecto es su promedio:

$$\phi_i = \hat{g}_1(X_i) - \hat{g}_0(X_i) + \frac{D_i\,(Y_i - \hat{g}_1(X_i))}{\hat{m}(X_i)} - \frac{(1 - D_i)\,(Y_i - \hat{g}_0(X_i))}{1 - \hat{m}(X_i)}, \tag{4.1}$$

$$\hat{\theta} = \frac{1}{n} \sum_i \phi_i.$$

El primer término es la diferencia predicha. Los otros dos corrigen el error del modelo de precio en la versión observada, ponderado por la propensión. Si el modelo de precio o el de propensión es correcto, el estimador es consistente (*doble robustez*). Se repite con 10 particiones y se reporta la mediana. Los errores estándar se agrupan por edificio, y como alternativa por bloque de 1 km. Los baños se estiman con el modelo parcialmente lineal (dos modelos y regresión de residuos).

4.4. Heterogeneidad, sensibilidad y dependencia

Efectos por grupo. Los GATE son el promedio de ϕ_i por clase de distrito (clase1: Miraflores, San Isidro, Barranco y Lince; clase2: Magdalena, Surquillo, Jesús María, San Borja y Surco; clase3: Cercado, San Miguel, Chorrillos y La Molina) y por quintil de área. La igualdad entre grupos se contrasta con una prueba de Wald.

Sensibilidad. Para un confusor omitido U con fuerzas C_Y^2 (sobre el precio) y C_D^2 (sobre el tratamiento), el sesgo queda acotado por (Chernozhukov et al., 2022)

$$|\hat{\theta} - \theta| \leq \sqrt{\frac{C_Y^2 \, C_D^2}{1 - C_D^2}} \, \sqrt{\sigma^2 \nu^2}, \tag{4.2}$$

donde σ^2 es la varianza del error del precio y ν^2 el segundo momento de los pesos. Se reportan el valor de robustez (RV: la fuerza común que anula el efecto) y benchmarks que comparan con la fuerza de los confusores observados.

Dependencia espacial. Se calcula el I de Moran de los residuos (Moran, 1950).

Capítulo 5

Diseño experimental y validación

Las decisiones siguientes se fijaron antes de estimar, en el protocolo de `notebook3b_efecto_cochera`, y no se cambiaron en función de los resultados.

Comparadores. Diferencia sin ajustar, hedónico OLS, DML parcialmente lineal y DML-IRM, este último sin recorte y con soporte común (principal). Los modelos auxiliares se evalúan fuera de fold: AUC, log-loss y Brier para la propensión, y R^2 para el precio. El balance se mide con diferencias de medias estandarizadas.

Grilla de especificaciones. Cada especificación cambia una sola decisión respecto de la principal (C1):

- **confusores omitidos:** sin área (C2), sin ubicación (C3), sin baños ni dormitorios (C4), sin antigüedad (C5);
- **control inadmisible:** precio por m² (C6);
- **medición:** solo inclusión explícita (C7), cocheras de costo extra como tratadas (C8), indicador de descripción truncada (C9);
- **partición:** folds por bloque de 1 km (P1).

Para los baños, la grilla incluye además la cochera como control (S8) y la muestra con todas las precisiones de geocodificación (D3).

Criterio de robustez. El resultado es *robusto* si un confusor omitido tan fuerte como el más fuerte de los observados no lo anula, y *frágil* en caso contrario.

Validación semisintética. En `notebook4_semisintetico` se conservan las covariables reales y se simulan el tratamiento y el precio con un efecto conocido:

- **tratamiento binario**, con $P(D = 1 \mid X, U) = \text{logit}^{-1}(\text{logit}\, m_0(X) + aU)$ y $Y = g_0(X) + 0.10\, D + b\sigma U +$ ruido: sin confusor (B1) y con confusor moderado (B2);
- **baños**, con efecto 0.05: sin confusor (E1), con confusor débil, moderado o fuerte (E2–E4), heterogéneo (E5) y con dependencia espacial (E6).

Con 100 réplicas por escenario (800 en total) se miden el sesgo, el RMSE, la cobertura del IC 95 % y si la cota (4.2) contiene el valor verdadero. La simulación no prueba que el efecto real sea causal; muestra cuándo funcionan los estimadores y cuándo fallan.

Capítulo 6

Resultados

Las cifras provienen de la ejecución final de los notebooks (anexo C). La tabla 6.1 resume los resultados por objetivo.

Tabla 6.1: Resumen de resultados por objetivo específico

Objetivo	Resultado	Sección
OE1 Auditoría	3 739 → 2 220 avisos; 243 duplicados; 30 % de direcciones imprecisas	6.1
OE5 Medición con IA	1 095 con cochera incluida y 956 sin cochera; 0.76 USD	6.2
Caracterización	Sin ajustar, con cochera: precio +46 %, área +48 %	6.3
OE2–3 Soporte y efecto	95 % en soporte común; **+7.5 % (3.7–11.4 %), ≈ S/ 199**	6.4, 6.5
OE4 Grilla	Sin ubicación 21.7 %; con precio/m² −0.5 %; alternativas 5.3–7.9 %	6.6
OE4 Sensibilidad	RV = 0.105; un confusor como la antigüedad lo lleva a 0.4 %	6.7
OE4 Heterogeneidad	1.5 / 10.3 / 17.8 % por clase de distrito; $p = 0.0001$	6.8
Secundario	Un baño adicional: +3.8 % (1.7–6.0 %)	6.9
OE6 Validación	Sin confusor omitido: cobertura 94–96 %; cota binaria optimista	6.10

6.1. Población y muestra (R1)

La muestra conserva 2 220 de los 3 739 avisos (tabla 6.2). Se eliminaron 243 duplicados: en 83 casos, el mismo aviso aparecía bajo dos distritos. También se excluyeron 26 coordenadas a más de 8 km de su distrito. La mayor exclusión es la de direcciones

no exactas: 967 avisos (30 %), de los cuales 626 eran `APPROXIMATE`. Dentro de la muestra ROOFTOP, las reglas de depuración solo excluyen 60 avisos, porque los atípicos se concentraban en las direcciones imprecisas. La muestra abarca 1 948 edificios y 177 bloques de 1 km, y la antigüedad falta en el 9.2 % de los avisos.

Tabla 6.2: Flujo de exclusiones de la muestra (R1)

Paso	N restante	Excluidos	% del crudo
Archivo crudo del scraping	3,739	0	100
Sin dormitorios/baños/área/precio/distrito	3,516	223	94.0
Duplicados D1 (re-publicación)	3,350	166	89.6
Duplicados D2 (publicación cruzada)	3,273	77	87.5
G1 geocodificación incoherente (>8 km del distrito)	3,247	26	86.8
G2 geocodificación no exacta (distinta de ROOFTOP)	2,280	967	61.0
F1 rangos (dorm>6, área>600, precio/m2 fuera de [8,120])	2,263	17	60.5
F2 área incoherente (<=2 dorm, 1 baño, >=160 m2)	2,262	1	60.5
F4 precio < 600	2,254	8	60.3
F5 combinación dorm-baños rara (<=3 casos)	2,244	10	60.0
F6 precio/m2 atípico en su distrito	2,220	24	59.4

Fuente: `notebook2_auditoria.ipynb` → `R1_exclusiones.csv`.

6.2. Medición de la cochera con IA (R8)

La extracción, que costó 0.76 USD, dio el resultado de la tabla 6.3:

- **sin mención (659 avisos):** se clasificaron sin llamar a la API;
- **enviados a la API (1 561 avisos):** como fragmentos de unos 458 caracteres, frente a 1 012 de la descripción completa;
- **“no tiene” (297 avisos):** la IA reconoció casos que una regex no distingue, como “no tiene cochera” o el estacionamiento de visitas;
- **costo extra (150 avisos):** 110 indican un monto;
- **inclusión explícita:** solo 155 avisos dicen literalmente “incluida”, así que el supuesto “sin pago adicional equivale a incluida” es necesario.

Tabla 6.3: Clasificación de la cochera y uso en el análisis (R8)

Clasificación	N	%	Uso en el análisis
Ambigua	19	0.9	excluido
Cochera con costo extra	150	6.8	excluido
Cochera incluida	1,095	49.3	T = 1
No tiene (según la IA)	297	13.4	T = 0
Sin mención (no se envía a la API)	659	29.7	T = 0

Fuente: `notebook2b_extraccion_ia.ipynb` → `R8_distribucion.csv`.

6.3. Análisis exploratorio: con y sin cochera

El alquiler mediano es de S/ 2 625 y el área mediana de 78 m². Sin ajustar, los avisos con cochera incluida tienen un alquiler mediano un 46 % mayor (S/ 3 200 frente a S/ 2 198), pero también son un 48 % más grandes (96 frente a 65 m²), tienen medio baño más y están con más frecuencia en la clase1 (56 % frente a 32 %). La antigüedad es parecida (figura 6.1). Esa diferencia bruta mezcla la cochera con el tamaño y la zona: es lo que el análisis causal debe separar.

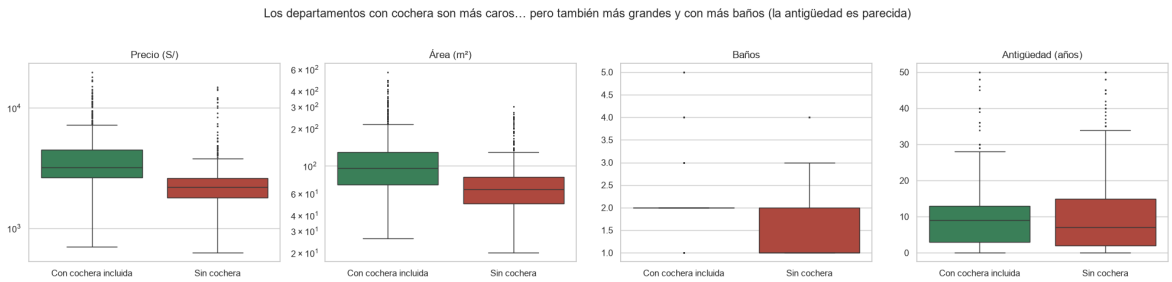


Figura 6.1: Precio, área, baños y antigüedad de los avisos con y sin cochera incluida.
Fuente: `notebook_resumen.ipynb`, sección 2.2.

La cochera está repartida de forma muy desigual (figura 6.2): la incluye el 78 % de los avisos de Miraflores y el 68 % de los de San Isidro y Surco, frente al 20 % en San Miguel y el 15 % en Cercado. En los avisos que la cobran aparte, la mediana pedida es de **S/ 250 mensuales** (84 avisos en soles; rango intercuartil de S/ 200 a S/ 300). Es una referencia de mercado para la magnitud del efecto.

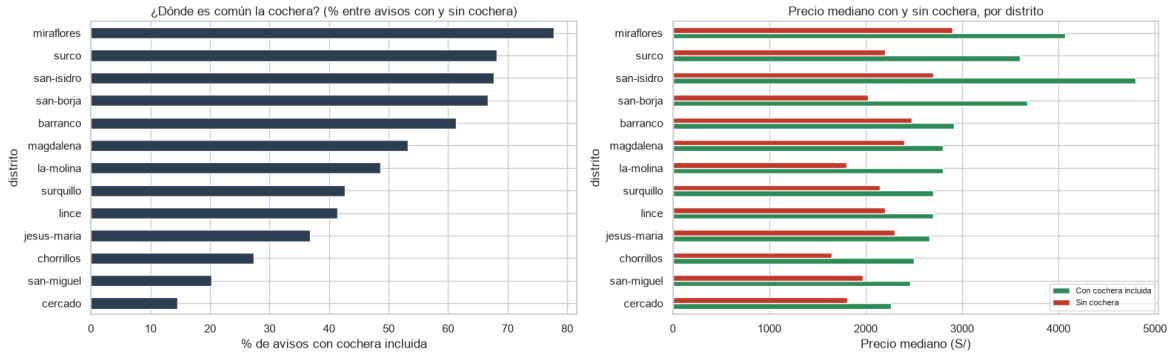


Figura 6.2: Porcentaje de avisos con cochera incluida y alquiler mediano con y sin cochera, por distrito.

Fuente: `notebook_resumen.ipynb`, sección 2.2.

6.4. Soporte común y balance (R2)

La propensión fuera de fold discrimina bien (AUC = 0.82; log-loss 0.52; Brier 0.17). Solo el 5 % de los avisos queda fuera de $[0.05, 0.95]$, y el soporte común conserva 1 949 avisos (1 046 tratados y 903 controles). Antes de ponderar, las diferencias estandarizadas son grandes (0.92 en el área y 0.71 en los baños). Después, todas son menores que 0.05 en valor absoluto (figura 6.3): los grupos son comparables.

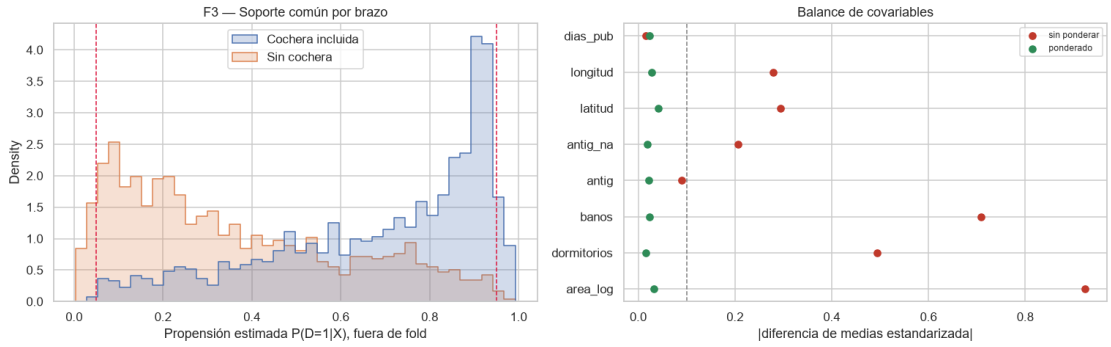


Figura 6.3: Soporte común: propensión por grupo y balance antes y después de ponderar (R2).

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 2 → `R2_soporte.csv`, `R2_balance.csv`.

6.5. Efecto de la cochera incluida (R3)

Tabla 6.4: Efecto de tener cochera incluida sobre el precio de oferta (R3). EE agrupados por edificio

Estimador	N	θ	EE	IC 95 % (θ)	% efecto	IC 95 % (%)	S/ al mes
Diferencia sin ajustar (OLS)	2,051	0.4883	0.0197	[0.450, 0.527]	63.0	[56.8, 69.4]	1,668
Hedónico OLS	2,051	0.0748	0.0133	[0.049, 0.101]	7.8	[5.0, 10.6]	206
DML parcialmente lineal (PLR)	2,051	0.0683	0.0119	[0.045, 0.092]	7.1	[4.6, 9.6]	187
DML-IRM, muestra completa	2,051	0.0425	0.0356	[-0.027, 0.112]	4.3	[-2.7, 11.9]	115
DML-IRM, soporte común (principal)	1,949	0.0724	0.0184	[0.036, 0.108]	7.5	[3.7, 11.4]	199

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 3 → `R3c_principal.csv`. Alquiler de referencia: S/ 2 650.

La diferencia bruta del 63 % se reduce, con el DML-IRM en el soporte común, a **7.5 % (IC 95 %: 3.7–11.4 %)**: unos **S/ 199 mensuales** (entre S/ 98 y S/ 303). El hedónico (7.8 %) y el PLR (7.1 %) coinciden. Sin recorte, el IRM es inestable (IC de −2.7 a 11.9 %), lo que confirma la necesidad del soporte común. Las 10 particiones dieron entre 6.8 y 9.4 %, y el modelo de precio explica el 82 % de la varianza fuera de fold. **H1 se confirma.**

6.6. Grilla de especificaciones (R4)

Tabla 6.5: Efecto de la cochera bajo cada especificación (R4). DML-IRM, soporte común

Cód.	Especificación	Tipo	N	θ	EE	IC 95 %	% efecto
C1	Principal	válida	1,931	0.0732	0.0166	[0.041, 0.106]	7.6
C2	Sin área	omite confusor	1,972	0.1081	0.0272	[0.055, 0.161]	11.4
C3	Sin ubicación (distrito, lat, lon)	omite confusor	1,975	0.1961	0.0201	[0.157, 0.236]	21.7
C4	Sin baños ni dormitorios	omite confusor	1,941	0.0868	0.0183	[0.051, 0.123]	9.1
C5	Sin antigüedad	omite confusor	1,930	0.0775	0.0173	[0.044, 0.111]	8.1
C6	+ precio/m^2 (descendiente de Y)	control inadmisible	1,820	-0.0046	0.0080	[-0.020, 0.011]	-0.5
C7	Tratamiento estricto (incluida explícita)	medición	547	0.0764	0.0342	[0.009, 0.143]	7.9
C8	Cochera con costo extra también como D=1	medición	2,113	0.0515	0.0156	[0.021, 0.082]	5.3
C9	+ indicador de descripción cortada	medición	1,926	0.0717	0.0181	[0.036, 0.107]	7.4
P1	Folds y EE por bloque de 1 km	partición	1,953	0.0738	0.0204	[0.034, 0.114]	7.7

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 4 → `R4c_especificaciones.csv`.

- **Confusores omitidos:** sin ubicación, el efecto casi se triplica (21.7 %), porque las cocheras abundan en las zonas caras. Sin área sube a 11.4 %.
- **Control inadmisible:** el precio por m^2 lo anula (−0.5 %).
- **Medición:** las alternativas se mueven en la dirección esperada. La definición estricta da 7.9 %, y contar las de costo extra como tratadas, 5.3 %.

El efecto se mueve mucho más con los controles que con el estimador (7.1–7.8 %). **H2 se confirma.**

6.7. Robustez a confusores no observados (R5)

El valor de robustez es RV = 0.105: un confusor que explique el 10.5 % de la variación residual de la cochera y del precio anularía el efecto. Para que el IC incluya el cero basta una fuerza de 0.054. Comparado con los observados (figura 6.4), un confusor tan fuerte como la antigüedad llevaría el efecto a 0.4 %, y uno como la ubicación lo invertiría. La simulación muestra además que esta cota es optimista (sección 6.10). El resultado es **frágil**. **H4 se confirma.**

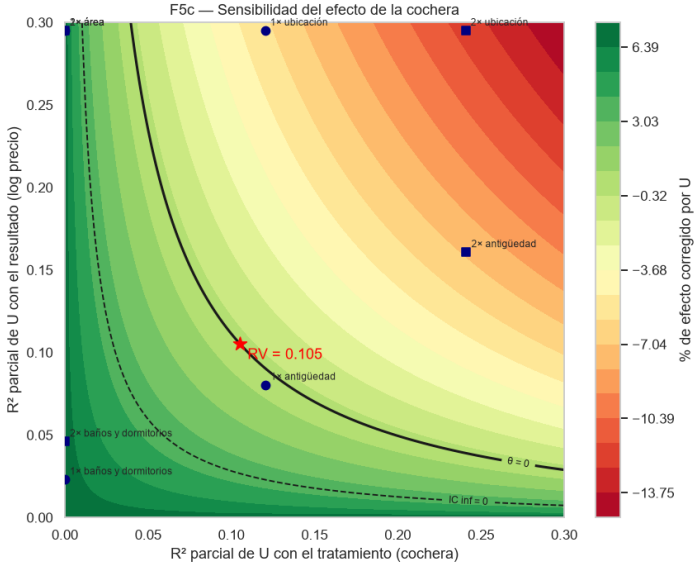


Figura 6.4: Contorno de sensibilidad del efecto de la cochera con benchmarks observados (R5).

Fuente: `notebook3b_efecto_cochera.ipynb`, sección 5 → `R5c_sensibilidad.csv`.

6.8. Heterogeneidad y dependencia espacial (R7)

El efecto difiere por clase de distrito (figura 6.5; Wald $\chi^2_2 = 18.3$, $p = 0.0001$):

- **clase1** (Miraflores, San Isidro, Barranco, Lince): 1.5 %, con un IC que incluye el cero;
- **clase2**: 10.3 %;
- **clase3**: 17.8 %.

Por tamaño no hay diferencias ($p = 0.35$). **H3 se confirma** por zona. Los residuos del

precio tienen una autocorrelación espacial pequeña (I de Moran = 0.019, $p = 0.025$), y el IC agrupado por bloque de 1 km también excluye el cero.

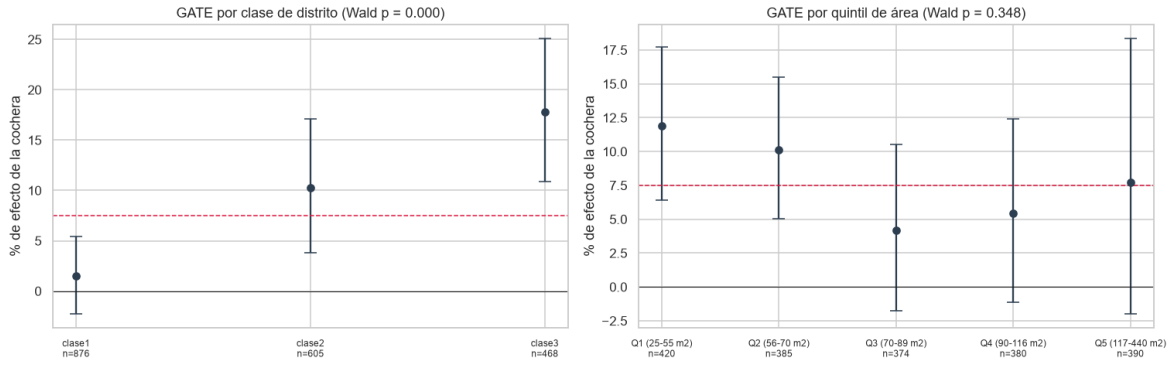


Figura 6.5: Efecto de la cochera por clase de distrito y por quintil de área (R7).
Fuente: `notebook3b_efecto_cochera.ipynb`, sección 6 → `R7c_gate.csv`.

6.9. Análisis secundario: un baño adicional

Con los mismos 2 220 avisos (`notebook3_estimacion_causal`), la asociación bruta del 45.7 % se reduce a 7.4 % con el hedónico y a **3.8 % (IC 95 %: 1.7–6.0 %)** con el DML, unos S/ 100 mensuales:

- los *learners* de árboles coinciden (3.8–4.4 %), mientras que Lasso, lineal, da 7.6 %;
- sin área el efecto sube a 19.5 %, y con el precio por m² se anula;
- agregar la cochera como control apenas lo cambia (3.5 %);
- con todas las precisiones de geocodificación sube a 5.1 %: la ubicación imprecisa lo inflaba;
- no hay heterogeneidad ($p > 0.3$), y un confusor como la antigüedad lo dejaría en 0.7 % (RV = 0.079).

6.10. Validación semisintética (R6)

Tabla 6.6: Validación semisintética del estimador binario (100 réplicas por escenario; efecto verdadero 0.10)

Escenario	Estimador	θ verdadero	Sesgo	RMSE	Cobertura IC 95 %	Long. IC
B1	Hedónico OLS	0.10	0.0002	0.0147	94	0.058
B1	DML PLR	0.10	-0.0040	0.0145	95	0.055
B1	DML-IRM (soporte común)	0.10	-0.0036	0.0198	96	0.081
B2	Hedónico OLS	0.10	0.0412	0.0434	19	0.057
B2	DML PLR	0.10	0.0392	0.0418	20	0.053
B2	DML-IRM (soporte común)	0.10	0.0421	0.0462	45	0.078

Fuente: `notebook4_semisintetico.ipynb` → `R6b_simulacion_binaria.csv`.

Sin confusor omitido (B1). Los tres estimadores recuperan el efecto: el sesgo es de 0.004 o menos y la cobertura del 94 al 96 %.

Con confusor moderado (B2). Todos se sesgan ($\approx +0.04$) y la cobertura cae al 19–45 %. La cota de sensibilidad estimó un sesgo de 0.024 frente a uno real de 0.042, de modo que es **optimista** para el tratamiento binario.

Baños. Para el estimador de baños, la simulación confirma tres cosas:

- sin confusor, el DML es insesgado (cobertura del 93 %), mientras que el hedónico lineal sobreestima el efecto (cobertura del 50 %);
- con confusor, la cota sí es fiel (cobertura del 95–98 %);
- la heterogeneidad real se detecta el 49 % de las veces.

Capítulo 7

Discusión

7.1. Interpretación

Entre departamentos con dirección exacta y con igual área, distribución, antigüedad y ubicación, los que incluyen cochera se ofrecen en promedio un 7.5 % más caros: unos S/ 199 al mes. Casi todo el 63 % de la diferencia bruta se debe a que los departamentos con cochera son más grandes y están en zonas más caras.

Heterogeneidad. La prima es casi nula en los distritos más caros (1.5 %) y llega al 18 % donde la cochera escasea. Una explicación coherente con la teoría hedónica y con el contexto local es la *escasez relativa*. En Miraflores y San Isidro, la normativa municipal fija un mínimo de estacionamientos por vivienda (Municipalidad de Miraflores, 2011; Municipalidad de San Isidro, 2020), y la mayoría de los avisos incluye cochera (78 % y 68 %). Allí no distingue a un aviso de otro, mientras que en Cercado (15 %) o San Miguel (20 %) el mercado la paga. Lince, en la clase1, es una excepción (41 %), y la explicación no se contrastó formalmente.

7.2. Contraste con los antecedentes

- **Con el avance previo.** La regresión lineal del `notebook1` asociaba un baño adicional con S/ 195–298. El análisis causal con direcciones exactas lo reduce a unos S/ 100 (3.8 %). Con direcciones imprecisas el efecto sube a 5.1 %: la calidad de la geocodificación cambia el resultado.
- **Con los estudios peruanos.** Cacñahuaray y Jiménez (2024) y Barrientos et al. (2026) identifican la cochera entre los mejores predictores del precio en Lima, y esta tesis confirma que el atributo importa. La diferencia está en qué se mide: esos

modelos cuantifican cuánto ayuda la cochera a *predecir*, una medida que la mezcla con el tamaño y la zona. Aquí se mide cuánto cambia el precio por la cochera misma, y resulta mucho menos (7.5 % frente a 63 %). Mundaca y Sánchez (2018) coinciden en la dirección y en que la cochera es el atributo más valorado, pero no son comparables en magnitud, porque estudian la venta y cada cochera adicional.

- **Con el propio mercado.** Los avisos que cobran la cochera aparte piden una mediana de S/ 250 mensuales, del mismo orden que el efecto estimado (S/ 199). Que este sea algo menor es razonable, porque quien la paga aparte la necesita.
- **Con la evidencia internacional.** En Estados Unidos, la cochera incluida eleva el alquiler en torno al 17 % (Gabbe y Pierce, 2017). Una prima menor en Lima es coherente con que solo alrededor del 17 % de los hogares tiene automóvil (Lima Cómo Vamos, 2016).
- **Con la metodología.** La grilla confirma que la flexibilidad del DML no protege contra los malos controles (Hünermund et al., 2023). La simulación confirma, además, que el hedónico lineal sobreestima los efectos cuando la confusión es no lineal.

7.3. Amenazas a la validez

Confusión no observada. Un confusor tan fuerte como la antigüedad llevaría la prima cerca de cero, y la cota binaria es optimista. El candidato es la calidad del edificio. La heterogeneidad atenúa en parte esta preocupación: si la prima fuera solo calidad omitida, cabría esperarla mayor en las zonas de mayor estándar, y ocurre lo contrario.

Medición. La clasificación depende del texto, y el 72 % de las descripciones termina con la marca “Leer descripción completa”. Si un aviso con cochera no la menciona, queda como control. Si ese error no difiere entre grupos, atenúa el efecto. La definición estricta (7.9 %) y el control por truncamiento (7.4 %) no sugieren un sesgo grande, pero falta la validación humana (Egami et al., 2023).

Población. Precios de oferta, un solo portal y un solo mes, y solo direcciones exactas, que en promedio son más caras. Los resultados no se transportan a contratos, a todo el parque residencial ni a avisos con dirección vaga. Tampoco justifican afirmar que agregar una cochera elevará la renta en un 7.5 % en cualquier distrito.

Capítulo 8

Conclusiones y recomendaciones

8.1. Respuesta a la pregunta

Entre avisos de alquiler de departamentos en 13 distritos de Lima con dirección exacta, y bajo el supuesto de que área, distribución, antigüedad y ubicación capturan lo que determina a la vez la cochera y el precio, **tener cochera incluida eleva el precio de oferta en 7.5 % (IC 95 %: 3.7–11.4 %), unos S/ 199 al mes**. La prima es casi nula donde la cochera es habitual y llega al 18 % donde escasea. El resultado es estable ante cambios de estimador y de definición del tratamiento, y sensible a los errores de especificación que advierte el DAG. Su fragilidad es considerable: un confusor tan influyente como la antigüedad bastaría para llevarlo cerca de cero.

8.2. Conclusiones por objetivo

Tabla 8.1: Objetivo, evidencia y conclusión verificable

Objetivo	Evidencia	Conclusión
OE1 Auditoría	Tabla 6.2	2 220 avisos válidos de 3 739; 243 duplicados y 30 % de direcciones imprecisas detectados
OE2 Identificación	Figura 3.1, tabla 3.1, figura 6.3	Estimando defendible en el soporte común (95 % de la muestra, grupos balanceados); amenaza: calidad del edificio
OE3 Estimación	Tabla 6.4	+7.5 % frente a 63 % bruto; los estimadores coinciden. **H1 se confirma**
OE4 Variación y sensibilidad	Tabla 6.5, figuras 6.4 y 6.5	Los controles importan más que el estimador (**H2**); efecto heterogéneo por zona (**H3**); frágil frente a confusores (**H4**)
OE5 Medición con IA	Tabla 6.3	Medición barata (0.76 USD) y trazable; exploratoria hasta validarla
OE6 Validación	Tabla 6.6	Los estimadores funcionan sin confusión omitida; la cota binaria es optimista
OE7 Trazabilidad	Anexo C	Cada resultado es rastreable a su notebook; falta un comando único

Tres tipos de afirmaciones.

- **Observacional:** los avisos con cochera cuestan un 63 % más, pero casi todo es tamaño y zona.
- **Causal condicionada a los supuestos:** la cochera incluida eleva el alquiler de oferta entre 3.7 y 11.4 %, y más donde escasea.
- **Hipótesis futuras:** que la heterogeneidad responda a la escasez y a la normativa, y que la prima de oferta se traslade al contrato.

8.3. Límites del trabajo

- **Identificación:** la ignorabilidad solo puede acotarse, y la calidad del edificio no se observa.
- **Medición:** la IA no tiene validación humana. Además, "sin mención" se trata como "sin cochera", y el 72 % de las descripciones podría estar truncado.

- **Tratamiento:** es sí/no; las cocheras múltiples (26 % de los tratados) se agrupan y las de costo extra se excluyen.
- **Sensibilidad:** la cota binaria es optimista.
- **Población:** oferta, no contrato; un portal y un mes; solo direcciones exactas, que excluyen el 30 % de los avisos.

8.4. Recomendaciones

1. **Validar la medición** con los 249 avisos etiquetados a mano y corregir el efecto con el estimador de Egami et al. (2023).
2. **Medir la calidad del edificio** desde el texto (ascensor, acabados, seguridad) para reducir la amenaza principal.
3. **Ampliar los datos** a más meses y portales, y **consolidar el repositorio** con un comando único reproducible.

Referencias

Advani, A., Kitagawa, T., & Słoczyński, T. (2019). Mostly harmless simulations? Using Monte Carlo studies for estimator selection. *Journal of Applied Econometrics, 34*(6), 893–910. https://doi.org/10.1002/jae.2724

Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized random forests. *The Annals of Statistics, 47*(2), 1148–1178. https://doi.org/10.1214/18-AOS1709

Bach, P., Chernozhukov, V., Kurz, M. S., & Spindler, M. (2022). DoubleML: An object-oriented implementation of double machine learning in Python. *Journal of Machine Learning Research, 23*(53), 1–6. https://www.jmlr.org/papers/v23/21-0862.html

Barrientos, R., Delgado, R., Escalante, L., Febres, G., Hisbes, B., Chavez-Bedoya, L., Rosales, F., & Vargas, W. (2026). Using machine learning to predict apartment prices in Lima. En *Entrepreneurship and human-centric business strategies for social and economic resilience* (pp. 2725–2737). Springer. https://doi.org/10.1007/978-981-95-6415-6_168

Black, S. E. (1999). Do better schools matter? Parental valuation of elementary education. *The Quarterly Journal of Economics, 114*(2), 577–599. https://doi.org/10.1162/003355399556070

Boeing, G., & Waddell, P. (2017). New insights into rental housing markets across the United States: Web scraping and analyzing Craigslist rental listings. *Journal of Planning Education and Research, 37*(4), 457–476. https://doi.org/10.1177/0739456X16664789

Cacñahuaray Huaraca, J. C., & Jiménez Novoa, S. M. (2024). *Modelo predictivo de precios de alquiler de departamentos en la provincia de Lima usando técnicas de machine learning* [Tesis de segunda especialidad, Universidad Peruana Unión]. Repositorio institucional UPeU.

Cameron, A. C., & Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources, 50*(2), 317–372. https://doi.org/10.3368/jhr.50.2.317

Chay, K. Y., & Greenstone, M. (2005). Does air quality matter? Evidence from the housing market. *Journal of Political Economy, 113*(2), 376–424. https://doi.org/10.1086/427462

Chen, Z., Moeltner, K., & Mair, M. (2026). *Recovering direct price effects of environmental amenities in housing markets: Regression and causal machine learning model assessment with empirical Monte Carlo simulation* (arXiv:2606.02795). arXiv. https://arxiv.org/abs/2606.02795

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal, 21*(1), C1–C68. https://doi.org/10.1111/ectj.12097

Chernozhukov, V., Cinelli, C., Newey, W., Sharma, A., & Syrgkanis, V. (2022). *Long story short: Omitted variable bias in causal machine learning* (NBER Working Paper No. 30302). National Bureau of Economic Research. https://www.nber.org/papers/w30302

Cinelli, C., Forney, A., & Pearl, J. (2024). A crash course in good and bad controls. *Sociological Methods & Research, 53*(3), 1071–1104. https://doi.org/10.1177/00491241221099552

Cinelli, C., & Hazlett, C. (2020). Making sense of sensitivity: Extending omitted variable bias. *Journal of the Royal Statistical Society: Series B, 82*(1), 39–67. https://doi.org/10.1111/rssb.12348

Contreras, C., Aguilar, D., & Lázaro, J. (2024). Impacto del transporte masivo en la informalidad de vivienda: el caso de la Línea 1 del Metro de Lima. *Argumentos, 5*(1). Instituto de Estudios Peruanos. https://doi.org/10.46476/ra.v5i1.183

Egami, N., Hinck, M., Stewart, B. M., & Wei, H. (2023). Using imperfect surrogates for downstream inference: Design-based supervised learning for social science applications of large language models. En *Advances in Neural Information Processing Systems 36* (NeurIPS 2023).

Faxvaag, H., Aarsnes, U., & Oust, A. (2026). Incorporating large language models in automated real estate valuation. *Journal of Real Estate Research, 48*(3), 454–479. https://doi.org/10.1080/08965803.2025.2587313

Gabbe, C. J., & Pierce, G. (2017). Hidden costs and deadweight losses: Bundled parking and residential rents in the metropolitan United States. *Housing Policy Debate, 27*(2), 217–229. https://doi.org/10.1080/10511482.2016.1205647

Gyger, T., Hauri, S., Bühlmann, S., Lehner, M., Schlesinger, J., & Sigrist, F. (2026). Explainable spatial machine learning for hedonic real estate modeling. *Real Estate Economics, 54*(3), 761–806. https://doi.org/10.1111/1540-6229.70030

Hernán, M. A., & Robins, J. M. (2020). *Causal inference: What if*. Chapman & Hall/CRC.

Hünermund, P., Louw, B., & Caspi, I. (2023). Double machine learning and automated confounder selection: A cautionary tale. *Journal of Causal Inference, 11*(1), 20220078. https://doi.org/10.1515/jci-2022-0078

Imbens, G. W., & Rubin, D. B. (2015). *Causal inference for statistics, social, and biomedical sciences: An introduction*. Cambridge University Press.

Keele, L. J., & Titiunik, R. (2015). Geographic boundaries as regression discontinuities. *Political Analysis, 23*(1), 127–155. https://doi.org/10.1093/pan/mpu014

Knaus, M. C., Lechner, M., & Strittmatter, A. (2021). Machine learning estimation of heterogeneous causal effects: Empirical Monte Carlo evidence. *The Econometrics Journal, 24*(1), 134–161. https://doi.org/10.1093/ectj/utaa014

Lima Cómo Vamos. (2016). *Cómo vamos en movilidad: sexto informe de resultados sobre*

calidad de vida en Lima y Callao 2015. Lima Cómo Vamos.

Malpezzi, S. (2003). Hedonic pricing models: A selective and applied review. En T. O'Sullivan & K. Gibb (Eds.), *Housing economics and public policy* (pp. 67–89). Blackwell.

Manville, M. (2013). Parking requirements and housing development: Regulation and reform in Los Angeles. *Journal of the American Planning Association, 79*(1), 49–66. https://doi.org/10.1080/01944363.2013.785346

Mayo Urtecho, H. M. (2017). *Elaboración de un índice de precios de viviendas nuevas para Lima Metropolitana mediante precios hedónicos* [Tesis de grado, Universidad Nacional de Ingeniería]. http://hdl.handle.net/20.500.14076/13730

Moran, P. A. P. (1950). Notes on continuous stochastic phenomena. *Biometrika, 37*(1/2), 17–23. https://doi.org/10.2307/2332142

Mundaca, F., & Sánchez, E. (2018). Índice de precios de inmuebles: un enfoque hedónico. *Revista Estudios Económicos, 36*, 55–74. Banco Central de Reserva del Perú.

Municipalidad de Miraflores. (2011). *Ordenanza N.° 342/MM: aprueban parámetros urbanísticos y edificatorios y las condiciones generales de edificación en el distrito* (art. 10: número mínimo de estacionamientos por unidad de vivienda; modificada por las Ordenanzas 385-MM y 466-MM).

Municipalidad de San Isidro. (2020). *Ordenanza N.° 523-MSI* (parámetros de estacionamiento para edificaciones multifamiliares).

Nowak, A., & Smith, P. (2017). Textual analysis in real estate. *Journal of Applied Econometrics, 32*(4), 896–918. https://doi.org/10.1002/jae.2550

Pearl, J. (2009). *Causality: Models, reasoning, and inference* (2.ª ed.). Cambridge University Press.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rivera Romero, L. A. (2018). *Caso: determinantes del precio por metro cuadrado para departamentos en Lima Metropolitana: período 2005–2017* [Trabajo académico, Universidad de Lima].

Robinson, P. M. (1988). Root-N-consistent semiparametric regression. *Econometrica, 56*(4), 931–954. https://doi.org/10.2307/1912705

Rosen, S. (1974). Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy, 82*(1), 34–55. https://doi.org/10.1086/260169

Shen, L., & Ross, S. (2021). Information value of property description: A machine learning approach. *Journal of Urban Economics, 121*, 103299. https://doi.org/10.1016/j.jue.2020.103299

Sirmans, G. S., Macpherson, D. A., & Zietz, E. N. (2005). The composition of hedonic pricing models. *Journal of Real Estate Literature, 13*(1), 1–44. https://doi.org/10.1080/10835547.2005.12090154

Tapia, J., Chavez-Garzon, N., Pezoa, R., Suarez-Aldunate, P., & Pilleux, M. (2025). Comparing automated valuation models for real estate assessment in the Santiago Metropolitan Region: A study on machine learning algorithms and hedonic pricing with spatial adjustments. *PLOS ONE, 20*(3), e0318701. https://doi.org/10.1371/journal.pone.0318701

Urbania. (2025). *Urbania Index: índice de venta y alquiler, informe de mercado Lima, julio 2025*. https://urbania.pe/blog/urbania-index-lima/

VanderWeele, T. J., & Ding, P. (2017). Sensitivity analysis in observational research: Introducing the E-value. *Annals of Internal Medicine, 167*(4), 268–274. https://doi.org/10.7326/M16-2607

Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association, 113*(523), 1228–1242. https://doi.org/10.1080/01621459.2017.1319839

Apéndice A

Correspondencia con la rúbrica de evaluación

Criterio de la rúbrica	Puntos	Dónde se desarrolla
Justificación científica	2	Sección 1.2
Hipótesis, objetivos	2	Secciones 1.3–1.5 y tabla 1.1
Revisión de antecedentes teóricos y experimentales	2	Capítulo 2 (secciones 2.1 y 2.2) y anexo B
Presentación de resultados teóricos y/o experimentales	4	Teóricos: capítulos 3–5. Experimentales: capítulo 6 (tabla 6.1)
Discusión de resultados	2	Capítulo 7
Conclusiones	2	Capítulo 8 (tabla 8.1)
Bibliografía	1	44 referencias en APA 7, con DOI verificados en Crossref y todas citadas en el texto

Apéndice B

Registro de la búsqueda bibliográfica

Fuentes: Google Scholar, RePEc, arXiv, NBER, Crossref; repositorios peruanos (ALICIA-CONCYTEC, UNI, UPeU, ESAN, Universidad de Lima, Universidad del Pacífico, IEP), BCRP y normativa municipal. Los metadatos se verificaron el 21 y el 25 de octubre de 2026.

Cadenas principales:

- `("doublemachinelearning"OR"causalforest")AND(housingORrentalORhedonic)`
- `"precioalquilerdepartamentosLima"AND(hedónicoOR"machinelearning"ORestacionamientoORcochera)`
- `("inferenciacausal"OR"diferenciasendiferencias")ANDviviendaAND(LimaORPerú)`
- `("bundledparking"OR"parkingpremium")ANDrent`
- `("largelanguagemodel"ORGPT)AND("realestate"ORhousing)ANDlisting`

Criterios: se incluyeron estudios que estiman precios implícitos, predicen precios o identifican efectos de atributos de la vivienda, y los trabajos metodológicos usados directamente. Se excluyeron los estudios sin metadatos verificables y las versiones duplicadas, en cuyo caso se cita la versión publicada.

Apéndice C

Reproducibilidad y trazabilidad

Artefacto (`notebooks/`)	Contenido
`notebook2_auditoria`	R1: limpieza, duplicados, ROOFTOP; genera `csv/data_causal_base.csv`
`notebook2b_extraccion_ia` + `extraccion_ia.py`	R8: extracción de la cochera (regex + OpenAI, con caché)
`notebook3b_efecto_cochera`	R2–R5, R7: resultado principal
`notebook3_estimacion_causal`	Análisis secundario (baños)
`notebook4_semisintetico` + `semisintetico.py`	R6: validación semisintética
`notebook_resumen`	EDA resumido y recorrido de toda la tesis
`causal_utils.py`	Estimadores DML (PLR, IRM), GATE, sensibilidad, Moran
`informe/tablas_manuscrito.py`	Convierte los CSV de resultados en las tablas del informe

Orden de ejecución: `notebook2` → `2b` → `3b` → `3` → `4` → `notebook_resumen` → `tablas_manuscrito.py` → compilación. La semilla es `SEED=42`. Una segunda ejecución completa reprodujo exactamente las 29 tablas y los resúmenes.

Software: Python 3.13, pandas 3.0, scikit-learn 1.9 (Pedregosa et al., 2011), statsmodels 0.15 y `gpt-4.1-mini-2025-04-14`, con el prompt v2.

Privacidad: los datos (`data/`, `csv/`) y la clave (`.env`) no se versionan, y la base analítica no contiene descripciones, direcciones ni teléfonos.